

Politechnika Warszawska

W Y D Z I A Ł E L E K T R Y C Z N Y



Instytut Sterowania i Elektroniki Przemysłowej

Praca dyplomowa magisterska

na kierunku Informatyka Stosowana
w specjalności Inżynieria Oprogramowania

Sieć neuronowa dla gier typu fantasy football do konkursu BotBowlI

inż. Mikołaj Klębowski

numer albumu 299253

promotor

dr inż. Krzysztof Hryniów

WARSZAWA 2026

Sieć neuronowa dla gier typu fantasy football do konkursu BotBowl

Streszczenie

Praca dotyczy zastosowania metod uczenia ze wzmocnieniem oraz głębokich sieci neuronowych do nauki gry w Blood Bowl w środowisku symulacyjnym BotBowl. Blood Bowl stanowi wymagające środowisko badawcze ze względu na bardzo dużą przestrzeń stanów, wysoki współczynnik rozgałęzienia decyzji, losowość wynikającą z mechaniki rzutów kośćmi oraz długoterminowe zależności pomiędzy działaniami agenta. W takich warunkach klasyczne metody przeszukiwania drzew decyzyjnych okazują się niewystarczające, co czyni uczenie ze wzmocnieniem obiecującym podejściem do konstruowania agentów zdolnych do podejmowania skutecznych decyzji.

Celem pracy było porównanie różnych architektur sieci neuronowych stosowanych w agentach uczących się gry w Blood Bowl z wykorzystaniem algorytmów typu actor-critic. W badaniach zastosowano dwa algorytmy uczenia ze wzmocnieniem: Advantage Actor-Critic (A2C) oraz Proximal Policy Optimization (PPO). Analizowano modele oparte na klasycznych warstwach konwolucyjnych, blokach Inception, architekturze ResNet, blokach Inception-Residual oraz mechanizmie hyper-connections. W badanych sieciach wykorzystano również techniki stabilizacji uczenia, takie jak Layer Normalization, inicjalizacja He, funkcja aktywacji Parametric ReLU (PReLU) oraz maskowanie niedozwolonych akcji.

Reprezentacja stanu gry została podzielona na dwa strumienie: przestrzenny, opisujący układ planszy, oraz nieprzestrzenny, zawierający parametry bieżącego stanu rozgrywki. Dane przestrzenne były przetwarzane przez sieci konwolucyjne, natomiast dane nieprzestrzenne przez warstwy w pełni połączone. Eksperymenty przeprowadzono w środowisku BotBowl implementującym zasady gry Blood Bowl i udostępniającym interfejs zgodny ze standardem OpenAI Gym. Postęp uczenia oceniano na podstawie średniej nagrody, liczby przyłożeń na epizod oraz wskaźnika zwycięstw.

Uzyskane wyniki wskazują, że architektura sieci neuronowej istotnie wpływa na zdolność agenta do nauki skutecznej strategii. Najlepsze rezultaty osiągnęły modele wykorzystujące algorytm PPO oraz bardziej zaawansowane mechanizmy ekstrakcji cech przestrzennych, w szczególności bloki Inception i hyper-connections. Jednocześnie eksperymenty potwierdziły, że środowisko Blood Bowl generuje dużą wariancję wyników ze względu na losowość mechaniki gry i rzadkość nagród, co utrudnia ocenę jakości modeli na podstawie pojedynczych przebiegów treningu.

Wyniki pracy potwierdzają, że odpowiedni dobór architektury sieci neuronowej ma kluczowe znaczenie dla skutecznego zastosowania uczenia ze wzmocnieniem w złożonych środowiskach decyzyjnych. Otrzymane rezultaty wskazują również, że Blood Bowl może stanowić wartościowy benchmark do dalszych badań nad architekturami głębokiego uczenia i metodami Uczenia ze Wzmocnieniem (RL) w zadaniach o dużej przestrzeni decyzyjnej.

Słowa kluczowe: uczenie ze wzmocnieniem, Blood Bowl, BotBowl, sieci neuronowe, PPO, A2C, sieci konwolucyjne.

Bot Bowl - learning the neural network game of Blood Bowl

Abstract

This thesis concerns the application of reinforcement learning methods and deep neural networks to learning to play Blood Bowl in the BotBowl simulation environment. Blood Bowl is a challenging research environment due to its very large state space, high branching factor, randomness resulting from dice-based game mechanics, and long-term dependencies between an agent's actions. Under such conditions, classical tree-search methods become insufficient, which makes reinforcement learning a promising approach for constructing agents capable of making effective decisions.

The aim of this thesis was to compare different neural network architectures used in agents learning to play Blood Bowl with actor-critic algorithms. Two reinforcement learning algorithms were employed in the study: Advantage Actor-Critic (A2C) and Proximal Policy Optimization (PPO). The analyzed models were based on classical convolutional layers, Inception blocks, the ResNet architecture, Inception-Residual blocks, and the hyper-connections mechanism. The examined networks also incorporated training stabilization techniques such as Layer Normalization, He initialization, the Parametric ReLU (PReLU) activation function, and invalid action masking.

The game state representation was divided into two streams: a spatial stream describing the board layout and a non-spatial stream containing parameters of the current game state. Spatial data were processed by convolutional neural networks, whereas non-spatial data were processed by fully connected layers. The experiments were conducted in the BotBowl environment, which implements the rules of Blood Bowl and provides an interface compatible with the OpenAI Gym standard. Learning progress was evaluated using average reward, touchdowns per episode, and win rate.

The obtained results indicate that the neural network architecture significantly affects the agent's ability to learn an effective strategy. The best results were achieved by models using the PPO algorithm and more advanced spatial feature extraction mechanisms, in particular Inception blocks and hyper-connections. At the same time, the experiments confirmed that the Blood Bowl environment produces high variance in results due to the randomness of the game mechanics and the sparsity of rewards, which makes it difficult to assess model quality on the basis of single training runs.

The results of this thesis confirm that the proper selection of neural network architecture is crucial for the effective application of reinforcement learning in complex decision-making environments. The obtained findings also indicate that Blood Bowl may serve as a valuable benchmark for further research on deep learning architectures and reinforcement learning (RL) methods in tasks with a large decision space.

Keywords: reinforcement learning, Blood Bowl, BotBowl, neural networks, PPO, A2C, convolutional networks.

Spis treści

1	Wstęp	9
2	Sieci Neuronowe	11
2.1	Funkcja aktywacji	12
2.2	Architektura sieci neuronowej	14
2.3	Sieci Splotowe	16
2.3.1	Geneza	16
2.3.2	Sposób działania	16
2.4	Techniki uczenia sieci neuronowych	19
2.5	Funkcje straty w uczeniu ze wzmocnieniem	21
2.6	Algorytmy optymalizacji	22
2.7	Problemy gradientowe	26
2.8	Techniki stabilizacji i usprawnienia procesu uczenia	28
3	Zestawienie użytych rozwiązań	31
3.1	Algorytmy aktor–krytyk	31
3.2	Advantage Actor-Critic (A2C)	34
3.3	PPO	36
3.4	Współdzielenie części konwolucyjnej	38
3.5	Reprezentacja danych wejściowych	38
3.6	Architektura typu CNN z blokiem Inception	39
3.7	ResNet	41
3.8	Inception-Residual	41
3.9	Hyper-Connections	42
3.10	Rozszerzenia architektury sieci i techniki stabilizacji uczenia	46
3.11	Architektury sieci neuronowych zastosowanych w środowisku	50
3.11.1	Analizowane warianty architektur	52
4	Środowisko testowe	55
4.1	Blood Bowl jako benchmark dla uczenia ze wzmocnieniem.	56
4.2	Środowisko BotBowl	57
4.3	Przegląd najlepszych rozwiązań w środowisku BotBowl	59

5	Eksperymenty	61
5.1	Wyniki w pełnej skali	66
5.2	Ograniczenia wykorzystania rozwiązań referencyjnych	68
6	Podsumowanie	69
	Spis rysunków	75
	Spis tabel	77

Rozdział 1

Wstęp

W ostatnich latach sztuczna inteligencja, a w szczególności metody oparte na głębokich sieciach neuronowych, stały się jednym z kluczowych obszarów rozwoju współczesnej informatyki. Ich zastosowania obejmują zarówno zadania percepcyjne, takie jak rozpoznawanie obrazów i mowy, jak i problemy decyzyjne występujące w systemach autonomicznych, analizie danych czy optymalizacji procesów przemysłowych. Dynamiczny postęp w tej dziedzinie wynika w dużej mierze z rosnących możliwości obliczeniowych oraz rozwoju algorytmów umożliwiających skuteczne uczenie modeli na podstawie dużych zbiorów danych. Coraz częściej systemy te potrafią podejmować złożone decyzje w sposób autonomiczny, bez bezpośredniego nadzoru człowieka.

Szczególną rolę w tym kontekście odgrywa uczenie ze wzmocnieniem, stanowiące jeden z podstawowych paradygmatów uczenia maszynowego, skoncentrowany na problemach sekwencyjnego podejmowania decyzji przez agenta, czyli system wchodzący w interakcję ze środowiskiem. W przeciwieństwie do uczenia nadzorowanego, w którym model otrzymuje pary danych wejściowych i oczekiwanych odpowiedzi, w uczeniu ze wzmocnieniem agent zdobywa wiedzę poprzez interakcję ze środowiskiem oraz obserwację konsekwencji podejmowanych działań. Takie podejście pozwala modelować problemy, w których nagroda jest opóźniona w czasie, a decyzje podejmowane na wczesnym etapie wpływają na dalszy przebieg procesu. Z tego względu metody te znajdują zastosowanie m.in. w robotyce, systemach sterowania, logistyce, finansach oraz w grach.

Gry od wielu lat pełnią funkcję kluczowych środowisk testowych dla algorytmów sztucznej inteligencji. Ich popularność wynika z kilku cech: jasno zdefiniowanych reguł, możliwości precyzyjnego pomiaru wyników oraz łatwości powtarzania eksperymentów w identycznych warunkach początkowych. Dzięki temu umożliwiają obiektywne porównywanie skuteczności różnych metod i architektur modeli uczących się. W historii rozwoju sztucznej inteligencji gry planszowe, karciane oraz komputerowe wielokrotnie wykorzystywano jako środowiska badawcze pozwalające analizować zachowanie agentów w warunkach wysokiej złożoności decyzyjnej.

Istotnym wyzwaniem w środowiskach decyzyjnych jest duża przestrzeń stanów oraz wysoki współczynnik rozgałęzienia akcji (*ang. branching factor*). W takich warunkach liczba potencjalnych trajektorii działania agenta rośnie wykładniczo wraz z długością sekwencji decyzji, co znacząco

utrudnia zarówno eksplorację przestrzeni rozwiązań, jak i stabilne uczenie modeli. Dodatkową trudność stanowi obecność losowości, która wprowadza niepewność co do skutków podejmowanych działań i wymusza na agencie uczenie się strategii odpornych na zmienne warunki.

Gra Blood Bowl, będąca turową grą strategiczną wywodzącą się z gry planszowej, stanowi przykład środowiska spełniającego wszystkie powyższe kryteria. Rozgrywka łączy elementy planowania długoterminowego, zarządzania ryzykiem oraz reagowania na zdarzenia losowe, takie jak wyniki rzutów kośćmi. W każdej turze gracz ma do dyspozycji wiele akcji, których kolejność i wybór mają istotny wpływ na dalszy przebieg meczu. Wysoki poziom złożoności decyzyjnej oraz wieloetapowy charakter gry sprawiają, że Blood Bowl stanowi wymagające i jednocześnie wartościowe środowisko do badań nad algorytmami uczenia ze wzmocnieniem.

Motywacją niniejszej pracy jest potrzeba lepszego zrozumienia, w jaki sposób różne architektury sieci neuronowych radzą sobie w środowiskach charakteryzujących się wysoką złożonością decyzyjną i znaczną losowością. W literaturze przedmiotu często prezentuje się wyniki uzyskiwane w relatywnie prostych środowiskach, takich jak klasyczne gry Atari czy zadania o ograniczonej liczbie akcji. Tymczasem bardziej złożone problemy decyzyjne, bliższe rzeczywistym zastosowaniom, mogą ujawniać istotne różnice między poszczególnymi podejściami architektonicznymi i algorytmicznymi.

Celem niniejszej pracy jest porównanie wybranych rozwiązań uczenia ze wzmocnieniem w kontekście gry Blood Bowl, ze szczególnym uwzględnieniem wpływu architektury sieci neuronowej na efektywność procesu uczenia. Analizie poddane zostaną różne podejścia do przetwarzania informacji, a także ich zdolność do wypracowywania skutecznych strategii w złożonym środowisku gry. Porównanie to pozwoli na ocenę, w jakim stopniu określone rozwiązania sprzyjają stabilnemu uczeniu oraz szybkiej adaptacji agenta do reguł rozgrywki.

Zakres pracy obejmuje zarówno omówienie teoretycznych podstaw uczenia ze wzmocnieniem i sieci neuronowych, jak i analizę praktycznych aspektów ich zastosowania w środowisku gry. W kolejnych rozdziałach przedstawiono podstawy teoretyczne, środowisko symulacyjne wykorzystane w badaniach, opis zastosowanych modeli oraz metodykę przeprowadzonych eksperymentów. Pracę kończy analiza uzyskanych wyników oraz wnioski dotyczące przydatności poszczególnych architektur w kontekście złożonych problemów decyzyjnych.

Rozdział 2

Sieci Neuronowe

Idea sztucznych sieci neuronowych narodziła się podczas prób modelowania pracy ludzkiego mózgu. Warren S. McCulloch oraz Walter Pitts w swojej pracy "A logical calculus of the ideas immanent in nervous activity" [20] zaproponowali model sieci neuronowej, jako graf skierowany, gdzie węzły to matematyczne modele neuronu takie, że

$$N_i(t+1) = H\left(\sum_{j=1}^n w_{ij}(t)N_j(t) - \Theta_i(t)\right)$$

gdzie:

- N - stan neuronu, może przyjąć wartość 0 lub 1
- $H()$ - funkcja skokowa Heaviside'a
- w_{ij} - waga połączenia między wektorem j oraz i .
- Θ - próg wyzwania, neuron aktywuje się, gdy sygnał wejściowy go przekroczy.

Sieć złożona z takich neuronów jest nazywana dzisiaj perceptronem. Służy ona do zadań klasyfikacji binarnej. Potrafi określić przynależność badanego obiektu do jednej z klas na podstawie wybranych cech. W 1957 roku Frank Rosenblatt opracował pierwszy uczący się perceptron, który stanowił przełom w rozwoju sztucznych sieci neuronowych. Pomimo swojej innowacyjności, model ten miał istotne ograniczenia – nie potrafił rozwiązywać problemów nieliniowych, takich jak klasyczny przykład funkcji XOR, a jego struktura uniemożliwiała zastosowanie metod uczenia opartych na obliczaniu pochodnych. Źródłem tego ograniczenia była funkcja skokowa Heaviside'a, wykorzystywana jako funkcja aktywacji neuronu. Współcześnie zastępuje się ją funkcjami ciągłymi i różniczkowalnymi, takimi jak sigmoid, tangens hiperboliczny czy ReLU (Rectified Linear Unit) wraz z jej modyfikacjami (np. Leaky ReLU, Parametric ReLU), które umożliwiają skuteczne stosowanie algorytmów gradientowych, takich jak propagacja wsteczna błędów. [22] Jak wspomniano wcześniej, model ten został stworzony w celu opisanie sposobu działania biologicznego neuronu. Można go uogólnić, pozwalając stworzyć bardziej uniwersalny model matematyczny.

$$y = f \left(\sum_{i=1}^m w_i(t) x_i(t) + b \right)$$

gdzie:

- w_i – waga
- x_i – wejście,
- f – funkcja aktywacji,
- y – wyjście,
- m – liczba wejść,
- b – stała wartość (ang. bias).

Do funkcji aktywacji f przekazywana jest ważona suma sygnałów wejściowych, do której dodaje się opcjonalnie parametr bias. Taki opis umożliwia zastosowanie dowolnej funkcji aktywacji, co pozwala sieci neuronowej modelować nieliniowe zależności.

2.1 Funkcja aktywacji

Jednym z kluczowych elementów sztucznego neuronu jest funkcja aktywacji, która określa, w jaki sposób sygnał wejściowy jest przekształcany w sygnał wyjściowy. Od jej właściwości zależy zdolność sieci neuronowej do modelowania złożonych zależności nieliniowych.

Pierwszym powszechnie stosowanym rozwiązaniem była funkcja skokowa Heaviside'a:

$$H(x) = \begin{cases} 0, & x < 0, \\ 1, & x \geq 0. \end{cases}$$

która aktywuje neuron dopiero po przekroczeniu określonego progu. Funkcja ta stanowi uproszczony model działania neuronu biologicznego, który reaguje po osiągnięciu odpowiedniego poziomu pobudzenia, jednak z matematycznego punktu widzenia ma istotną wadę — nie jest różniczkowalna. Jej pochodna jest równa zero dla wszystkich wartości oprócz punktu $x = 0$, gdzie jest nieokreślona. W konsekwencji uniemożliwia to stosowanie metod uczenia opartych na gradiencie, takich jak propagacja wsteczna błędów.

Aby umożliwić płynne i różniczkowalne przejście między stanami aktywacji, wprowadzono funkcje ciągłe, takie jak sigmoid i tangens hiperboliczny ($\tanh$). Funkcja sigmoidalna ma postać:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

a tangens hiperboliczny:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Obie funkcje zapewniają gładką i różniczkowalną zależność między sygnałem wejściowym a wyjściem neuronu, co umożliwia stosowanie gradientowych metod optymalizacji. Dodatkową zaletą funkcji $\tanh(x)$ jest zakres wartości $(-1, 1)$ oraz symetria względem zera, co sprzyja uczeniu głębokich sieci neuronowych. Ich istotną wadą jest jednak zjawisko nasycenia: dla dużych wartości argumentu pochodna tych funkcji przyjmuje wartości bliskie zero, co prowadzi do problemu zanikającego gradientu.

W odpowiedzi na te ograniczenia opracowano funkcję ReLU (Rectified Linear Unit), definiowaną jako:

$$\text{ReLU}(x) = \max(0, x) = \begin{cases} 0, & x \leq 0, \\ x, & x > 0. \end{cases}$$

Funkcja ta jest ciągła w całej swojej dziedzinie, również w punkcie $x=0$, lecz nie jest różniczkowalna w tym punkcie — lewa pochodna wynosi 0, a prawa 1. W praktyce jednak przyjmuje się, że funkcja jest „różniczkowalna prawie wszędzie”, co pozwala skutecznie stosować ją w uczeniu sieci metodami gradientowymi. ReLU eliminuje zjawisko zanikającego gradientu dla dodatnich wartości wejść, dzięki czemu znacząco przyspiesza uczenie głębokich modeli. Współczesne warianty, takie jak Leaky ReLU, Parametric ReLU czy ELU (Exponential Linear Unit), pozwalają dodatkowo ograniczyć problem tzw. martwych neuronów, które przestają reagować na sygnał uczący.









Porównanie funkcji i ich pochodnych	
Funkcja Heaviside $H(x)$	Pochodna $H(x)$
	
Funkcja ReLU(x)	Pochodna ReLU(x)
	
Tangens hiperboliczny $\tanh(x)$	Pochodna $\tanh(x)$
	
$\sigma(x)$	Pochodna $\sigma(x)$
	

Tabela 1. Porównanie funkcji aktywacji oraz ich pochodnych

2.2 Architektura sieci neuronowej

Architektura sieci neuronowej i zdolność reprezentacyjna

Sieć neuronowa jest modelem obliczeniowym złożonym z kolejnych warstw przetwarzających dane wejściowe w coraz bardziej użyteczne reprezentacje. Typowa architektura obejmuje warstwę wejściową, jedną lub większą liczbę warstw ukrytych oraz warstwę wyjściową. W klasycznych modelach warstwy są zazwyczaj w pełni połączone (ang. *fully connected*), co oznacza, że każdy neuron danej warstwy jest połączony z każdym neuronem warstwy następnej.

Pojedyncza warstwa sieci realizuje przekształcenie postaci

$$\mathbf{h}^{(l)} = f^{(l)} \left(\mathbf{W}^{(l)} \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)} \right), \quad (1)$$

gdzie:

- $\mathbf{h}^{(l)}$ – wektor aktywacji warstwy l ,

- $W^{(l)}$ – macierz wag warstwy l ,
- $b^{(l)}$ – wektor przesunięć (*bias*),
- $f^{(l)}(\cdot)$ – funkcja aktywacji stosowana w warstwie l .

Cała sieć może być opisana jako złożenie kolejnych transformacji:

$$f(x) = f^{(L)}\left(f^{(L-1)}\left(\dots f^{(1)}(x) \dots\right)\right), \quad (2)$$

gdzie L oznacza liczbę warstw, a x jest wektorem wejściowym.

Jednym z podstawowych parametrów opisujących architekturę sieci jest jej głębokość. Mianem *płytkiej sieci* (*shallow network*) określa się model zawierający pojedynczą warstwę ukrytą, natomiast *głębokie sieci* (*deep networks*) zawierają wiele warstw ukrytych. Zwiększenie głębokości pozwala przedstawiać złożone zależności za pomocą sekwencji prostszych przekształceń, co w praktyce często prowadzi do bardziej efektywnej reprezentacji niż w przypadku architektur płytszych.


Teoretyczne podstawy zdolności aproksymacyjnych sieci neuronowych opisuje twierdzenie o uniwersalnej aproksymacji. Zgodnie z nim sieć z jedną warstwą ukrytą i odpowiednio dużą liczbą neuronów może przybliżać dowolną funkcję ciągłą na zwartym zbiorze z dowolną zadaną dokładnością [8, 14]. Działanie takiej sieci można zapisać jako

$$f(x) = \sum_{i=1}^N \alpha_i \sigma(w_i^\top x + b_i), \quad (3)$$


gdzie $\sigma(\cdot)$ oznacza nieliniową funkcję aktywacji, natomiast α_i , w_i oraz b_i są parametrami modelu wyznaczanymi w procesie uczenia.

Choć twierdzenie to potwierdza dużą moc aproksymacyjną sieci płytkich, w praktyce uzyskanie wysokiej jakości odwzorowania może wymagać bardzo szerokiej warstwy ukrytej. Z tego względu architektury głębokie są często korzystniejsze, ponieważ umożliwiają osiągnięcie porównywalnej lub większej zdolności reprezentacyjnej przy bardziej zwartej strukturze modelu.

Płytką sieć neuronową



Głęboką sieć neuronową



Rysunek 1. Porównanie płytkiej i głębokiej sieci neuronowej z wyrównanym położeniem neuronów wyjściowych.

Badania [21, 27, 34] wykazały istnienie tzw. **hierarchii głębokości**, zgodnie z którą zwiększanie liczby warstw jest znacznie bardziej efektywne niż ich poszerzanie. Dla pewnych klas funkcji ograniczenie głębokości prowadzi do wykładniczego wzrostu liczby neuronów wymaganych do osiągnięcia tej samej jakości aproksymacji. Zależność tę można opisać asymptotycznie:

$$N_{\text{shallow}} = \mathcal{O}(2^k), \quad N_{\text{deep}} = \mathcal{O}(k^3), \quad (4)$$

gdzie k oznacza głębokość sieci. Zwiększenie głębokości modelu pozwala zatem uzyskać porównywalną zdolność aproksymacji określonych klas funkcji przy istotnie mniejszej liczbie neuronów i parametrów.

2.3 Sieci Splotowe

2.3.1 Geneza

Sieci splotowe (*Convolutional Neural Networks*, CNN) stanowią jedną z podstawowych klas modeli stosowanych w głębokim uczeniu do analizy danych o strukturze przestrzennej. Ich rozwój był inspirowany badaniami nad organizacją kory wzrokowej, w której neurony reagują na bodźce występujące w ograniczonych obszarach pola widzenia. W odróżnieniu od klasycznych sieci w pełni połączonych, CNN wykorzystują lokalne filtry przesuwane po całym wejściu, co umożliwia automatyczne wydobywanie cech przestrzennych przy znacznie mniejszej liczbie parametrów.

Kluczową własnością sieci splotowych jest współdzielenie wag, polegające na stosowaniu tych samych filtrów w różnych położeniach danych wejściowych. Pozwala to wykrywać te same wzorce niezależnie od ich położenia oraz ogranicza złożoność modelu. Dzięki temu sieci splotowe są szczególnie przydatne w zadaniach, w których istotne są lokalne zależności pomiędzy elementami danych.

W kontekście gry Blood Bowl sieci splotowe mogą pełnić rolę ekstraktora cech przestrzennych opisujących stan planszy, takich jak położenie zawodników, strefy zagrożenia, pozycja piłki czy układy taktyczne. Umożliwia to przekształcenie surowej reprezentacji stanu w bardziej użyteczne cechy przekazywane następnie do części decyzyjnej agenta. [19]

2.3.2 Sposób działania

Operacja splotu

Podstawowym elementem sieci splotowej jest warstwa splotowa. Operacja splotu polega na obliczaniu lokalnych sum ważonych pomiędzy fragmentami danych wejściowych a wagami filtra, co prowadzi do powstania mapy aktywacji uwypuklającej obecność określonych wzorców.

$$y(i) = \sum_{m \in \mathcal{M}} x(i + m) w(m) + b,$$

gdzie:

- i oznacza wektor indeksów wyjścia,
- m oznacza wektor przesunięć w obrębie jądra,
- $x(i + m)$ oznacza fragment danych wejściowych,
- $w(m)$ oznacza wagę filtra,
- b oznacza wyraz wolny,
- $y(i)$ oznacza wartość wyjściową.

Dla danych dwuwymiarowych operacja ta przyjmuje postać:

$$y(i, j) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} x(i + m, j + n) w(m, n) + b.$$

W wyniku przesuwania filtra po wejściu powstaje mapa cech (*feature map*), wskazująca miejsca, w których dany wzorec został wykryty.

Dane wielokanałowe

W praktyce dane wejściowe mają zwykle wiele kanałów. W klasycznych zadaniach wizji komputerowej kanały te odpowiadają na przykład składowym RGB obrazu, natomiast w analizie stanu gry mogą reprezentować różne cechy planszy, takie jak pozycje zawodników, położenie piłki, zajętość pól czy dodatkowe informacje taktyczne.

Jeżeli wejście opisane jest tensorem

$$X \in \mathbb{R}^{C_{in} \times H \times W},$$

to pojedyncza mapa wyjściowa obliczana jest jako suma splotów po wszystkich kanałach wejściowych:


$$Y_k(i, j) = b_k + \sum_{c=1}^{C_{in}} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} X_c(i + m, j + n) W_{k,c}(m, n),$$

gdzie k oznacza indeks filtra wyjściowego, a C_{in} liczbę kanałów wejściowych. Każdy filtr wykorzystuje zatem pełną informację zawartą we wszystkich kanałach, tworząc jedną mapę cech opisującą określony typ wzorca.

Funkcje aktywacji i normalizacja

Po wykonaniu operacji splotu wynik jest zazwyczaj przekazywany przez nieliniową funkcję aktywacji, taką jak ReLU. Dzięki temu sieć może modelować zależności nieliniowe i budować bardziej złożone reprezentacje niż modele oparte wyłącznie na przekształceniach liniowych.

W wielu architekturach pomiędzy warstwą splotową a funkcją aktywacji stosuje się również warstwy normalizacyjne, takie jak Batch Normalization lub Layer Normalization. Ich zadaniem jest stabilizacja procesu uczenia poprzez ograniczanie nadmiernych zmian rozkładu aktywacji. W praktyce typowy



Rysunek 2. Padding i Stride

blok przetwarzania może więc przyjmować postać warstwy splotowej, następnie normalizacji, a na końcu funkcji aktywacji.

Stride i padding

Istotnymi parametrami warstwy splotowej są krok przesuwania filtra (*stride*) oraz sposób uzupełniania brzegów wejścia (*padding*). Parametr *stride* określa, o ile pozycji filtr przesuwa się przy każdym kroku, natomiast *padding* pozwala kontrolować sposób przetwarzania elementów znajdujących się przy krawędziach wejścia.

Parametry te wpływają bezpośrednio na rozmiar mapy cech. Dla wejścia o wysokości H i szerokości W , filtra o rozmiarze K , kroku S oraz paddingu P , rozmiar wyjścia można zapisać jako:

$$H_{\text{out}} = \left\lfloor \frac{H + 2P - K}{S} \right\rfloor + 1, \quad W_{\text{out}} = \left\lfloor \frac{W + 2P - K}{S} \right\rfloor + 1.$$

Zwiększenie kroku przesuwania prowadzi do zmniejszenia rozdzielczości mapy cech, natomiast zastosowanie paddingu pozwala zachować większą ilość informacji brzegowej i ograniczyć szybkie zmniejszanie wymiarów reprezentacji.

Hierarchia reprezentacji

Kolejne warstwy splotowe tworzą hierarchię reprezentacji. Warstwy płytsze uczą się prostych zależności lokalnych, natomiast warstwy głębsze budują na ich podstawie bardziej złożone reprezentacje przestrzenne. W klasycznych zastosowaniach pierwsze warstwy wykrywają proste wzorce, takie jak krawędzie lub tekstury, a dalsze warstwy łączą je w coraz bardziej złożone układy.

W zastosowaniach związanych z grami planszowymi hierarchia ta może odpowiadać przejściu od prostych zależności pomiędzy sąsiednimi polami do bardziej złożonych układów pozycyjnych obejmujących większy fragment planszy. Dzięki temu sieć może kodować zarówno lokalne zagrożenia, jak i bardziej globalne zależności taktyczne.

Warstwy wspierające

W sieciach splotowych stosuje się również warstwy wspierające, które uzupełniają działanie samych operacji splotu. Warstwy *pooling* redukują rozdzielczość map cech poprzez lokalną agregację, co zmniejsza koszt obliczeniowy i zwiększa zakres zależności analizowanych przez kolejne warstwy. Warstwy normalizacyjne stabilizują proces uczenia, natomiast *dropout* ogranicza ryzyko przeuczenia przez losowe wyłączanie części aktywacji w trakcie treningu.

Dobór tych mechanizmów zależy od charakteru zadania. W problemach wymagających zachowania precyzyjnej informacji przestrzennej, takich jak analiza planszy gry, nadmierna redukcja rozdzielczości może być niekorzystna. Z tego względu warstwy wspierające powinny być dobierane z uwzględnieniem kompromisu pomiędzy efektywnością obliczeniową a dokładnością reprezentacji.

Wynik działania części splotowej jest następnie przekazywany do dalszych warstw modelu, na przykład warstw gęstych lub głów aktora i krytyka w algorytmach uczenia ze wzmocnieniem.

2.4 Techniki uczenia sieci neuronowych

Uczenie sieci neuronowych to proces, podczas którego model dopasowuje swoje parametry w taki sposób, aby minimalizować błąd predykcji. Efektywność tego procesu decyduje o zdolności modelu do generalizacji, czyli poprawnego działania na podstawie danych, których nie widział podczas treningu.

Uczenie odbywa się w sposób iteracyjny poprzez modyfikację wag modelu w kierunku przeciwnym do gradientu funkcji kosztu. Każdy cykl uczenia (epoka) obejmuje cztery główne etapy:

- Propagacja w przód (*forward pass*) – dane wejściowe przechodzą przez kolejne warstwy modelu, aż do uzyskania przewidywania $\hat{y}$.
- Obliczenie błędu (*loss*) – funkcja kosztu $(y, \hat{y})$ mierzy jakość otrzymanej predykcji.
- Propagacja wsteczna (*backpropagation*) – na podstawie reguły łańcuchowej obliczane są gradienty funkcji kosztu względem wag.
- Aktualizacja wag (*update*) – parametry są modyfikowane zgodnie z wybranym algorytmem optymalizacji, np. Stochastyczny spadek gradientu lub Adamem.

Na podstawie sposobu pozyskiwania informacji zwrotnej i dostępności danych uczących wyróżnia się trzy główne paradygmaty uczenia: uczenie nadzorowane, uczenie nienadzorowane oraz uczenie ze wzmocnieniem. [2]

Uczenie nadzorowane

Uczenie nadzorowane (ang. *supervised learning*) jest najczęściej stosowanym paradygmatem uczenia sieci neuronowych. Wymaga on zbioru danych uczących składający się z par (x, y) , gdzie x reprezentuje wektor cech opisujących przykład, a y jest przypisaną do niego etykietą lub wartością wyjściową. Celem modelu jest nauczenie się odwzorowania $f : x \rightarrow y$ w taki sposób, aby przewidywane wyjście $\hat{y}$ było jak najbardziej zbliżone do wartości rzeczywistej y [10].

W ramach uczenia nadzorowanego wyróżnia się dwa główne typy zadań:

- **Klasyfikacja** – gdy etykiety y należą do skończonego zbioru klas, a model ma za zadanie przypisać dany przykład do jednej z nich. Przykłady zastosowań obejmują rozpoznawanie obrazów, klasyfikację dokumentów tekstowych czy diagnozowanie chorób na podstawie danych medycznych.
- **Regresja** – gdy etykieta y ma charakter ciągły lub liczbowy, a zadaniem modelu jest oszacowanie jej wartości na podstawie dostępnych danych wejściowych. Przykładami takich zadań są prognozowanie cen, przewidywanie popytu oraz estymacja parametrów fizycznych w eksperymentach naukowych.

Dzięki swojej uniwersalności, uczenie nadzorowane jest stosowane w szerokim zakresie dziedzin, od rozpoznawania mowy i analizy obrazu, przez systemy rekomendacyjne, aż po prognozy finansowe i modelowanie procesów przemysłowych.

Uczenie nienadzorowane

Uczenie nienadzorowane (ang. *unsupervised learning*) obejmuje metody, w których model uczy się wyłącznie na podstawie danych wejściowych x , bez dostępu do odpowiadających im etykiet wynikowych. Celem jest odkrycie wewnętrznej struktury danych, zależności pomiędzy przykładami lub reprezentacji pozwalających na ich bardziej efektywne opisanie [10].

W ramach uczenia nienadzorowanego wyróżnić można kilka głównych typów zadań:

- **Grupowanie (*clustering*)** – podział zbioru danych na zbiory w taki sposób, aby przykłady w tym samym zbiorze były do siebie możliwie podobne, a między nimi różnice jak najbardziej wyraźne. Przykładami takich algorytmów są *k-means*, DBSCAN (ang. *Density-Based Spatial Clustering of Applications with Noise*) czy sieci Kohonena (SOM) [18].
- **Redukcja wymiarów** – przekształcenie danych do przestrzeni o mniejszej liczbie wymiarów przy zachowaniu jak największej ilości informacji. Popularne metody to analiza głównych składowych (PCA) czy autoenkodery.
- **Uczenie reprezentacji** – poszukiwanie wewnętrznych opisów danych (tzw. reprezentacji ukrytych), które mogą ułatwić dalsze zadania, np. klasyfikację lub generowanie nowych przykładów. Przykładem są modele generatywne, takie jak *Variational Autoencoder* (VAE) czy *Generative Adversarial Networks* (GAN) [11].

Uczenie nienadzorowane znajduje zastosowanie m.in. w segmentacji obrazów, eksploracji danych, kompresji informacji, wyszukiwaniu podobnych obiektów, detekcji anomalii czy jako etap wstępny w uczeniu nadzorowanym (tzw. *pretraining*).

Uczenie ze wzmocnieniem

Uczenie ze wzmocnieniem (ang. *reinforcement learning*, RL) to proces, w którym agent uczy się poprzez interakcję ze środowiskiem. W każdym kroku czasowym t agent obserwuje stan s_t , wybiera akcję a_t , otrzymuje nagrodę r_t i przechodzi do kolejnego stanu s_{t+1} . Celem jest maksymalizacja zdyskontowanej sumy nagród:

$$R_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$$

gdzie $\gamma \in (0, 1)$ to współczynnik dyskontowania, który określa znaczenie przyszłych nagród. Uczenie ze wzmocnieniem znajduje zastosowanie w problemach decyzyjnych – w tym w robotyce, sterowaniu i grach strategicznych, takich jak Blood Bowl, Go czy StarCraft, gdzie sieci neuronowe pełnią rolę polityki decyzyjnej (ang. *policy network*).

2.5 Funkcje straty w uczeniu ze wzmocnieniem

Funkcja straty (ang. *loss function*) pełni istotną rolę również w uczeniu ze wzmocnieniem, jednak jej znaczenie różni się od roli, jaką pełni w klasycznych zadaniach uczenia nadzorowanego. W przypadku uczenia nadzorowanego funkcja straty opisuje bezpośrednią rozbieżność pomiędzy przewidywaniem modelu $\hat{y}$ a znaną wartością docelową y . Natomiast w uczeniu ze wzmocnieniem model nie dysponuje jednoznacznymi etykietami poprawnych odpowiedzi dla poszczególnych przykładów. Zamiast tego agent uczy się na podstawie sygnału nagrody otrzymywanego ze środowiska, którego wpływ może ujawniać się dopiero po wielu kolejnych decyzjach. [33]

W konsekwencji funkcja straty w uczeniu ze wzmocnieniem nie służy wyłącznie do minimalizacji błędu predykcji względem z góry zadanej odpowiedzi, lecz do takiej modyfikacji parametrów modelu, aby zwiększać oczekiwaną skumulowaną nagrodę. Wartości docelowe wykorzystywane podczas optymalizacji są najczęściej estymowane na podstawie obserwowanych przejść, uzyskanych nagród oraz przewidywań samego modelu.

Na podstawie funkcji straty algorytm optymalizacji wyznacza gradienty, które informują, w jaki sposób należy modyfikować parametry sieci, aby poprawić jakość podejmowanych decyzji, trafność estymacji wartości stanów lub działań oraz skuteczność całej polityki działania. Proces ten prowadzi do iteracyjnego dostosowywania parametrów modelu w kierunku maksymalizacji oczekiwanego zwrotu, przy czym w praktyce często realizuje się to poprzez minimalizację odpowiednio zdefiniowanej funkcji straty.

W praktyce można wyróżnić kilka głównych grup funkcji straty stosowanych w uczeniu ze wzmocnieniem:

- **Funkcje straty dla metod opartych na funkcji wartości** – stosowane, gdy model estymuje wartość stanu $V(s)$ lub wartość akcji $Q(s, a)$:
 - *Mean Squared Error (MSE)* – używana do minimalizacji różnicy pomiędzy przewidywaną wartością a wartością docelową wyznaczoną na podstawie nagrody i bootstrappingu.
 - *Huber loss* – często stosowana jako bardziej odporna alternatywa dla MSE, ograniczająca wpływ dużych błędów estymacji.
- **Funkcje straty dla metod gradientu polityki** – stosowane, gdy model bezpośrednio optymalizuje politykę wyboru działań:
 - strata polityki oparta na logarytmie prawdopodobieństwa wybranego działania, ważona estymowanym zwrotem lub przewagą (*advantage*),
 - funkcje celu z mechanizmami ograniczającymi zbyt duże zmiany polityki, jak w metodzie PPO.

Dobór funkcji straty w uczeniu ze wzmocnieniem powinien uwzględniać kilka istotnych czynników:

- **Rodzaj stosowanego algorytmu** – inna postać funkcji straty jest wykorzystywana w metodach opartych na funkcji wartości, inna w metodach gradientu polityki, a jeszcze inna w podejściach actor-critic.
- **Sposób wyznaczania celu optymalizacji** – w uczeniu ze wzmocnieniem wartości docelowe są zwykle estymowane, a nie znane z góry, co wpływa na stabilność uczenia i jakość uzyskiwanych gradientów.
- **Wariancję i szum sygnału uczącego** – sygnał nagrody może być rzadki, opóźniony i obciążony dużą losowością, dlatego funkcja straty powinna sprzyjać stabilnemu uczeniu mimo niepewności estymowanych celów.
- **Równowagę pomiędzy eksploracją a eksploatacją** – w wielu metodach do funkcji straty dodawany jest składnik entropijny, który zachęca agenta do dalszego badania przestrzeni możliwych działań.
- **Stabilność optymalizacji** – ze względu na niestacjonarny charakter danych treningowych oraz zależność kolejnych obserwacji od aktualnej polityki, szczególne znaczenie ma ograniczanie zbyt gwałtownych aktualizacji parametrów.

Ostateczny dobór funkcji straty ma istotny wpływ na stabilność procesu uczenia, szybkość konwergencji oraz końcową skuteczność agenta. W przeciwieństwie do klasycznych zadań nadzorowanych funkcja straty w uczeniu ze wzmocnieniem ma charakter bardziej pośredni, ponieważ nie odnosi się do jawnie zadanej poprawnej odpowiedzi, lecz do estymowanego wpływu działań na przyszłą sumę nagród.

2.6 Algorytmy optymalizacji

Kluczowym elementem procesu uczenia są Algorytmy optymalizacji. Odpowiadają one za aktualizację parametrów modelu w celu minimalizacji wartości funkcji straty. W praktyce optymalizacja odbywa się iteracyjnie, a parametry modelu są aktualizowane zgodnie z kierunkiem przeciwnym do gradientu

funkcji kosztu względem wag. [10]

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t)$$

gdzie η oznacza współczynnik uczenia (learning rate). Zbyt duża wartość η może powodować niestabilność uczenia, a zbyt mała – spowolnienie konwergencji. Dlatego opracowano szereg metod adaptacyjnych i usprawnień klasycznego spadku gradientu.

Metoda najszybszego spadku

Podstawowy algorytm optymalizacji, stosowany zarówno w wersji pełnej (batch gradient descent), jak i stochastycznej (stochastic gradient descent, SGD). W przypadku danych dzielonych na partie (mini-batches), aktualizacja parametrów przyjmuje postać:

$$\theta_{t+1} = \theta_t - \eta \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} L_i(\theta_t)$$

gdzie m to liczba próbek w partii danych.

W praktyce metoda spadku gradientu występuje w trzech głównych wariantach, różniących się sposobem obliczania gradientu. W pełnym spadku gradientu (batch gradient descent) gradient wyznacza się na podstawie całego zbioru treningowego, co daje dokładny kierunek spadku, ale jest obliczeniowo kosztowne i mało praktyczne przy dużych danych. W przeciwieństwie do tego, stochastyczny spadek gradientu (stochastic gradient descent, SGD) aktualizuje wagi po każdej próbce danych, co znacząco przyspiesza uczenie i umożliwia ucieczkę z minimów lokalnych, jednak wprowadza losowe oscylacje w kierunku gradientu. Kompromisem pomiędzy tymi podejściami jest mini-batch gradient descent, który wykorzystuje niewielkie partie danych (zazwyczaj od kilkunastu do kilkuset przykładów). Takie podejście poprawia stabilność uczenia i umożliwia efektywne wykorzystanie równoległości obliczeń, np. na procesorach GPU.

Choć klasyczna metoda spadku gradientu jest intuicyjna i prosta w implementacji, ma istotne ograniczenia. Jest bardzo wrażliwa na dobór współczynnika uczenia i może łatwo utknąć w minimach lokalnych lub punktach siodłowych. Ponadto w obszarach o silnie nachylonych dolinach funkcji kosztu często występują oscylacje, które spowalniają konwergencję

Spadek gradientu z momentem (Momentum)

Metoda *momentum* to usprawnienie klasycznego spadku gradientu, które wprowadza do aktualizacji wag składnik bezwładności (momentum) odpowiednio skalowany przez parametr γ . Pozwala to na użycie większego współczynnika uczenia. Tempo konwergencji znacząco wzrasta, w szczególności w trudnych obszarach funkcji kosztu z dużą ilością minimów lokalnych.

$$\begin{aligned}1 &= \gamma + \eta \\ \mathbf{v}_t &= \gamma \mathbf{v}_{t-1} + \eta \nabla_{\theta} L(\theta_t), \\ \theta_{t+1} &= \theta_t - \mathbf{v}_t.\end{aligned}$$

- θ_t — wektor parametrów modelu w kroku t .
- θ_{t+1} — wektor parametrów modelu po wykonaniu aktualizacji.
- $L(\theta_t)$ — wartość funkcji straty dla parametrów θ_t .
- $\nabla_{\theta} L(\theta_t)$ — gradient funkcji straty względem parametrów modelu, obliczony w punkcie θ_t .
- $\mathbf{v}_t$ — wektor aktualizacji w kroku t , uwzględniający zarówno bieżący gradient, jak i wpływ poprzednich aktualizacji.
- $\mathbf{v}_{t-1}$ — wektor aktualizacji z poprzedniego kroku.
- η — współczynnik uczenia (*learning rate*), określający wielkość kroku aktualizacji.
- $\gamma \in [0, 1]$ — współczynnik momentu (*momentum coefficient*), określający stopień zachowania informacji o poprzednich aktualizacjach.
- t — numer iteracji procesu optymalizacji.

Efektem jest filtr wygładzający historię gradientów, co przyspiesza konwergencję i redukuje oscylacje, a także ułatwia przeciskanie przez lokalne minima.

Metoda przyspieszonego gradientu

Metoda przyspieszonego gradientu, nazywana metodą Nestorova od nazwiska autora, jest dalszym usprawnieniem metody z momentem, w którym gradient jest obliczany nie w bieżącym położeniu parametrów, a w przewidywanym „przyszłym” położeniu modelu. Dzięki temu aktualizacja jest bardziej precyzyjna i stabilna, co pozwala uniknąć nadmiernego przeskoczenia minimum [24]

$$\begin{aligned}\mathbf{v}_t &= \gamma \mathbf{v}_{t-1} + \eta \nabla_{\theta} L(\theta_t - \gamma \mathbf{v}_{t-1}), \\ \theta_{t+1} &= \theta_t - \mathbf{v}_t.\end{aligned}$$

W praktyce metoda Nesterova jest bardziej stabilna od klasycznego momentu i często prowadzi do szybszej konwergencji, zwłaszcza w sieciach głębokich

RMSProp (Root Mean Square Propagation)

RMSProp to metoda optymalizacji z adaptacyjnymi współczynnikami uczenia. Jest ona modyfikacją optymalizatora AdaGrad (Adaptive Gradient). Algorytmy tego typu dostosowują tempo uczenia dla każdego parametru indywidualnie. [13].

Aktualizacje w RMSProp zapisuje się jako:

$$\begin{aligned}V_t &= \beta V_{t-1} + (1 - \beta) (\nabla_{\theta} L(\theta_t))^2, \\ \theta_{t+1} &= \theta_t - \frac{\eta}{\sqrt{V_t + \epsilon}} \nabla_{\theta} L(\theta_t),\end{aligned}$$

gdzie:

- β (typowo ok. 0.9) — współczynnik wygładzania,
- ϵ — mała stała dla stabilności numerycznej i uniknięcia dzielenia przez zero
- η — współczynnik uczenia.

Dzięki temu zwiększamy tempo nauki parametrów, których gradient jest mały oraz zwalniamy proces nauki parametrów z porównywalnie stromym gradientem. Chroni to sieć przed pominięciem optimum w regionie o stromym gradiencie oraz przyspiesza proces nauki w przeciwnym przypadku.

Zalety RMSProp:

- Utrzymuje adaptacyjny krok uczenia bez jego nadmiernej redukcji,
- Poprawia zbieżność w problemach o zmiennych gradientach — często stosowany w sieciach rekurencyjnych.

Wady:

- Wymaga starannego doboru hiperparametrów,
- Może być mniej skuteczny w przypadku ekstremalnie rzadkich gradientów — wtedy lepszy jest Adam.

Adam (Adaptive Moment Estimation)

Adam stara się łączyć zalety optymalizatorów momentum i RMSProp. Uwzględnia kierunek zmian gradientu i wygładza aktualizacje tak jak momentum oraz adaptacyjnie skaluje krok uczenia względem wariancji gradientów jak RMSProp. Z tego powodu jest on obecnie, wraz z wariantami, najpopularniejszym optymalizatorem sieci neuronowych.

W Adamie dla każdego parametru θ śledzi się dwa momenty:

Pierwszy moment, średnia gradientów

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

Drugi moment, średnia kwadratów gradientów

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

Ze względu na początkowe wartości zerowe m_t oraz v_t wprowadza się poprawki biasu. Dzięki nim na początku uczenie nie jest spowolnione.

$$\begin{aligned} m_t &= \beta_1 m_{t-1} + (1 - \beta_1) g_t, \\ v_t &= \beta_2 v_{t-1} + (1 - \beta_2) g_t^2, \\ \hat{m}_t &= \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \end{aligned}$$

Finalna aktualizacja wag ma postać

$$\theta_{t+1} = \theta_t - \frac{\eta \hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon},$$

gdzie $g_t = \nabla_{\theta} L(\theta_t)$, β_1 , β_2 są współczynnikami wygładzania (np. 0.9 i 0.999), a ϵ to mała wartość stabilizująca.

Zalety:

- Adaptacyjny krok dla każdego parametru,
- Efektywny obliczeniowo i pamięciowo,
- Działa dobrze przy danych z szumem, gradientach niestabilnych.

Wady:

- Możliwe problemy ze zbieżnością w funkcjach wypukłych,
- Czasem gorsza generalizacja niż klasyczne SGD z momentum,
- Wymaga dostrojenia wielu hiperparametrów.

[17]

2.7 Problemy gradientowe

Wraz ze wzrostem głębokości sieci neuronowych proces uczenia staje się coraz bardziej podatny na problemy związane z propagacją błędu i stabilnością optymalizacji. Kluczowym czynnikiem wpływającym na skuteczność uczenia jest sposób, w jaki gradienty funkcji kosztu rozchodzą się przez kolejne warstwy modelu. Jeżeli wartości te zanikają lub eksplodują, uczenie głębokiej sieci staje się nieefektywne lub wręcz niemożliwe. Poniżej przedstawiono najważniejsze zjawiska i techniki ich łagodzenia

Nasycenie

Zjawisko nasycenia występuje, gdy dla dużych wartości wejścia funkcja aktywacji osiąga swoje asymptotyczne maksimum lub minimum, a jej pochodna staje się bliska zero. W takich warstwach gradient błędu praktycznie nie przepływa dalej, co prowadzi do spowolnienia lub całkowitego zatrzymania procesu uczenia.

Typowym przykładem są funkcje sigmoidalne i tangens hiperboliczny, które dla dużych wartości $|x|$ przestają reagować na zmiany sygnału wejściowego. Wprowadzenie funkcji ReLU i jej wariantów rozwiązało ten problem dla dodatnich wartości argumentu, choć nadal może prowadzić do tzw. martwych neuronów – przypadków, w których gradient po stronie ujemnej jest stale równy zero.

Dodatkowe techniki, takie jak Leaky ReLU czy ELU, wprowadzają niewielkie nachylenie w obszarze ujemnym, co pozwala zachować przepływ gradientu i utrzymać aktywność neuronów w całej sieci.

Skośność rozkładu aktywacji

Kolejnym problemem, często pomijanym, jest skośność rozkładu aktywacji (ang. bias shift). Występuje on, gdy funkcje aktywacji generują wyłącznie dodatnie wartości, jak w przypadku sigmoidy, której zakres wynosi $(0, 1)$. W takiej sytuacji średnia wartość aktywacji jest dodatnia, co powoduje

przesunięcie rozkładu wejść kolejnych warstw w kierunku dodatnich wartości. W efekcie sieć pracuje w obszarze nasycenia funkcji aktywacji, a gradienty stopniowo zanikają.

Skośność rozkładu aktywacji utrudnia także utrzymanie stabilnego przepływu sygnału i powoduje, że wagi w kolejnych warstwach są zmuszane do kompensowania przesunięć statystycznych. Rozwiązaniem tego problemu jest stosowanie funkcji aktywacji o zakresie symetrycznym względem zera, takich jak $\tanh(x)$, lub metod normalizacji danych, które utrzymują średnią aktywacji blisko zera (np. Batch Normalization).

Zanikanie gradientu

Zjawisko zanikającego gradientu polega na tym, że wartości gradientów w trakcie propagacji wstecznej stają się coraz mniejsze w miarę przechodzenia przez kolejne warstwy. W konsekwencji wcześniejsze warstwy sieci uczą się bardzo wolno, podczas gdy końcowe – położone bliżej wyjścia – aktualizują swoje wagi znacznie szybciej. Problem ten wynika głównie z własności funkcji aktywacji, takich jak sigmoida lub tangens hiperboliczny, których pochodne przyjmują wartości bliskie zeru dla dużych wartości argumentu. Dla przykładu, w przypadku tangensa hiperbolicznego:

$$\tanh'(x) = 1 - \tanh^2(x)$$

co oznacza, że dla $|x| > 3$ pochodna staje się praktycznie zerowa. Jeżeli gradient pochodnej jest mniejszy niż jeden, a sieć zawiera wiele warstw, iloczyn kolejnych pochodnych szybko dąży do zera, przez co sygnał błędu praktycznie nie dociera do wcześniejszych warstw.

Aby przeciwdziałać zanikaniu gradientu, wprowadza się funkcje aktywacji, które nie nasycają się dla dodatnich wartości argumentu, takie jak ReLU i jej warianty (LeakyReLU, Parametric ReLU (PReLU), ELU). Dodatkowo stosuje się odpowiednie metody inicjalizacji wag (np. He lub Xavier) oraz techniki normalizacji, które utrzymują rozkład aktywacji w kontrolowanym zakresie. [9]

Eksplodujący gradient

Przeciwstawnym zjawiskiem jest eksplodujący gradient, który występuje wtedy, gdy wartości gradientów w trakcie propagacji wstecznej stają się coraz większe, często osiągając wartości prowadzące do niestabilności numerycznej. W takim przypadku wagi sieci zaczynają przyjmować bardzo duże wartości, co skutkuje rozbieżnością funkcji kosztu i przerwaniem procesu uczenia. Problem ten występuje szczególnie często w głębokich sieciach rekurencyjnych oraz w modelach o źle dobranych współczynnikach uczenia.

Jednym z najczęściej stosowanych sposobów zapobiegania eksplozji gradientów jest ograniczanie ich normy (ang. gradient clipping), które polega na skalowaniu wektora gradientu, jeśli jego długość przekracza ustalony próg τ :

$$g \leftarrow \frac{g}{\max\left(1, \frac{\|g\|}{\tau}\right)}$$

gdzie:

- g — wektor gradientu
- $\|g\|$ - jego norma (najczęściej euklidesowa, czyli 2)
- τ - ustalony próg (np. 1.0)

Dzięki temu uczenie pozostaje stabilne nawet w sytuacjach, gdy lokalny gradient przyjmuje bardzo duże wartości. Innym sposobem łagodzenia tego problemu jest obniżenie współczynnika uczenia lub zastosowanie metod optymalizacji adaptacyjnej, takich jak RMSProp czy Adam, które automatycznie dopasowują krok optymalizacji dla każdego parametru.

2.8 Techniki stabilizacji i usprawnienia procesu uczenia

Występowanie problemów takich jak zanikający gradient, eksplodujący gradient czy nasycenie funkcji aktywacji powoduje, że odpowiednie metody stabilizacji są niezbędne do osiągnięcia zbieżności. Współczesne sieci wykorzystują szereg technik, które poprawiają przepływ gradientu, ograniczają przeuczenie oraz przyspieszają proces optymalizacji. Do najczęściej stosowanych należą: Batch Normalization, Dropout oraz Learning Rate Scheduling.

Batch Normalization

Jedną z najważniejszych metod poprawiających stabilność uczenia jest Batch Normalization, zaproponowana przez Ioffe i Szegedy'ego w 2015 roku. Jej głównym celem jest utrzymanie stabilnego rozkładu aktywacji w kolejnych warstwach poprzez normalizację danych wejściowych do każdej z nich. W praktyce polega to na przeskalowaniu i przesunięciu aktywacji w taki sposób, aby ich średnia i wariancja w obrębie mini-batcha pozostawały w ustalonych granicach.

Dla danej partii danych oblicza się średnią i odchylenie standardowe:

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i, \quad \sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$$

a następnie normalizuje się wejście:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}},$$

gdzie ϵ to mała stała zapobiegająca dzieleniu przez zero. Taka normalizacja sprawia, że aktywacje w każdej warstwie mają średnią równą zero i wariancję równą jeden, co stabilizuje propagację gradientów wstecz i zapobiega zarówno ich zanikaniu, jak i eksplozji.

Jednakże, całkowite znormalizowanie aktywacji mogłoby ograniczyć zdolność sieci do reprezentacji nieliniowych przekształceń. Dlatego w Batch Normalization wprowadza się dodatkowe parametry skalujące i przesuwające, oznaczane odpowiednio jako γ (skala) i β (przesunięcie). Ostateczna postać wyjścia warstwy po normalizacji to:

$$y_i = \gamma \hat{x}_i + \beta$$

Batch Normalization redukuje wpływ zjawiska internal covariate shift – zmiany rozkładu aktywacji w trakcie uczenia, stabilizując tym samym propagację gradientu i umożliwiając stosowanie wyższego współczynnika uczenia. W praktyce BN znacząco przyspiesza trening i często poprawia dokładność końcową modelu.

[15]

Dropout

Drugą powszechnie stosowaną metodą stabilizacji jest Dropout, zaproponowany przez Srivastavę i wsp. w 2014 roku. Technika ta ma na celu ograniczenie zjawiska przeuczenia (ang. overfitting) poprzez losowe wyłączanie części neuronów w trakcie uczenia. W każdej iteracji treningu każdy neuron z prawdopodobieństwem p zostaje „wyłączony” (tj. jego wyjście zostaje ustawione na zero), co można formalnie zapisać jako:

$$\tilde{h}^{(l)} = h^{(l)} \odot r^{(l)}, \quad r^{(l)} \sim \text{Bernoulli}(p)$$

gdzie $\odot$ oznacza mnożenie element po elemencie, a w fazie testowej aktywacje są odpowiednio skalowane:

$$h_{\text{test}}^{(l)} = p h_{\text{train}}^{(l)}$$

aby zachować oczekiwaną wartość wyjść. Dropout można interpretować jako rodzaj losowego „ensemble learning” — w każdej iteracji trenowany jest inny podzbiór sieci, a końcowy model działa jak uśrednienie wielu słabszych klasyfikatorów. W efekcie sieć staje się bardziej odporna na szum w danych i lepiej generalizuje na zbiorze testowym [31].

Pooling

W sieciach splotowych często stosuje się również operację *poolingu*, której celem jest redukcja rozdzielczości map cech przy zachowaniu najważniejszych informacji o lokalnie wykrytych wzorcach. Mechanizm ten polega na agregacji wartości aktywacji w niewielkich obszarach wejścia, co prowadzi do zmniejszenia wymiaru reprezentacji oraz ograniczenia kosztu obliczeniowego kolejnych warstw.

Najczęściej wykorzystywaną odmianą jest *max pooling*, w której z każdego lokalnego obszaru wybierana jest wartość maksymalna. Dla okna o rozmiarze $K \times K$ operację tę można zapisać w postaci:

$$y(i,j) = \max_{\substack{0 \leq m < K \\ 0 \leq n < K}} x(i \cdot S + m, j \cdot S + n),$$

gdzie S oznacza krok przesuwania okna, natomiast x i y są odpowiednio mapą wejściową i wyjściową. Alternatywę stanowi *average pooling*, w którym zamiast maksimum obliczana jest średnia wartość aktywacji w danym obszarze:

$$y(i,j) = \frac{1}{K^2} \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} x(i \cdot S + m, j \cdot S + n).$$

Zastosowanie poolingu zmniejsza czułość modelu na niewielkie przesunięcia i lokalne zakłócenia danych wejściowych, a także pozwala zwiększyć efektywny zakres zależności analizowanych przez kolejne warstwy. Jednocześnie nadmierna redukcja rozdzielczości może prowadzić do utraty precyzyjnej informacji przestrzennej, dlatego w zadaniach wymagających dokładnej lokalizacji obiektów lub relacji przestrzennych pooling stosuje się ostrożnie albo zastępuje innymi mechanizmami redukcji wymiaru.

Learning Rate Scheduling

Proces uczenia sieci neuronowych jest w dużej mierze zależny od wartości współczynnika uczenia η . Stała wartość tego parametru może być nieoptymalna w różnych fazach treningu — zbyt duży krok w pobliżu minimum może powodować oscylacje, a zbyt mały na początku wydłuża proces konwergencji. Z tego powodu stosuje się Learning Rate Scheduling, czyli adaptacyjne strategie zmiany tempa uczenia w czasie.

Najprostszym podejściem jest harmonogram malejący wykładniczo:

$$\eta_t = \eta_0 e^{-kt}$$

gdzie η_0 to początkowy współczynnik uczenia, t — numer epoki, a k — stała określająca szybkość spadku. Popularne są również strategie krokowe (ang. *step decay*), w których współczynnik uczenia jest zmniejszany skokowo po określonej liczbie epok, oraz metody adaptacyjne, które dostosowują tempo uczenia dynamicznie w zależności od wartości błędu walidacyjnego (*ReduceLROnPlateau*).

Rozdział 3

Zestawienie użytych rozwiązań

W niniejszym rozdziale przedstawiono zestawienie rozwiązań wykorzystanych w badaniach eksperymentalnych przeprowadzonych w ramach tej pracy. Celem rozdziału jest jednoznaczne zdefiniowanie architektur sieci neuronowych oraz technik uczenia zastosowanych w agentach uczących się gry Blood Bowl z wykorzystaniem metod uczenia ze wzmocnieniem.


Analizie poddano agentów opartych na algorytmach Advantage Actor–Critic(A2C) oraz Proximal Policy Optimization(PPO), które stanowią podstawę zastosowanych metod uczenia we wszystkich rozważanych wariantach. W celu zapewnienia porównywalności wyników algorytmu uczenia, sposób reprezentacji stanu oraz mechanizmy interakcji ze środowiskiem zostały w maksymalnym stopniu ujednolicone. Zmienną badawczą pozostają zastosowane algorytmy oraz architektury sieci neuronowych.

W kolejnych podrozdziałach opisano strukturę badanych agentów, sposób reprezentacji danych wejściowych, a następnie szczegółowo omówiono zastosowane architektury konwolucyjne, w tym warianty oparte na blokach ResNet, Inception oraz ich kombinacjach. Rozdział obejmuje również opis technik stabilizacji i usprawnień procesu uczenia, które okazały się istotne w kontekście złożonego środowiska decyzyjnego gry Blood Bowl.

3.1 Algorytmy aktor–krytyk

Algorytmy typu aktor–krytyk (ang. *actor–critic*) stanowią klasę metod uczenia ze wzmocnieniem, w których agent uczy się jednocześnie polityki decyzyjnej oraz funkcji wartości. Podejście to łączy zalety metod opartych bezpośrednio na polityce z metodami wykorzystującymi estymację jakości stanów, dzięki czemu umożliwia bardziej stabilne i efektywne uczenie w środowiskach o dużej przestrzeni stanów i akcji, takich jak gra Blood Bowl.

Do tej klasy należą między innymi algorytmy A2C oraz PPO, wykorzystane w niniejszej pracy. Oba podejścia są metodami *on-policy*, co oznacza, że aktualizacja parametrów polityki odbywa się na podstawie trajektorii wygenerowanych przez bieżącą wersję tej polityki. Innymi słowy, agent uczy się bezpośrednio na danych pochodzących z własnej, aktualnie stosowanej strategii działania.



Rysunek 3. Schemat sieci actor-critic

Podjęcie *on-policy* ma istotne konsekwencje praktyczne. Po każdej aktualizacji parametrów polityki wcześniej zebrane trajektorie przestają w pełni odpowiadać nowemu rozkładowi decyzji, dlatego nie mogą być wykorzystywane w dowolny sposób przez wiele kolejnych iteracji uczenia. Ogranicza to efektywność wykorzystania próbek, ale jednocześnie zwiększa spójność między zachowaniem agenta a optymalizowaną funkcją celu, co sprzyja stabilności uczenia w złożonych, dynamicznych środowiskach decyzyjnych [23, 33].

Architektura aktor–krytyk (*Actor–Critic*)

W architekturze aktor–krytyk model składa się z dwóch współpracujących komponentów: aktora oraz krytyka. Aktor odpowiada za wybór akcji na podstawie aktualnego stanu środowiska, natomiast krytyk ocenia jakość danego stanu z punktu widzenia oczekiwanych przyszłych nagród.

Aktor reprezentuje politykę decyzyjną agenta, opisaną rozkładem prawdopodobieństwa

$$\pi_{\theta}(a | s),$$

gdzie s oznacza stan środowiska, a – akcję, a θ – parametry polityki. W przypadku dyskretnej przestrzeni akcji wyjściem aktora jest wektor prawdopodobieństw, na podstawie którego wybierana lub próbkowana jest akcja wykonywana przez agenta.

Krytyk aproksymuje funkcję wartości stanu, czyli oczekiwaną zdyskontowaną sumę przyszłych nagród przy założeniu, że agent będzie postępował zgodnie z bieżącą polityką:

$$V_{\phi}(s) \approx V^{\pi_{\theta}}(s) = \mathbb{E}_{\pi_{\theta}} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s \right],$$

gdzie r_{t+k} oznacza nagrodę otrzymaną w kroku $t+k$, $\gamma \in (0, 1)$ jest współczynnikiem dyskontowania, a ϕ oznacza parametry krytyka. W praktycznych implementacjach aktor i krytyk często współdzielą część warstw sieci odpowiedzialnych za ekstrakcję cech, a następnie rozdzielają się na dwie odrębne głowy wyjściowe.

Zastosowanie krytyka pozwala ograniczyć wariancję estymacji gradientu polityki w porównaniu z metodami czysto politycznymi, takimi jak REINFORCE (ang. *REward Increment = Nonnegative Factor $\times$ Offset Reinforcement $\times$ Characteristic Eligibility*). Krytyk dostarcza bowiem dodatkowego sygnału uczącego, który informuje aktora, czy wynik uzyskany po wykonaniu danej akcji był lepszy, czy gorszy od oczekiwań. Dzięki temu aktualizacje polityki są bardziej stabilne i skuteczniejsze, co ma szczególne znaczenie w środowiskach o wysokiej złożoności decyzyjnej [23].

Funkcja przewagi (*Advantage Function*)

W algorytmach typu aktor–krytyk aktualizacja parametrów polityki opiera się nie na samej sumie nagród, lecz na funkcji przewagi (ang. *advantage function*). Jej zadaniem jest określenie, na ile dana akcja była lepsza lub gorsza od przeciętnego zachowania polityki w danym stanie.

Formalnie funkcja przewagi definiowana jest jako różnica pomiędzy wartością funkcji akcji a wartością stanu:

$$A(s, a) = Q(s, a) - V(s),$$

gdzie $Q(s, a)$ oznacza wartość wykonania akcji a w stanie s , a $V(s)$ jest wartością stanu. Interpretacyjnie $A(s, a) > 0$ oznacza, że akcja a była lepsza od średniej oczekiwanej w stanie s , natomiast $A(s, a) < 0$ wskazuje, że była gorsza.

W praktycznych algorytmach $Q(s, a)$ nie jest obliczane jawnie, ponieważ jego estymacja jest kosztowna i obciążona dużą wariancją. Zamiast tego funkcja przewagi jest aproksymowana na podstawie obserwowanych nagród oraz estymaty krytyka. Typowym przybliżeniem jest n -krokowy zwrot:

$$A_t \approx R_t^{(n)} - V(s_t),$$

gdzie $R_t^{(n)}$ oznacza zdyskontowaną sumę n kolejnych nagród z oszacowaniem wartości stanu końcowego przez krytyka. Bardziej zaawansowanym podejściem jest uogólniona estymacja przewagi (GAE), która wykorzystuje ważoną sumę błędów TD (ang. *Temporal Difference error*) z wielu kroków czasowych.

Zastosowanie funkcji przewagi pełni rolę tzw. *baseline* i prowadzi do istotnego zmniejszenia wariancji estymatora gradientu. W rezultacie polityka uczona jest nie na podstawie surowych nagród, lecz informacji o tym, czy dana decyzja była lepsza czy gorsza od oczekiwań w danym stanie. Mechanizm ten stanowi kluczowy element stabilności i efektywności algorytmów A2C oraz PPO. [23, 29, 32].

Błąd różnicy czasowej

Kluczowym pojęciem w algorytmach aktor–krytyk jest błąd TD, który stanowi lokalną miarę niedokładności estymacji funkcji wartości przez krytyka. Błąd TD łączy w sobie idee metod Monte Carlo oraz dynamicznego programowania, umożliwiając aktualizację wartości stanu na podstawie pojedynczego kroku interakcji ze środowiskiem.

Dla pojedynczego kroku czasowego błąd TD ma postać:

$$\delta_t = r_t + \gamma V_{\theta}(s_{t+1}) - V_{\theta}(s_t),$$

- s_t — stan środowiska w chwili t ,
- a_t — akcja wykonana w stanie s_t ,
- r_t — nagroda otrzymana po wykonaniu akcji a_t ,
- s_{t+1} — stan osiągnięty po przejściu środowiska,
- $V_{\theta}(s_t)$ — estymowana przez krytyka wartość stanu s_t ,
- $\gamma \in [0, 1]$ — współczynnik dyskontowania,
- δ_t — błąd różnicy czasowej.

Wartość δ_t informuje, czy rzeczywisty rezultat przejścia był lepszy czy gorszy od przewidywania krytyka. Jeżeli $\delta_t > 0$, to uzyskany wynik okazał się korzystniejszy od oczekiwanego, natomiast gdy $\delta_t < 0$, przejście było gorsze niż wskazywała bieżąca estymacja funkcji wartości.

W praktyce błąd TD pełni w metodach aktor–krytyk dwie podstawowe funkcje. Po pierwsze, stanowi sygnał uczący dla krytyka, którego parametry są aktualizowane tak, aby zmniejszać różnicę pomiędzy przewidywaną wartością stanu a wartością docelową. Po drugie, może służyć jako najprostsze przybliżenie funkcji przewagi:

$$A_t \approx \delta_t.$$

Takie przybliżenie jest szczególnie naturalne w jednoscokowych metodach aktor–krytyk [33].

3.2 Advantage Actor-Critic (A2C)

A2C, a A3C

Różnica pomiędzy A2C i A3C dotyczy przede wszystkim sposobu równoległego zbierania doświadczeń i aktualizacji parametrów sieci. W A3C (*Asynchronous Advantage Actor–Critic*) wiele niezależnych procesów (aktorów-uczących) równolegle oddziałuje ze środowiskiem i wyznacza gradienty, które są następnie stosowane do wspólnego modelu w sposób asynchroniczny (bez globalnej synchronizacji kroków), co prowadzi do mniej skorelowanych próbek i może stabilizować uczenie [23]. Z kolei A2C (*Advantage Actor–Critic*) stanowi wariant synchroniczny tego podejścia: próbki z wielu równoległych środowisk są agregowane w jedną paczkę (ang. *batch*), po czym wykonywana jest pojedyncza, wspólna aktualizacja parametrów, co upraszcza implementację oraz czyni przebieg uczenia bardziej deterministycznym przy zachowaniu tej samej ogólnej struktury aktor–krytyk [25].

Generowanie danych uczących: rollout i długość trajektorii w A2C

W algorytmie A2C dane uczące powstają w sposób iteracyjny poprzez równoległe generowanie doświadczeń w wielu instancjach środowiska. W każdej iteracji uruchamia się N środowisk działających równoległe (ang. *vectorized environments*), które wykorzystują tę samą, aktualną politykę π_θ . Następnie z każdego środowiska zbierany jest fragment trajektorii (ang. *rollout*) o stałej długości T kroków, często oznaczanej jako $t_{\max}$. Otrzymana paczka danych składa się z obserwacji, akcji i nagród:

$$\mathcal{B} = \left\{ \left(s_t^{(i)}, a_t^{(i)}, r_t^{(i)}, s_{t+1}^{(i)} \right) : i = 1, \dots, N, t = 0, \dots, T-1 \right\}.$$

Po zebraniu paczki $\mathcal{B}$ wyznacza się na jej podstawie wielkości wymagane do uczenia, w szczególności przybliżone zwroty (np. n -krokowe) oraz estymaty przewagi A_t , a następnie wykonuje się jedną synchroniczną aktualizację parametrów sieci na całej paczce. Dopiero po tej aktualizacji generowana jest kolejna paczka danych, już z użyciem zaktualizowanej polityki, co jest zgodne z charakterem on-policy A2C [23, 25].

Wzory zawierające operator wartości oczekiwanej $\mathbb{E}_t[\cdot]$ interpretowane są w praktyce jako uśrednienie po wszystkich próbkach z paczki rollout:

$$\mathbb{E}_t[f_t] \approx \frac{1}{NT} \sum_{i=1}^N \sum_{t=0}^{T-1} f_t^{(i)}.$$

Takie ujęcie jednoznacznie określa, że estymacja gradientu oraz wartości strat aktora i krytyka opiera się na skończonej próbce doświadczeń zebranych w bieżącej iteracji uczenia.

Funkcja straty w A2C

Uczenie w algorytmie A2C realizowane jest poprzez minimalizację funkcji straty złożonej z komponentów odpowiadających aktorowi (polityce) oraz krytykowi (funkcji wartości), często uzupełnionej o składnik entropii wspierający eksplorację. Taka konstrukcja umożliwia jednocześnie doskonalenie polityki oraz estymację wartości stanu, co stabilizuje proces uczenia w środowiskach o dużej złożoności decyzyjnej [23].

Składnik aktora wynika z twierdzenia o gradiencie polityki i przyjmuje postać ujemnej logarytmicznej wiarygodności wybranej akcji, ważonej estymowaną funkcją przewagi:

$$\mathcal{L}_{\text{actor}}^{\text{A2C}}(\theta) = -\mathbb{E}_t [\log \pi_\theta(a_t | s_t) A_t].$$

Postać ta wzmacnia decyzje przynoszące wyniki ponadprzeciętne ($A_t > 0$) oraz tłumi decyzje gorsze od oczekiwanych ($A_t < 0$) [32].

Składnik krytyka odpowiada za aproksymację funkcji wartości stanu i najczęściej definiowany jest jako błąd średniokwadratowy względem przybliżonej wartości docelowej:

$$\mathcal{L}_{\text{critic}}^{\text{A2C}}(\theta) = \mathbb{E}_t \left[\left(V_{\theta}(s_t) - \hat{V}_t \right)^2 \right],$$

gdzie $\hat{V}_t$ może oznaczać np. n-krokowy zwrot lub wartość opartą na błędzie TD. Krytyk pełni rolę funkcji bazowej (baseline), zmniejszając wariancję estymatora gradientu aktora i poprawiając stabilność uczenia [23].

W wielu implementacjach A2C stosuje się również bonus entropijny:

$$\mathcal{L}_{\text{entropy}}^{\text{A2C}}(\theta) = -\mathbb{E}_t [\mathcal{H}(\pi_{\theta}(\cdot | s_t))].$$

Całkowita funkcja straty może być zapisana jako:

$$\mathcal{L}^{\text{A2C}}(\theta) = \mathcal{L}_{\text{actor}}^{\text{A2C}} + c_v \mathcal{L}_{\text{critic}}^{\text{A2C}} - c_e \mathcal{L}_{\text{entropy}}^{\text{A2C}},$$

gdzie c_v oraz c_e są współczynnikami wagowymi regulującymi wpływ krytyka i entropii.

3.3 PPO

Proximal Policy Optimization (PPO) jest algorytmem typu actor–critic zaproponowanym jako praktyczna alternatywa dla metod z ograniczeniem kroku aktualizacji polityki, takich jak Trust Region Policy Optimization (TRPO). Główna idea PPO polega na wykonywaniu kilku kroków optymalizacji na tej samej paczce trajektorii, ale w taki sposób, aby nowa polityka nie odsunęła się zbyt gwałtownie od polityki, która wygenerowała dane. Osiąga się to przez zastosowanie funkcji celu opartej na ilorazie prawdopodobieństw (ang. *importance sampling ratio*) oraz mechanizmie *clippingu*, który ogranicza wpływ zbyt dużych zmian polityki [28, 29].

Funkcja celu PPO (clipped surrogate objective)

Niech θ_{old} oznacza parametry polityki użytej do wygenerowania danych (rolloutu), a θ – parametry aktualizowanej polityki. Definiuje się iloraz:

$$r_t(\theta) = \frac{\pi_{\theta}(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}.$$

W PPO maksymalizuje się tzw. *surrogate objective* z obciążeniem (clipping):

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t [\min(r_t(\theta)A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) A_t)],$$

gdzie A_t jest estymatą przewagi (np. z GAE), a ϵ jest hiperparametrem ograniczającym dopuszczalną zmianę polityki w pojedynczej aktualizacji. Mechanizm $\min(\cdot)$ wraz z clip powoduje, że gdy $r_t(\theta)$

wychodzi poza przedział $[1 - \epsilon, 1 + \epsilon]$, dalsze zwiększanie $r_t(\theta)$ nie przynosi już korzyści w funkcji celu, co stabilizuje uczenie i zapobiega destrukcyjnym, zbyt agresywnym krokom optymalizacji [29].

W praktycznych implementacjach PPO optymalizuje się łączną funkcję straty, zawierającą również komponent krytyka (aproksymacja wartości) oraz bonus entropijny:

$$\mathcal{L}^{\text{PPO}}(\theta) = -\mathcal{L}^{\text{CLIP}}(\theta) + c_v \mathbb{E}_t \left[\left(V_\theta(s_t) - \hat{V}_t \right)^2 \right] - c_e \mathbb{E}_t [\mathcal{H}(\pi_\theta(\cdot | s_t))],$$

gdzie $\hat{V}_t$ oznacza wartość docelową (np. zwrot R_t), a c_v, c_e są wagami części krytyka i entropii. Taka postać odpowiada standardowej praktyce w actor–critic, natomiast różnica PPO polega na zastosowaniu członu $\mathcal{L}^{\text{CLIP}}$ zamiast klasycznej straty polityki bez ograniczenia kroku [29].

Algorytm PPO w ujęciu praktycznym (pętla uczenia)

W odróżnieniu od A2C, w którym po zebraniu rolloutu wykonuje się zwykle pojedynczą aktualizację, PPO wykorzystuje tę samą paczkę danych przez kilka epok optymalizacji (mini-batche). Typowy schemat jest następujący:

1. Zbierz rollout o długości T w N równoległych środowiskach, używając polityki $\pi_{\theta_{\text{old}}}$. Zapisz m.in. (s_t, a_t, r_t) oraz $\log \pi_{\theta_{\text{old}}}(a_t | s_t)$ i estymaty $V_{\theta_{\text{old}}}(s_t)$.
2. Wyznacz $\hat{V}_t$ (zwroty) oraz A_t (np. z GAE) na podstawie zebranej trajektorii [30].
3. Przez K epok wykonuj optymalizację SGD/Adam na losowanych mini-batchach z tej samej paczki, minimalizując $\mathcal{L}^{\text{PPO}}(\theta)$.
4. Ustaw $\theta_{\text{old}} \leftarrow \theta$ i powtórz proces dla kolejnego rolloutu.

Dzięki ilorazowi $r_t(\theta)$ PPO pozostaje metodą bliską on-policy, ale efektywniej wykorzystuje próbki, ponieważ dopuszcza kilka przejść optymalizacyjnych po tych samych danych przy jednoczesnym ograniczeniu odchylenia polityki.

Rodzaj sieci neuronowej w PPO

PPO nie wymaga odrębnego typu sieci względem ogólnej architektury actor–critic: najczęściej stosuje się jedną sieć z *współdzielonym trzonem* (np. CNN przetwarzające wejście przestrzenne), a następnie dwie głowy:

- **głowa polityki (aktor)**: generuje parametry rozkładu $\pi_\theta(a | s)$ (w Blood Bowl zwykle logity dla akcji dyskretnych),
- **głowa wartości (krytyk)**: generuje skalar $V_\theta(s)$.

Kluczowa różnica implementacyjna względem prostszych wariantów actor–critic polega na tym, że podczas uczenia PPO potrzebuje stabilnego odniesienia do polityki zbierającej dane, czyli przechowywania $\log \pi_{\theta_{\text{old}}}(a_t | s_t)$ (lub równoważnie $\pi_{\theta_{\text{old}}}(a_t | s_t)$), aby obliczać $r_t(\theta)$. Pozostałe elementy (np. maskowanie akcji w przestrzeni dyskretniej) mogą być zastosowane analogicznie jak

w innych agentach actor–critic, ponieważ wpływają jedynie na postać $\pi_{\theta}(\cdot | s)$, a nie na samą konstrukcję PPO.

3.4 Współdzielenie części konwolucyjnej

We wszystkich analizowanych architekturach zastosowano wspólną część konwolucyjną (ang. *trunk*), która przetwarza przestrzenne wejście sieci. Dopiero po ekstrakcji cech następuje rozdzielenie na dwie głowy: polityki i wartości. Takie podejście ma kilka istotnych zalet:

- redukuje liczbę parametrów modelu
- pozwala obu głowom korzystać z tej samej reprezentacji stanu,
- znacząco obniża koszty obliczeniowe w porównaniu do tworzenia dwóch oddzielnych sieci.

W praktyce trunk CNN odpowiada za mapowanie danych przestrzennych na wektor cech, który następnie jest łączony z danymi nieprzestrzennymi i przekazywany do końcowych warstw gęstych obu głów.

3.5 Reprezentacja danych wejściowych

W przypadku gry Blood Bowl stan gry ma charakter złożony i heterogeniczny: zawiera zarówno informacje przestrzenne (układ zawodników, lokalizacja piłki, strefy zagrożeń), jak i nieprzestrzenne (licznik tur, aktywny etap procedury gry, dostępne przerzuty). Dlatego konieczne jest zastosowanie reprezentacji umożliwiającej jednocześnie efektywne przetwarzanie danych o różnych charakterystykach strukturalnych.

W pracy przyjęto podział reprezentacji danych wejściowych na dwa niezależne strumienie: strumień przestrzenny, przetwarzany przez konwolucyjne sieci neuronowe, oraz strumień nieprzestrzenny, analizowany za pomocą klasycznych warstw w pełni połączonych.

Strumień Przestrzenny

Strumień przestrzenny stanowi tensor opisujący układ gry na planszy w formie wielowarstwowej mapy cech. Tensor wejściowy ma postać:

$$X \in \mathbb{R}^{C \times H \times W}$$

gdzie

- C oznacz liczbę kanałów cech,
- $H \times W$ odpowiada wymiarom planszy.

BotBowl w formule turniejowej udostępnia 44 kanały. Kanały te zawierają między innymi informacje o

- położenie zawodników drużyny gracza
- położenie zawodników przeciwnika
- parametry zawodników (siła, zwinności, prędkość)

- położenie piłki
- strefa punktowa własnej drużyny
- strefa punktowa przeciwnej drużyny
- pozycje na których można wykonać akcję push
- pozycja wybranego zawodnika
- stany zawodników (ogłuszony, po ruchu)
- szanse na wykonanie bloku

Strumień nie przestrzenny

Drugim komponentem reprezentacji danych jest strumień nieprzestrzenny, zawierający wszystkie informacje dotyczące gry, których nie da się w sposób naturalny odwzorować jako mapę dwuwymiarową. Są to np. numer aktualnej tury, flagi opisujące możliwe operacje w danej chwili, dostępne ponowne rzuty obydwu drużyn. Jest on zapisywany w postaci wektora.

$$y \in \mathbb{R}^d$$

gdzie d oznacza liczbę cech.

Strumień nieprzestrzenny jest przetwarzany przez warstwy gęste, które mapują go na reprezentację ukrytą

$$h = \sigma(Wy + b)$$

Integracja strumieni danych

Po przetworzeniu oddzielnych strumieni następuje ich agregacja:

$$z = [\text{flatten}(f_{\text{CNN}}(X)), h]$$

gdzie

- $f_{\text{CNN}}(\cdot)$ oznacza działanie trzonu konwolucji
- h jest przetworzonym wektorem cech skalarnych
- operator $[\cdot]$ oznacza konkatenację wektorową.

Powstały wektor z stanowi skondensowaną reprezentację stanu gry zawierającą zarówno informacje przestrzenne, jak i skalarne. W tej formie trafia on do kolejnych warstw sieci, które generują:

- wartości polityki (logity akcji)
- estymatę funkcji wartości $V_{\theta}(s)$

3.6 Architektura typu CNN z blokiem Inception

W wersji podstawowej sieci konwolucyjne posiadają stałe rozmiary filtrów (np. 3×3), co ogranicza ich zdolność do równoczesnego wychwytywania cech lokalnych i bardziej globalnych. Aby zwiększyć

elastyczność i reprezentatywność ekstraktora cech, w niniejszej pracy zastosowano rozszerzenie w postaci bloku Inception, inspirowanego architekturą GoogLeNet

Blok Inception został zaprojektowany tak, aby umożliwić równoległe przetwarzanie tych samych danych za pomocą operatorów konwolucyjnych o różnych rozmiarach filtrów. Każdy z filtrów bada dane w innej skali przestrzennej, co pozwala na lepsze uchwycenie wieloskalowych zależności obecnych na planszy Blood Bowl, takich jak:

- lokalne konfiguracje zawodników (bloki, strefy ataku, pojedyncze zagrożenia)
- średnie struktury pozycyjne (np. zagęszczenia w centrum, formacje ofensywne)
- zależności dalekiego zasięgu (np. ścieżki podań, ustawienia defensywne)

Formalnie, niech wejście do bloku oznaczone będzie jako tensor:

$$X \in \mathbb{R}^{C \times H \times W}$$

Blok inception składa się z zestawu równoległych ścieżek konwolucyjnych, z których każda operuje na filtrach o innym rozmiarze jądra:

$$Y_k = f_k(X), k = 1, 2, 3, \dots, K$$

gdzie $f_k(\cdot)$ to operacja konwolucji o jądrze $k \times k$, Następnie wszystkie przetworzone reprezentacje są łączone wzdłuż wymiaru kanałów:

$$Y = \text{concat}(Y_1, Y_2, \dots, Y_k)$$

Tak powstała cecha końcowa łączy informacje wieloskalowe w jednym tensorze.

Zastosowanie bloków Inception w sieci konwolucyjnej daje kilka istotnych korzyści.

Decyzje podejmowane przez agenta w Blood Bowl zależą zarówno od lokalnych interakcji (np. możliwości bloku), jak i globalnych struktur (np. ustawienie do biegu po przyłożeniu). Architektura Inception pozwala modelować oba rodzaje zależności w ramach jednej warstwy.

Blok Inception jest modularny i dobrze współpracuje z pozostałymi elementami architektur A2C i PPO.

Może być on nakładany sekwencyjnie, zwiększając głębokość modelu. W praktyce zastosowano od kilku do kilkunastu takich bloków w zależności od rozmiaru planszy i dostępnych zasobów obliczeniowych.

Ograniczenia

Mimo licznych zalet, klasyczny Inception stosowany jako wielowarstwowy trunk ma pewne ograniczenia:

- brak mechanizmu kompensacji zanikania gradientu przy głębokich sieciach,
- możliwe zwiększenie kosztów obliczeń przy dużej liczbie kanałów wyjściowych,
- brak informacji rezydualnej, co utrudnia stabilne uczenie w głębokich modelach.

Z tego względu w kolejnych architekturach wprowadzono połączenia rezydualne oraz klasyczną strukturę ResNet, co pozwala poprawić stabilność i jakość ekstrakcji cech.

3.7 ResNet

Kolejną analizowaną architekturą jest sieć konwolucyjna oparta na klasycznym modelu ResNet, charakteryzującym się zastosowaniem bloków rezydualnych o stałej liczbie kanałów. Architektura ta jest uznawana za jedną z najbardziej stabilnych struktur CNN do głębokiej ekstrakcji cech. W przeciwieństwie do bloku Inception, blok rezydualny w ResNet wykorzystuje konwolucje o stałym rozmiarze (zwykle 3×3), jednak równoważy brak wieloskalarności większą głębokością i stabilnością gradientu. Podstawowy blok ResNet składa się z dwóch konwolucji 3×3 z normalizacją i nieliniowością:

$$F(X) = \sigma(\text{BN}(W_2 * \sigma(\text{BN}(W_1 * X))))$$

gdzie,

- W_1, W_2 są filtrami konwolucyjnymi
- BN oznacza normalizację BatchNorm
- σ jest funkcją aktywacji

Wyjście bloku powstaje poprzez dodanie wejścia do przetworzonej reprezentacji:

$$Y = X + F(X)$$

Zalety ResNet

ResNety zostały zaprojektowane specjalnie w celu umożliwienia trenowania bardzo głębokich sieci, nawet powyżej 100 warstw. Połączenia rezydualne stabilizują gradient, co istotnie poprawia możliwości ekstrapolacyjne sieci.

Bloki ResNet dobrze radzą sobie z wykrywaniem średniego i globalnego kontekstu przestrzennego, co jest istotne w ocenie pozycji zawodników, wyznaczaniu ścieżek ruchu i szacowaniu zagrożeń.

Wady ResNet

Choć ResNet jest stabilny i prosty w implementacji, brak mechanizmu wieloskalarności może prowadzić do utraty informacji istotnych dla niektórych sytuacji taktycznych, np. jednoczesnej oceny bloków lokalnych i formacji globalnych. W praktyce jednak jego stabilność i przewidywalność czynią go doskonałą bazą do porównania z bardziej złożonymi architekturami.

3.8 Inception-Residual

Trzecią z analizowanych architektur jest model oparty na blokach Inception, wzbogacony o mechanizm połączeń rezydualnych (residual connections). Rozwiązanie to stanowi połączenie wieloskalowej

analizy cech, charakterystycznej dla modułu Inception, z właściwościami stabilizującymi proces uczenia, typowymi dla sieci ResNet. Architektura ta została zaprojektowana w celu zwiększenia głębokości sieci oraz poprawy jakości gradientu podczas optymalizacji, co jest szczególnie istotne w środowiskach o dużej złożoności, takich jak Blood Bowl.

W klasycznym bloku Inception wykorzystuje się równoległe konwolucje o różnych rozmiarach filtrów, które następnie są konkatencjonowane. W obecnej architekturze wynik działania bloku Inception oznaczamy jako:

$$F(X) = \text{concat}(f_1(X), f_3(X), f_5(X))$$

Aby zwiększyć stabilność uczenia i umożliwić efektywne propagowanie gradientu, wprowadzono połączenie rezydualne, które dodaje wejście bloku do jego wyjścia:

$$Y = F(X) + R(X)$$

gdzie $R(X)$ jest transformacją dopasowującą wymiar kanałów wejściowych i wyjściowych. W przypadku zgodnej liczby kanałów stosuje się połączenie tożsamościowe $R(X) = X$. W przypadku rozbieżności stosuje się projekcję:

$$R(X) = W_s * X$$

, gdzie W_s oznacza konwolucję 1×1 dopasowującą wymiar kanałów. Zabieg ten jest analogiczny do rozwiązań stosowanych w ResNet.

Architektura Residual Inception Network łączy komplementarne zalety modułów Inception oraz bloków rezydualnych ResNet, tworząc model o wysokiej zdolności reprezentacyjnej przy jednoczesnej stabilności uczenia. Zastosowanie wielu równoległych filtrów o różnych rozmiarach w bloku Inception umożliwia wydobywanie cech wieloskalowych – od lokalnych interakcji po bardziej globalne wzorce pozycyjne – co jest szczególnie istotne w złożonych środowiskach przestrzennych. Dodanie połączeń rezydualnych znacząco poprawia przepływ gradientu, eliminując problem zanikania sygnału i umożliwiając trenowanie głębszych modeli bez degradacji jakości reprezentacji. Połączenie tych dwóch podejść pozwala sieci zachować elastyczność i ekspresyjność architektury Inception, a jednocześnie wykorzystać właściwości stabilizujące charakterystyczne dla ResNet, prowadząc do skuteczniejszej i bardziej odpornej ekstrakcji cech w złożonych zadaniach decyzyjnych.

3.9 Hyper-Connections

Hyper-Connections (HC), zaproponowane przez Zhu i in. [36], stanowią rozszerzenie klasycznych połączeń rezydualnych. W standardowym połączeniu rezydualnym wejście warstwy i jej wyjście są łączone za pomocą z góry ustalonej operacji sumowania. Oznacza to, że sposób przepływu informacji pomiędzy kolejnymi głębokościami sieci jest sztywny i nie zależy ani od danych, ani od etapu uczenia. Autorzy HC wskazują, że takie podejście prowadzi do kompromisu pomiędzy dwoma niepożądanymi

zjawiskami: zanikaniem gradientu oraz kolapsem reprezentacji, rozumianym jako sytuacja, w której sąsiednie warstwy zaczynają generować bardzo podobne reprezentacje cech.

Podstawową ideą *Hyper-Connections* jest zastąpienie pojedynczego strumienia reprezentacji zbiorem n równoległych reprezentacji ukrytych:

$$H_l = \begin{bmatrix} h_l^{(1)} \\ h_l^{(2)} \\ \vdots \\ h_l^{(n)} \end{bmatrix} \in \mathbb{R}^{n \times d}, \quad (5)$$

gdzie $h_l^{(i)}$ oznacza i -tą reprezentację ukrytą w warstwie l , zbiór reprezentacji $h_l^{(1)}, \dots, h_l^{(n)}$ składa się z n równoległych strumieni przetwarzania informacji, pomiędzy którymi model może wymieniać informacje za pomocą mechanizmu *Hyper-Connections*. Dla wejścia sieci h_0 tworzona jest początkowa macierz:

$$H_0 = \begin{bmatrix} h_0 \\ h_0 \\ \vdots \\ h_0 \end{bmatrix}. \quad (6)$$

Takie sformułowanie pozwala warstwie operować nie na jednej reprezentacji, lecz na kilku równoległych strumieniach informacji. Dzięki temu model może uczyć się nie tylko siły połączenia typu wejście–wyjście, ale również sposobu mieszania informacji pomiędzy różnymi reprezentacjami i głębokościami sieci.

Formalny opis mechanizmu

Dla warstwy l mechanizm *Hyper-Connections* opisuje macierz blokowa:

$$HC_l = \begin{pmatrix} 0_{1 \times 1} & B_l \\ A_{m,l} & A_{r,l} \end{pmatrix} \in \mathbb{R}^{(n+1) \times (n+1)}. \quad (7)$$

W powyższym zapisie:

- n oznacza liczbę równoległych reprezentacji ukrytych,
- d oznacza wymiar pojedynczej reprezentacji ukrytej,
- $H_{l-1} \in \mathbb{R}^{n \times d}$ jest macierzą reprezentacji ukrytych z poprzedniej warstwy,
- $B_l \in \mathbb{R}^{1 \times n}$ określa, w jaki sposób wynik bieżącej transformacji jest rozdzielany pomiędzy reprezentacje wyjściowe,
- $A_{m,l} \in \mathbb{R}^{n \times 1}$ wyznacza sposób agregacji reprezentacji z poprzedniej warstwy do wejścia bieżącej transformacji,
- $A_{r,l} \in \mathbb{R}^{n \times n}$ opisuje przenoszenie i mieszanie reprezentacji w ścieżce rezidualnej,
- $F_l(\cdot)$ oznacza transformację realizowaną przez l -tą warstwę.

Na podstawie macierzy H_{l-1} konstruowane jest wejście do bieżącej transformacji:

$$\tilde{h}_l^\top = A_{m,l}^\top H_{l-1}, \quad (8)$$

gdzie $\tilde{h}_l \in \mathbb{R}^d$ jest zagregowaną reprezentacją wejściową dla transformacji $F_l(\cdot)$.

Następnie wyznaczana jest część rezydualna:

$$H'_l = A_{r,l}^\top H_{l-1}, \quad (9)$$

gdzie $H'_l \in \mathbb{R}^{n \times d}$ zawiera reprezentacje przenoszone ścieżką rezydualną.

Po zastosowaniu transformacji warstwy otrzymujemy nową macierz reprezentacji:

$$\hat{H}_l = B_l^\top (F_l(\tilde{h}_l))^\top + H'_l, \quad (10)$$

gdzie $\hat{H}_l \in \mathbb{R}^{n \times d}$ jest wynikiem działania mechanizmu *Hyper-Connections* w warstwie l .

Oznacza to, że mechanizm ten nie ogranicza się do prostego dodania wejścia i wyjścia warstwy, jak w klasycznym połączeniu rezydualnym. Zamiast tego model uczy się, jak agregować wcześniejsze reprezentacje, jak przenosić je ścieżką rezydualną oraz jak rozdzielać wynik bieżącej transformacji pomiędzy równoległe reprezentacje wyjściowe.


Depth-connections i width-connections

Mechanizm *Hyper-Connections* można interpretować jako połączenie dwóch rodzajów zależności, przedstawionych na rys. 4.

Depth-connections opisują przepływ informacji pomiędzy kolejnymi głębokościami sieci. Odpowiadają one za to, w jakim stopniu reprezentacje z poprzedniej warstwy oraz wynik bieżącej transformacji wpływają na reprezentacje w warstwie następnej.

Width-connections opisują natomiast wymianę informacji pomiędzy równoległymi reprezentacjami w obrębie tej samej warstwy. Dzięki nim poszczególne reprezentacje nie są przetwarzane niezależnie, lecz mogą wzajemnie przekazywać sobie informację.

W efekcie pojedyncza warstwa operuje nie na jednym wektorze cech, lecz na zbiorze równoległych reprezentacji, pomiędzy którymi zachodzi zarówno integracja wzdłuż głębokości, jak i wymiana informacji w szerokości.



Rysunek 4. Połączenia Hyper-Connections.

Dynamiczne Hyper-Connections

Rozszerzeniem podstawowego wariantu są dynamiczne *Hyper-Connections*, w których parametry połączeń nie są stałe, lecz zależą od aktualnych reprezentacji wejściowych. Oznacza to, że model może zmieniać sposób agregacji, przenoszenia i mieszania informacji w zależności od bieżącego kontekstu danych.

Dla warstwy l dynamiczną macierz połączeń zapisuje się jako:

$$HC_l(H_{l-1}) = \begin{pmatrix} 0_{1 \times 1} & B_l(H_{l-1}) \\ A_{m,l}(H_{l-1}) & A_{r,l}(H_{l-1}) \end{pmatrix}. \quad (11)$$

W praktyce dynamiczne składniki są wyznaczane jako poprawki do parametrów statycznych. Najpierw normalizowana jest macierz reprezentacji z poprzedniej warstwy:

$$\bar{H}_{l-1} = \text{norm}(H_{l-1}), \quad (12)$$

co stabilizuje obliczanie wag dynamicznych i ogranicza nadmierną wrażliwość na skalę aktywacji.

Następnie wyznaczane są trzy składniki dynamiczne:

$$B_l(H_{l-1}) = s_\beta \odot \tanh\left((\bar{H}_{l-1} W_\beta)^\top\right) + B_l, \quad (13)$$

$$A_{m,l}(H_{l-1}) = s_\alpha \odot \tanh(\bar{H}_{l-1} W_m) + A_{m,l}, \quad (14)$$

$$A_{r,l}(H_{l-1}) = s_\alpha \odot \tanh(\bar{H}_{l-1} W_r) + A_{r,l}. \quad (15)$$

W powyższych zależnościach:

- W_β , W_m , W_r są dodatkowymi parametrami uczonymi, odpowiedzialnymi za wyznaczanie części dynamicznej,
- B_l , $A_{m,l}$, $A_{r,l}$ są bazowymi parametrami statycznymi,
- s_β oraz s_α są współczynnikami skalującymi wpływ części dynamicznej,
- funkcja $\tanh$ ogranicza wartości poprawek i stabilizuje uczenie.

Znaczenie poszczególnych składników dynamicznych jest następujące. Macierz $A_{m,l}(H_{l-1})$ decyduje, które strumienie reprezentacji z poprzedniej warstwy i z jaką siłą zostaną wykorzystane do zbudowania wejścia dla bieżącej transformacji. Macierz $A_{r,l}(H_{l-1})$ steruje ścieżką rezydualną, określając, które wcześniejsze reprezentacje należy zachować, wzmocnić lub osłabić. Z kolei $B_l(H_{l-1})$ określa, jak wynik bieżącej warstwy zostanie rozprowadzony pomiędzy równoległe reprezentacje wyjściowe.

Wariant dynamiczny jest zatem istotnie bardziej elastyczny od wariantu statycznego. W zwykłym HC model uczy się jednego schematu przepływu informacji, który po zakończeniu treningu pozostaje stały. W dynamicznym HC schemat ten może zmieniać się zależnie od aktualnego wejścia. Oznacza

to, że dla różnych danych ta sama warstwa może korzystać z odmiennych proporcji informacji bieżącej i rezydualnej oraz z innego sposobu mieszania strumieni reprezentacji.

Znaczenie architektoniczne

Z architektonicznego punktu widzenia *Hyper-Connections* można traktować jako uogólnienie połączeń rezydualnych. Mechanizm ten nie narzuca jednego, sztywnego sposobu organizacji przepływu informacji, lecz pozwala modelowi uczyć się, czy przetwarzanie powinno mieć charakter bardziej sekwencyjny, bardziej równoległy, czy pośredni. W tym sensie HC zwiększają swobodę organizacji obliczeń w głębokiej sieci.

Istotne jest również to, że korzyści z HC pojawiają się dopiero przy więcej niż jednym strumieniu reprezentacji, czyli dla $n > 1$. Wówczas model rzeczywiście zyskuje możliwość jednoczesnego przenoszenia informacji pomiędzy głębokościami oraz mieszania reprezentacji w obrębie warstwy. Dzięki temu ograniczany jest problem nadmiernego upodobniania się reprezentacji kolejnych warstw, a wpływ pojedynczej warstwy na końcową reprezentację może być większy niż w klasycznym połączeniu rezydualnym.

W kontekście niniejszej pracy szczególnie istotny jest wariant dynamiczny, ponieważ umożliwia zależne od wejścia sterowanie przepływem informacji. Jest to własność cenna w zadaniach, w których kolejne stany mogą znacząco różnić się strukturą i wymagają odmiennych wzorców przetwarzania, jak ma to miejsce w środowiskach uczenia ze wzmocnieniem.

3.10 Rozszerzenia architektury sieci i techniki stabilizacji uczenia

Layer Normalization

Normalizacja warstwowa (ang. Layer Normalization, LN) to technika normalizacji zaproponowana przez Ba i wsp. (2016) jako alternatywa dla normalizacji wsadowej (BN). [1] W przeciwieństwie do BN, która wykorzystuje statystyki z mini-batcha, LN oblicza statystyki normalizacji dla każdej próbki osobno, uwzględniając wszystkie neurony danej warstwy w próbce. Formalnie, dla wektora aktywacji $\mathbf{a}^{(l)} = (a_1^{(l)}, a_2^{(l)}, \dots, a_H^{(l)})$ w warstwie l , normalizacja warstwowa oblicza średnią $\mu^{(l)} = \frac{1}{H} \sum_{i=1}^H a_i^{(l)}$ oraz wariancję $\sigma^{2(l)} = \frac{1}{H} \sum_{i=1}^H (a_i^{(l)} - \mu^{(l)})^2$. Następnie każda aktywacja zostaje przeskalowana do postaci znormalizowanej:

$$\hat{a}_i^{(l)} = \frac{a_i^{(l)} - \mu^{(l)}}{\sqrt{\sigma^{2(l)} + \epsilon}}$$

gdzie ϵ to niewielka stała zapobiegająca dzieleniu przez zero. Po normalizacji, dla każdego neuronu stosuje się jeszcze parametry adaptacyjne: skalowanie γ_i oraz przesunięcie β_i , analogiczne jak w BN, co daje wyjście $y_i^{(l)} = \gamma_i \hat{a}_i^{(l)} + \beta_i$. Takie podejście powoduje, że wszystkie neurony w warstwie mają jednakowe wartości średniej i wariancji dla danej próbki, ale każda próbka (każdy element batcha) jest normalizowana względem własnych statystyk. W rezultacie znika zależność od rozmiaru batcha – LN

działa poprawnie nawet przy batch size = 1, czyli w trybie online. Co więcej, algorytm normalizacji jest identyczny podczas trenowania i testowania modelu, gdyż statystyki liczone są lokalnie dla próbki (nie ma potrzeby utrzymywania średnich z bieżącej partii czy populacji)

Normalizację warstwową stosuje się zazwyczaj bezpośrednio po warstwie liniowej lub konwolucyjnej, a przed funkcją aktywacji, analogicznie do sposobu użycia Batch Normalization. W testowanych architekturach agentów A2C – takich jak warianty z blokami Inception oraz ich warianty rezydualne – warstwy normalizujące mogą być stosowana zarówno w trunku konwolucyjnym, jak i w częściach gęstych. W przeciwieństwie do BatchNorm, LN oblicza średnią i wariancję osobno dla każdej próbki, niezależnie od innych elementów batcha. Dzięki temu działa poprawnie nawet przy batch size = 1, co jest szczególnie przydatne w algorytmach on-policy, takich jak PPO i A2C. LN jest także odporny na niestacjonarność rozkładów – nie bazuje na statystykach historycznych, lecz zawsze normalizuje względem bieżącej próbki. Ułatwia to adaptację do zmieniającej się przestrzeni stanów oraz upraszcza implementację, ponieważ nie wymaga przełączania między trybem treningu i ewaluacji. LN lepiej sprawdza się również przy korelowanych danych, typowych dla trajektorii w RL – normalizacja odbywa się niezależnie dla każdej próbki, co zapobiega mieszaniu informacji pomiędzy krokami czasowymi. Badania pokazują, że sieci z LN osiągają stabilniejsze i skuteczniejsze uczenie niż z BatchNorm, zwłaszcza w warunkach zmiennych i silnie skorelowanych danych.

W architekturach głębokich, takich jak Inception-Residual, LN dodatkowo stabilizuje propagację sygnału przez ścieżki rezydualne i przeciwdziała problemom z gradientami. Choć w klasycznej wizji komputerowej preferuje się inne metody, LN okazuje się szczególnie użyteczna w RL, gdzie małe batch size i niestacjonarne dane utrudniają skuteczne użycie BatchNorm.

Parametric ReLU

Parametric ReLU (PReLU) to uogólnienie klasycznej funkcji aktywacji ReLU, w którym nachylenie dla ujemnych wartości wejścia nie jest stałe, lecz jest parametryczne (uczony podczas trenowania sieci). Formalnie funkcja PReLU jest zdefiniowana wzorem:

$$f(x) = \begin{cases} x, & x > 0 \\ ax, & x \leq 0 \end{cases} \quad (16)$$

gdzie x oznacza wejście neuronu, zaś a (często oznaczane też α) to współczynnik kontrolujący nachylenie dla ujemnych wartości [12]. W odróżnieniu od zwykłego ReLU (dla którego $a = 0$) wartość a w PReLU jest uczonym parametrem modelu (stąd nazwa Parametric ReLU) i może przyjmować różne wartości w różnych kanałach lub neuronach.

W trakcie przepływu wstecznego (backpropagation) wyznaczone są gradienty zarówno względem wejścia x , jak i względem parametru a . Parametr a jest więc dostosowywany wraz z wagami sieci metodami optymalizacji gradientowej – podczas treningu sieć uczy się optymalnej wartości nachylenia dla ujemnych wartości każdej funkcji aktywacji. W praktyce uczenie parametru a odbywa się standardowo za pomocą algorytmu wstecznej propagacji błędów (np. z zastosowaniem optymalizatora

z momentum). Ważne jest, że nie stosuje się zwykle regularizacji L_2 (tzw. weight decay) na parametr a , aby nie biasować go w kierunku zera (co sprowadziłoby PReLU do zwykłego ReLU). Zamiast tego pozwala się wartości a swobodnie dostosować – badania wskazują, że nawet bez ograniczania zakresu a jego wartości rzadko przekraczają 1 (współczynniki pozostają umiarkowane). Typową inicjalizacją jest nadanie a małej dodatniej wartości (np. 0.25) przed treningiem

Inicjalizacja He

Inicjalizacja He (znana też jako Kaiming initialization) to metoda losowego ustawiania początkowych wag sieci neuronowej zaproponowana przez Kaiminga He i wsp. [12] specjalnie z myślą o sieciach z aktywacją ReLU. Wagi każdej warstwy są inicjalizowane jako niezależne zmienne losowe o średniej zero i odpowiednio dobranej wariancji. Formalnie dla wariantu normalnego (rozkład Gaussa) przyjmuje się:

$$w_{ij}^{(l)} \sim N(0, \sigma^2), \text{ gdzie } \sigma^2 = \frac{2}{n_{in}}$$

, czyli wagi pochodzą z rozkładu normalnego o średniej 0 i wariancji $2/n_{in}$ (tu n_{in} oznacza liczbę wejściowych połączeń neuronu, tzw. fan-in danej warstwy). Istnieje też wariant z rozkładu jednostajnego – wówczas wagi losuje się z przedziału symetrycznego:

$$w_{ij}^{(l)} \sim U(-a, +a), \text{ gdzie } a = \sqrt{\frac{6}{n_{in}}}$$

,

tak aby wariancja była równa $2/n_{in}$ (ponieważ dla $U(-a, a)$ wariancja wynosi $a^2/3$, stąd $a = \sqrt{6/n_{in}}$). Metoda He bywa nazywana również MSRA initialization (od Microsoft Research Asia) albo Kaiming initialization, od imienia głównego autora pracy. Celem inicjalizacji He jest zachowanie odpowiedniej skali sygnału (wariancji aktywacji) przy propagacji przez bardzo głęboką sieć. W sieciach głębokich niewłaściwe skalowanie wag może skutkować zanikaniem sygnału albo eksplozją sygnału w kolejnych warstwach.

He i wsp. analizowali wariancję aktywacji warstwy i po warstwie i i wymagali, by iloczyn wariancji sygnału przez kolejne warstwy pozostawał stały (w przybliżeniu równy 1). Warunek ten prowadzi do doboru wariancji wag $\text{Var}(w) \approx 2/n_{in}$, co odpowiada powyższemu wzorowi. Intuicyjnie, współczynnik 2 wynika z faktu, że aktywacja ReLU zeruje średnio połowę wejść – aby utrzymać stałą wariancję sygnału na wyjściu neuronu ReLU, wariancja wag musi być dwa razy większa niż w przypadku funkcji liniowej [12]. Dzięki temu rozwiązaniu amplituda sygnałów nie zanika wraz z głębokością sieci, co ułatwia trenowanie bardzo głębokich modeli.

Inicjalizacja He, a Glorot

Inicjalizacja He została zaprojektowana z myślą o architekturach wykorzystujących niesymetryczne funkcje aktywacji, takie jak ReLU oraz jej rozszerzenia, w szczególności PReLU. W przeciwieństwie

do wcześniejszych metod – jak inicjalizacja Glorota (znana też jako Xavier), która była dostosowana do aktywacji o symetrycznym rozkładzie wyjść (np. funkcji $\tanh$ lub sigmoidalnej) – inicjalizacja He uwzględnia fakt, że funkcje typu ReLU przekazują tylko część dodatnich sygnałów do kolejnych warstw. To asymetryczne zachowanie aktywacji czyni wcześniejsze strategie inicjalizacji mniej skutecznymi w kontekście głębokich modeli wykorzystujących rektyfikację.

W przypadku metody Glorota wagi warstw są dobierane tak, aby równoważyć propagację sygnału do przodu i gradientów wstecz. Wariancja wag zależy od średniej liczby połączeń wejściowych i wyjściowych danego neuronu (fan-in i fan-out), przez co inicjalizacja ta bywa niewystarczająca w sytuacji, gdy aktywacja istotnie zmniejsza amplitudę sygnału. W rezultacie może dojść do szybkiego wygaszenia aktywacji w głębokich warstwach, co utrudnia efektywne trenowanie modelu.

Inicjalizacja He, poprzez skupienie się wyłącznie na liczbie wejść do neuronu, lepiej dopasowuje skalę wag do rektyfikowanych funkcji aktywacji, zachowując stabilność propagowanego sygnału nawet w bardzo głębokich sieciach. Empiryczne wyniki autorów metody potwierdzają, że zastosowanie tej strategii umożliwia skuteczne trenowanie modeli złożonych z wielu warstw, które przy klasycznej inicjalizacji nie zbiegały lub zbiegały bardzo wolno. Ponadto, mimo że metoda He nie została zaprojektowana z myślą o kontroli przepływu gradientu wstecznego, w praktyce pozwala ona również uniknąć problemów eksplodujących lub zanikających gradientów, szczególnie w sieciach wykorzystujących ReLU lub PReLU.

Maskowania niedozwolonych akcji

W algorytmach typu actor-critic kluczowe jest zapewnienie, aby przestrzeń akcji dostępna dla agenta była zgodna z formalnymi ograniczeniami środowiska. W grze Blood Bowl liczba wszystkich możliwych do zakodowania akcji jest bardzo wysoka, lecz w danym stanie jedynie niewielki ich podzbiór stanowi akcje legalne. Pozostałe działania są niedozwolone (np. ruch na zajęte pole, podniesienie nieistniejącej piłki, wykonanie blitzu przez zawodnika, który wykonał już akcję w danej turze).

Aby zapewnić zgodność polityki z regułami środowiska oraz poprawić stabilność procesu uczenia, zastosowano formalny mechanizm *maskowania akcji* (ang. *action masking*). Mechanizm ten polega na modyfikacji wektora logitów polityki poprzez przypisanie logitom odpowiadającym nielegalnym akcjom w stanie s wartości nieskończenie ujemnej.

$$\text{logit}_i = -\infty \quad (17)$$

Po zastosowaniu funkcji softmax

$$\pi_{\theta}(a_i | s) = \frac{\exp(\text{logit}_i)}{\sum_j \exp(\text{logit}_j)}, \quad (18)$$

otrzymujemy w sposób bezpośredni

$$\pi_{\theta}(a_i | s) = 0 \quad \text{jeśli akcja } i \text{ jest nielegalna.} \quad (19)$$

Maskowanie można interpretować jako projekcję rozkładu polityki na zbiór akcji dopuszczalnych:

$$\pi_{\theta}(\cdot | s) \longrightarrow \pi_{\theta}(\cdot | s)|_{\mathcal{A}(s)}, \quad (20)$$

gdzie $\mathcal{A}(s) \subseteq \mathcal{A}$ oznacza zbiór akcji legalnych w stanie s .

Formalnie mechanizm ten można również zapisać jako dodanie wektora maski:

$$\tilde{z}_i = z_i + m_i, \quad (21)$$

gdzie

$$m_i = \begin{cases} 0, & i \in \mathcal{A}(s), \\ -\infty, & i \notin \mathcal{A}(s), \end{cases} \quad (22)$$

a z_i oznacza oryginalne logity polityki.

Tak zdefiniowana transformacja zapewnia, że wartość prawdopodobieństwa każdej akcji spoza zbioru $\mathcal{A}(s)$ równa jest zero, przy jednoczesnym braku wpływu na rozkład prawdopodobieństwa wśród akcji legalnych. W konsekwencji maskowanie poprawia efektywność eksploracji, redukuje wariancję gradientów oraz zapobiega generowaniu trajektorii niezgodnych z regułami gry.

3.11 Architektury sieci neuronowych zastosowanych w środowisku

Wszystkie analizowane architektury zostały zbudowane w oparciu o wspólny schemat agenta typu actor–critic. Niezależnie od zastosowanego algorytmu uczenia (A2C lub PPO), model przyjmuje dwa strumienie wejściowe: przestrzenny oraz nieprzestrzenny, a następnie generuje dwa wyjścia: estymatę wartości stanu oraz logity polityki.

Stan środowiska reprezentowany jest przez dwa strumienie danych:

$$x_s \in \mathbb{R}^{C \times H \times W}, \quad x_{ns} \in \mathbb{R}^N.$$

Strumień przestrzenny x_s koduje stan planszy w postaci tensora wielokanałowego, natomiast strumień nieprzestrzenny x_{ns} zawiera cechy skalarne opisujące bieżący stan rozgrywki.

Część przestrzenna modelu przetwarza tensor wejściowy za pomocą sekwencji bloków Inception. Każdy blok składa się z równoległych gałęzi konwolucyjnych o różnych rozmiarach jąder, a ich wyjścia są łączone przez konkatencję wzdłuż wymiaru kanałów. Dla wejścia h pojedynczy blok można zapisać jako:

$$\text{Inc}(h) = \text{concat}(f_{3 \times 3}(h), f_{5 \times 5}(h), f_{7 \times 7}(h)), \quad (23)$$

gdzie każda funkcja $f_{k \times k}$ oznacza konwolucję z dopełnieniem (*padding*) zachowującym rozmiar przestrzenny, po której stosowana jest funkcja aktywacji ReLU.

W bazowym wariancie Inception (IN) zastosowano trzy kolejne bloki przestrzenne:

$$h_s^{(1)} = \text{Inc}_1(x_s), \quad \text{Inc}_1 : (12, 3 \times 3), (8, 5 \times 5), (8, 7 \times 7), \quad (24)$$

$$h_s^{(2)} = \text{Inc}_2(h_s^{(1)}), \quad \text{Inc}_2 : (24, 3 \times 3), (16, 5 \times 5), (16, 7 \times 7), \quad (25)$$

$$h_s^{(3)} = \text{Inc}_3(h_s^{(2)}), \quad \text{Inc}_3 : (36, 3 \times 3), (24, 5 \times 5), (24, 7 \times 7). \quad (26)$$

Po przetworzeniu części przestrzennej otrzymana reprezentacja jest spłaszczana:

$$v_s = \text{flatten}(h_s^{(3)}). \quad (27)$$

Strumień nieprzestrzenny jest przetwarzany przez prosty encoder złożony z jednej warstwy liniowej oraz funkcji ReLU:

$$v_{ns} = \text{ReLU}(W_{ns}x_{ns} + b_{ns}). \quad (28)$$

Następnie obie reprezentacje są łączone przez konkatencję:

$$z_0 = [v_s, v_{ns}]. \quad (29)$$

Połączony wektor cech trafia do wspólnego trzonu MLP:

$$z = \text{ReLU}(W_t z_0 + b_t), \quad (30)$$

gdzie liczba neuronów warstwy ukrytej stanowi parametr architektury `hidden_nodes`.

Na podstawie wspólnej reprezentacji z wyznaczone są wyjścia aktora i krytyka. Część aktora ma postać:

$$l = W_{a,3} \text{ReLU}(W_{a,2} \text{ReLU}(W_{a,1}z + b_{a,1}) + b_{a,2}) + b_{a,3}, \quad (31)$$

gdzie $l \in \mathbb{R}^{|A|}$ oznacza logity polityki.

Część krytyka wyznacza estymatę wartości stanu:

$$V(s) = W_{c,3} \text{ReLU}(W_{c,2} \text{ReLU}(W_{c,1}z + b_{c,1}) + b_{c,2}) + b_{c,3}, \quad (32)$$

przy czym ostatnia warstwa zwraca pojedynczą wartość skalarną.


W pokazanej implementacji interfejs sieci wymaga, aby metoda `forward` zwracała parę $(V(s), l)$, metoda `act` realizowała próbkowanie akcji z rozkładu po maskowaniu, natomiast metoda `evaluate_actions` zwracała logarytmy prawdopodobieństw wybranych akcji, wartości stanu oraz entropię rozkładu polityki.

Opis poniżej dotyczy wspólnego schematu agenta. Poszczególne warianty różnią się budową encodera przestrzennego, liczbą bloków, sposobem skalowania liczby kanałów, obecnością połączeń rezydualnych, zastosowaniem normalizacji warstwowej oraz użyciem mechanizmu Hyper-Connections.


3.11.1 Analizowane warianty architektur

W dalszej części pracy stosowane są następujące skróty nazw modeli: IN, IN-C, IR, IR-LN, IR-C, HC oraz DHC. Wszystkie warianty korzystają ze wspólnego schematu agenta typu aktor–krytyk przedstawionego na rys. 5. O ile nie zaznaczono inaczej, encoder nieprzestrzenny składa się z jednej warstwy liniowej z aktywacją ReLU, a wspólny trzon MLP ma rozmiar `hidden_nodes=256`.


1. **IN** (*Inception*) – wariant bazowy. Część przestrzenna składa się z trzech kolejnych bloków Inception z jądrami 3×3 , 5×5 oraz 7×7 , przy czym liczba kanałów rośnie wraz z głębokością modelu: (12, 8, 8), następnie (24, 16, 16), a na końcu (36, 24, 24). W gałęziach bloków stosowana jest aktywacja ReLU. Wariant ten nie zawiera połączeń rezydualnych ani mechanizmu Hyper-Connections.
2. **IN-C-LN** (*Inception Constant*) – wariant kontrolny o stałej szerokości kanałowej. Wejście przestrzenne jest najpierw rzutowane konwolucją 1×1 do stałej liczby kanałów, a następnie przetwarzane przez cztery bloki Inception o identycznej konfiguracji gałęzi (12, 8, 8). Wariant ten nie zawiera połączeń rezydualnych, ale zawiera Layer Normalization.
3. **IR** (*Inception-Residual*) – wariant z trzema blokami Inception-Residual o rosnącej liczbie kanałów, zgodnej z wariantem IN. Sygnał wejściowy jest dodawany do wyjścia bloku przez ścieżkę skrótową; gdy liczba kanałów się zmienia, w ścieżce tej stosowana jest projekcja 1×1 .
4. **IR-C** (*Inception-Residual Constant*) – Tak samo jak w przypadku IN-C-LN tutaj bloki mają stałą ilość kanałów.
5. **IR-LN** (*Inception-Residual with Layer Normalization*) – wariant analogiczny do IR, lecz z normalizacją warstw, pomiędzy blokami Inception.
6. **HC** (*Hyper-Connections*) – wariant z mechanizmem statycznych Hyper-Connections. Wejście przestrzenne jest najpierw rzutowane konwolucją 1×1 do stałej szerokości 72 kanałów, a następnie przetwarzane przez dwa bloki Inception z gałęziami (32, 16, 16, 8) i jądrami 3×3 , 5×5 , 7×7 oraz 9×9 . Mechanizm HyperConnection realizuje mieszanie informacji pomiędzy równoległymi strumieniami reprezentacji. W odróżnieniu od pozostałych wariantów zastosowano tu także większy wspólny trzon (`hidden_nodes=512`) oraz dwuwarstwowy encoder nieprzestrzenny.
7. **DHC** (*Dynamic Hyper-Connections Inception*) – wariant z dynamicznym mechanizmem Hyper-Connections. Wejście przestrzenne jest rzutowane konwolucją 1×1 do stałej szerokości 28 kanałów, a następnie przetwarzane przez cztery bloki Inception o konfiguracji (12, 8, 8). Współczynniki mieszania reprezentacji są w tym wariantcie wyznaczone dynamicznie na podstawie bieżących aktywacji, dzięki czemu model może adaptacyjnie sterować przepływem informacji pomiędzy blokami.




Rysunek 5. Wspólny schemat architektury agenta typu actor–critic stosowanej w eksperymentach. Encoder przestrzenny składa się z trzech kolejnych bloków, natomiast po fuzji cech wspólna reprezentacja jest kierowana do części aktora i krytyka.



Rysunek 6. Schemat pojedynczego bloku Inception używanego jako podstawowy moduł części przestrzennej.



Rysunek 7. Schemat bloku Inception z połączeniem rezydualnym. Wejście bloku jest łączone ze ścieżką główną przez sumowanie, a wynik trafia dalej do następnego bloku encodera.



Rysunek 8. Schemat bloku Inception z mechanizmem Hyper-Connections. Mechanizm HC stanowi część pojedynczego bloku przestrzennego i łączy wejście bloku z rdzeniem Inception oraz jego wyjściem.

Rozdział 4

Środowisko testowe

Blood Bowl to strategiczna gra planszowa łącząca elementy footballu amerykańskiego oraz gier bitewnych. Rozgrywka toczy się na planszy w formie boiska o wymiarach 26×15 pól. Dwóch graczy prowadzi przeciwne drużyny złożone z figurek (zwanych zawodnikami) i dąży do zdobycia większej liczby przyłożeń (ang. touchdown) niż przeciwnik. Mecz składa się z dwóch połówek po 8 tur dla każdego gracza. W każdej turze trener może aktywować wielu swoich zawodników, wykonując nimi szereg akcji na boisku. Do podstawowych typów akcji należą m.in.: ruch (przesunięcie zawodnika o kilka pól zależnie od jego parametru szybkości), podanie piłki, przekazanie piłki innemu zawodnikowi (ang. handoff), blok (atak na sąsiadującego przeciwnika w próbie powalenia go), blitz (połączenie ruchu i ataku), a nawet sfaulowanie leżącego przeciwnika (ang. foul). Gdy zawodnik z piłką dotrze do strefy punktowej rywala, jego drużyna zdobywa punkt. Po upływie ustalonej liczby tur mecz kończy się, a wygrywa drużyna z większą liczbą przyłożeń.

Istotnym elementem Blood Bowl jest losowość oraz wynikające z niej zarządzanie ryzykiem. Większość istotnych akcji – takich jak bloki, uniki, podania czy chwyt piłki – wymaga powodzenia testu kośćmi. Szanse zależą od atrybutów zawodników (np. Siły przy blokowaniu, Zręczności przy chwytaniu czy uniku) oraz posiadanych umiejętności specjalnych (np. Dodge, Block). Niepowodzenie testu zwykle oznacza natychmiastową utratę tury (tzw. turnover). W związku z tym trenerzy muszą rozważnie planować kolejność działań – zazwyczaj zaczynają od ruchów bezpiecznych (niewymagających rzutów lub z bardzo dużą szansą powodzenia), odkładając ryzykowne akcje na koniec tury. Gra przyznaje też ograniczoną liczbę żetonów przerzutów, które pozwalają powtórzyć nieudany rzut kością, co dodaje element decyzyjny dotyczący zarządzania zasobami szczęścia. Stan gry w Blood Bowl jest złożony i bogaty: obejmuje on nie tylko położenie wszystkich zawodników na planszy, ale również ich stan (stojący, powalony, ogłuszony itp.), posiadane atrybuty i umiejętności, stan piłki, warunki pogodowe, licznik tur, rezerwy i kontuzje graczy w drużynach, dostępne przerzuty i inne elementy. W odróżnieniu od gier takich jak Go czy szachy, reprezentacja stanu w Blood Bowl ma charakter wielowymiarowy przestrzennie oraz nieprzestrzennie, a przestrzeń akcji nie jest stała – dostępne ruchy zależą od kontekstu sytuacyjnego każdego kroku.

4.1 Blood Bowl jako benchmark dla uczenia ze wzmocnieniem.

Blood Bowl jest uważany za kolejne wielkie wyzwanie dla sztucznej inteligencji w grach planszowych njustesen.github.io. Kilka cech tej gry sprawia, że stanowi ona wartościowe środowisko testowe dla metod uczenia ze wzmocnieniem i sieci neuronowych:

1. Wysoki branching factor – Każda tura oferuje olbrzymią liczbę możliwych sekwencji ruchów. Trener może poruszać wieloma zawodnikami w dowolnej kolejności, a każdy z nich może wykonać kilka akcji. Średni współczynnik rozgałęzienia pojedynczej akcji zawodnika szacuje się na ok. 10^5 możliwych przebiegów. W rezultacie pojedyncza tura (maksymalnie 11 zawodników) może rozwidlać się nawet na rząd 10^{50} możliwych ciągów akcji. Dla porównania, w szachach średni współczynnik rozgałęzienia wynosi ok. 30, a w go ok. 300. Tak ogromna przestrzeń decyzji przekracza możliwości tradycyjnych algorytmów przeszukiwania i stanowi poważne wyzwanie dla metod RL.
2. Nieregularne drzewa decyzyjne – W Blood Bowl długość tury oraz dostępne akcje nie są z góry ustalone. Z jednej strony, lista dozwolonych ruchów w danym momencie zależy od



Rysunek 9. Plansza Blood Bowl

stanu gry (np. tylko niektórzy zawodnicy mogą wykonać określone akcje, możliwe pola ruchu są ograniczone zasięgiem, itp.), co oznacza dynamicznie zmieniającą się przestrzeń akcji. Z drugiej strony, skutek losowości tura gracza może zakończyć się wcześniej (np. nieudany rzut kończy turę), przez co drzewo rozgrywki ma zmienną głębokość gałęzi. Strukturę decyzyjną Blood Bowl można określić jako niestandardową lub zagnieżdżoną: tura składa się z serii ruchów zawodników (podtur), z których każdy z kolei bywa sekwencją kilku akcji (np. ruch przez kilka pól, a następnie blok). Taka nieregularność utrudnia zastosowanie klasycznych algorytmów planowania, które zakładają stałą liczbę ruchów na turę i jednolitą strukturę drzewa.

3. Wieloetapowy charakter rozgrywki – Blood Bowl wymaga długoterminowego planowania oraz podejmowania szeregu skorelowanych decyzji w ramach jednej tury i całego meczu. Pełna rozgrywka to kilkanaście tur na stronę, łącznie około 1600 kroków decyzyjnych według szacunków. Punkty (przyłożenia) są zdobywane rzadko – w wielu partiach pada bardzo mało goli, zwłaszcza przy losowej lub słabej grze zdarza się remis 0:0. Taka długa horyzontalnie sekwencja decyzji ze sporadyczną nagrodą (sparse reward) powoduje, że algorytmy oparte na przeszukiwaniu oraz klasyczne metody RL mają trudność z uzyskaniem sygnału uczącego. Konieczne jest więc planowanie wieloetapowe – zarówno taktyczne (w obrębie jednej tury, optymalna kolejność akcji pod ryzykiem turnover), jak i strategiczne (przez cały mecz, np. zabezpieczenie piłki, kontrola czasu gry itp.).
4. Aspekty przestrzenne gry – Gra ma wyraźny charakter przestrzenny: położenie zawodników na planszy i kontrola terytorium (strefy ataku, krycie przeciwników, droga do pola punktowego) są kluczowe dla sukcesu. Stan gry można przedstawić w formie siatki cech (mapy zajętości pól, stref wpływu, pozycji piłki, itp.), co przypomina reprezentacje stanów znane z gier takich jak StarCraft II. Równocześnie jednak Blood Bowl posiada elementy symboliczne i atrybutowe (cechy postaci, liczniki, efekty), których nie da się ująć wyłącznie na obrazowej planszy. Ta kombinacja informacji przestrzennej i nieprzestrzennej wymaga od agentów uczenia się zarówno rozumienia układów geometrycznych na polu gry, jak i śledzenia zmiennych nienumerycznych (punkty, przerzuty, statusy). Stanowi to dobre pole do badań nad połączeniem sieci konwolucyjnych służących do przetwarzania map cech z sieciami gęstymi lub mechanizmami uwagi, analogicznie do podejść stosowanych w środowisku StarCraft II Learning Environment (SC2LE) [35].

4.2 Środowisko BotBowl

W celu badania opisanych wyżej zagadnień, stworzono BotBowl – otwartoźródłowe środowisko symulujące pełne zasady Blood Bowl, znane też jako Fantasy Football AI (FFAI). Platforma ta dostarcza szereg funkcjonalności wspierających efektywne szkolenie agentów sztucznej inteligencji.

BotBowl udostępnia interfejs zgodny z popularnym schematem OpenAI Gym, co ułatwia integrację z istniejącymi algorytmami RL. Środowisko zostało zaimplementowane w języku Python, dzięki

czemu można bezpośrednio korzystać z bibliotek uczenia maszynowego, a sam interfejs obejmuje standardowe metody jak `reset()` (inicjalizacja nowej gry) oraz `step(akcja)` (wykonanie kroku).

Framework BotBowl umożliwia łatwe tworzenie i włączenie własnych agentów. Udostępniane jest API wysokiego poziomu: wystarczy zaimplementować klasę bota dziedziczącą po abstrakcyjnej klasie `Agent` (z metodami m.in. `act()` definiującą decyzje na podstawie stanu gry). Następnie takiego bota można zarejestrować w systemie pod unikalną nazwą i używać go w symulacjach lub turniejach. BotBowl zawiera też przykładowe zaimplementowane boty (np. losowy `RandomBot`, heurystyczny `GrodBot`) mogące służyć jako punkt wyjścia lub przeciwnicy do testów.

Środowisko pozwala na resetowanie stanu gry oraz rozgrywanie meczów między wybranymi agentami w trybie symulowanym bez interakcji użytkownika. Możliwe jest również równoległe uruchamianie wielu instancji gry (`multi-env`) w celu przyspieszenia treningu. Dodatkowo BotBowl zawiera forward model (silnik przewidywania następstw akcji), co umożliwia zastosowanie metod planowania czy przeszukiwania drzewa gry (np. MCTS (ang. *Monte Carlo tree search*)) obok czystego RL. Wbudowane funkcje turniejowe pozwalają automatycznie rozegrać serię gier między botami, kontrolując limity czasu na turę oraz wykrywając ewentualne zawieszenia lub awarie agentów (co jest istotne przy treningu i testowaniu na szeroką skalę).

Stan rozgrywki zwracany przez środowisko jest podzielony na część przestrzenną i nieprzestrzenną. Część przestrzenna to tensor wymiaru (L, H, W) , gdzie $H \times W$ odpowiada polu gry (wraz z ewentualnymi obrzeżami), zaś L to liczba warstw cech. Domyślnie dostarczanych jest kilkadziesiąt warstw, m.in. zajętość pola przez zawodników, strefy ataku, pozycja piłki, pola dostępne do ruchu, prawdopodobieństwa powodzenia rzutów itp. . Część nieprzestrzenna to wektor liczbowy zawierający inne informacje o stanie gry – np. liczba tur, punkty, pozostałe przerzuty obu drużyn, aktualna faza/procedura gry – a także wskazania, które typy akcji są obecnie dostępne. Co ważne, BotBowl dostarcza również maskę dozwolonych akcji, dzięki czemu agent otrzymuje informację, które konkretne akcje (z ogromnej puli wszystkich możliwych) są w danym momencie legalne. Przestrzeń wszystkich potencjalnych akcji jest bowiem bardzo duża – rzędu tysięcy możliwych kodowanych decyzji – jednak w danej sytuacji tylko niewielki podzbiór ruchów wchodzi w grę. Maskę (oraz alternatywnie struktura danych `game.state.available_actions`) pozwala ograniczyć wybór do ruchów legalnych, co znacznie ułatwia trenowanie modelu i konwergencję algorytmów RL.

Podsumowując, Blood Bowl dostarcza unikalne, wymagające środowisko o wysokiej złożoności, które dzięki platformie BotBowl jest dostępne do eksperymentów z algorytmami uczenia ze wzmocnieniem. Połączenie czynników takich jak ogromny współczynnik rozgałęzienia, losowość i wieloetapowość decyzji oraz potrzeba percepcji przestrzennej czyni z niego atrakcyjny poligon doświadczalny dla nowoczesnych metod AI. BotBowl zapewnia zaś odpowiednie narzędzia – od interfejsu Gym, poprzez bogatą reprezentację stanów i mechanizmy ułatwiające implementację własnych agentów, aż po możliwość symulacji gier na masową skalę – aby skutecznie trenować i testować modele uczące się gry w Blood Bowl [16].

4.3 Przegląd najlepszych rozwiązań w środowisku BotBowl

Poniżej przedstawiono zestawienie rozwiązań osiągających najlepsze wyniki w kolejnych edycjach konkursu BotBowl. Wyróżniono osobno zwycięzców całych edycji konkursu oraz najwyższej sklasyfikowane rozwiązania wykorzystujące uczenie maszynowe, ponieważ w BotBowl najlepsze wyniki ogólne nie zawsze były uzyskiwane przez modele uczone.

Tabela 2. Zwycięskie modele BotBowl

Edycja	Bot	Podejście
Bot Bowl I	GrodBot	reguły eksperckie
Bot Bowl II	Minigrod	reguły eksperckie
Bot Bowl III	MimicBot	imitation learning + RL
Bot Bowl IV	Drefsante AI	bot ekspercki / heurystyczny
Bot Bowl V	Drefsante AI	bot ekspercki / heurystyczny

Tabela 3. Najlepsze rozwiązania wykorzystujące uczenie maszynowe w kolejnych edycjach BotBowl

Edycja	Bot	Podejście	Wynik / rola
Bot Bowl I	NO ONE	A2C, self-play, reward shaping	3. miejsce
Bot Bowl II	Gotebot	A2C, self-play, curriculum learning	4. miejsce
Bot Bowl III	MimicBot	imitation learning + RL	1. miejsce, nagroda ML
Bot Bowl IV	MotBot	uczenie maszynowe	2. miejsce
Bot Bowl V	Treeman	uczenie maszynowe / techniki ML lub search	3. miejsce

Na podstawie tabeli 2 można zauważyć, że w kolejnych edycjach konkursu BotBowl dominowały przede wszystkim rozwiązania oparte na wiedzy dziedzinowej, regułach eksperckich lub podejściach hybrydowych. W pierwszej edycji zwyciężył GrodBot, natomiast w Bot Bowl II najlepszy okazał się Minigrod. Oba boty wykorzystywały podejście skryptowe, oparte na ręcznie zaprojektowanych regułach gry [3, 4]. Oznacza to, że we wczesnym etapie rozwoju BotBowl najwyższą skuteczność osiągały przede wszystkim rozwiązania korzystające z wiedzy eksperckiej, a nie modele uczone wyłącznie na podstawie interakcji ze środowiskiem.

Przełomowym przypadkiem był MimicBot, który zwyciężył w Bot Bowl III. Jak pokazano w tabeli 2, był to bot wykorzystujący połączenie uczenia przez naśladowanie oraz uczenia ze wzmocnieniem [5, 26]. MimicBot stanowił więc przykład rozwiązania hybrydowego, w którym proces uczenia nie rozpoczynał się od całkowicie losowej polityki, lecz był wspierany przez imitation learning. Takie podejście pozwalało ograniczyć problem niskiej efektywności próbkowania, szczególnie istotny w środowisku Blood Bowl, gdzie wartościowy sygnał nagrody pojawia się rzadko, a przestrzeń możliwych decyzji jest bardzo duża [26].

W kolejnych edycjach konkursu ponownie bardzo silną pozycję zajęły boty eksperckie i heurystyczne. W Bot Bowl IV oraz Bot Bowl V zwyciężył Drefsante AI, co potwierdza, że najlepsze wyniki

konkursowe nadal mogły być osiągnane przez rozwiązania silnie wykorzystujące wiedzę dziedzinową [6, 7]. Nie oznacza to jednak braku postępu metod uczonych. Jak pokazano w tabeli 3, w każdej edycji pojawiały się również boty wykorzystujące uczenie maszynowe, które osiągały coraz lepsze wyniki względem całej stawki konkursowej.

Szczególnie istotne są wyniki zestawione w tabeli 3. W Bot Bowl I najlepszy bot wykorzystujący uczenie maszynowe, NO ONE, zajął 3. miejsce, stosując A2C, self-play oraz reward shaping [3]. W Bot Bowl II Gotebot, oparty na A2C, self-play i curriculum learning, zajął 4. miejsce [4]. W Bot Bowl III MimicBot nie tylko otrzymał nagrodę ML, ale także wygrał cały konkurs [5, 26]. W Bot Bowl IV MotBot zajął 2. miejsce, a w Bot Bowl V Treeman zajął 3. miejsce [6, 7]. Wyniki te wskazują, że rozwiązania uczone stopniowo osiągały coraz bardziej konkurencyjny poziom, choć często miały charakter hybrydowy i nie polegały wyłącznie na klasycznym uczeniu ze wzmocnieniem od zera.

Zestawienie tabel 2 oraz 3 pokazuje więc istotną zależność: state-of-the-art w BotBowl należy rozpatrywać w dwóch wymiarach. Pierwszym jest ogólna skuteczność konkursowa, w której bardzo mocne pozostają boty skryptowe, eksperckie i heurystyczne. Drugim jest rozwój metod wykorzystujących uczenie maszynowe, w których szczególne znaczenie mają techniki zwiększające efektywność próbkowania, takie jak imitation learning, self-play, curriculum learning oraz reward shaping. Na tym tle niniejsza praca nie stanowi próby zbudowania bota przewyższającego najlepsze rozwiązania konkursowe w pełnym środowisku BotBowl, lecz koncentruje się na porównaniu architektur sieci neuronowych uczonych metodami actor-critic w kontrolowanym wariancie środowiska.

Rozdział 5

Eksperymenty

Niniejszy rozdział omawia eksperymenty przeprowadzone w środowisku BotBowl, których celem było porównanie skuteczności architektur sieci neuronowych opisanych w rozdziale 3.11. Analizie poddano siedem wariantów modeli: IN, IN-C-LN, IR, IR-C, IR-LN, HC oraz DHC. Wszystkie porównywane modele zachowują wspólny schemat agenta typu actor-critic, różniąc się przede wszystkim budową encodera przestrzennego, liczbą bloków, sposobem skalowania liczby kanałów, obecnością połączeń rezydualnych, zastosowaniem normalizacji warstwowej oraz wykorzystaniem mechanizmu hyper-connections.

W celu końcowej oceny jakości wytrenowanych agentów przeprowadzono turniej ligowy obejmujący wszystkie analizowane modele oraz boty referencyjne. Rozgrywki zorganizowano w formule „każdy z każdym”, co oznacza, że każda para uczestników rozegrała pomiędzy sobą po 10 meczów. Za zwycięstwo przyznawano 3 punkty, za remis 1 punkt, natomiast za porażkę 0 punktów. Taka forma ewaluacji pozwoliła ograniczyć wpływ pojedynczych losowych przebiegów meczu i uzyskać bardziej wiarygodną ocenę rzeczywistej skuteczności poszczególnych agentów.

W tabelach 5 oraz 7 wyników bezpośrednich każda komórka przedstawia rezultat rywalizacji modelu z danego wiersza z modelem z danej kolumny. Pierwsza linia zapisu ma postać Z-R-P i oznacza odpowiednio liczbę zwycięstw, remisów oraz porażek modelu z wiersza. Druga linia przedstawia bilans przyłożeń w formacie przyłożenia zdobyte : przyłożenia stracone. Znak „-” na przekątnej oznacza, że dany model nie rozgrywał meczu sam ze sobą.

Do porównania włączono również dwa boty referencyjne, pełniące funkcję modeli kontrolnych. *RandomBot* stanowił dolny punkt odniesienia, ponieważ wybierał akcje w sposób losowy w granicach działań dopuszczalnych przez środowisko. Z kolei *Dreftsante AI v.0.7* pełnił rolę silniejszego bota porównawczego, pozwalającego ocenić, w jakim stopniu wytrenowane sieci są w stanie zbliżyć się do poziomu bardziej zaawansowanego, klasycznego bota heurystycznego. Uwzględnienie obu tych botów umożliwiło osadzenie wyników badanych architektur pomiędzy bardzo prostym punktem odniesienia a przeciwnikiem reprezentującym wyższy poziom trudności, co ułatwia interpretację uzyskanych rezultatów.

Ze względu na ograniczenia zasobów obliczeniowych oraz czasu eksperymenty przeprowadzono w środowisku z 3 zawodnikami na planszy o rozmiarze 12x5 zamiast w wersji klasycznej. Wytrenowanie pojedynczej sieci do poziomu umożliwiającego podstawową grę zajmowało około 1,5 godziny nawet w tak zmniejszonym środowisku, podczas gdy dla pełnowymiarowej planszy czas ten można szacować na około tydzień. Należy również zaznaczyć, że bot Drefsante był projektowany z myślą o grze na planszy o pełnym rozmiarze, dlatego w zastosowanym wariantcie środowiska działał poza swoim docelowym ustawieniem. Mimo to jego obecność w lidze stanowiła wartościowy punkt odniesienia.

Do oceny jakości badanych modeli wykorzystano dwa uzupełniające się zestawy metryk. W analizie procesu uczenia uwzględniono przede wszystkim *win rate*, czyli odsetek zwycięstw osiąganych podczas ewaluacji, oraz średnią *reward*, opisującą zmianę łącznej nagrody uzyskiwanej przez agenta w trakcie treningu. W ocenie końcowej, przeprowadzonej w formie turnieju ligowego, analizowano liczbę zwycięstw, remisów i porażek, łączną liczbę punktów oraz bilans przyłożeń zapisany w postaci *Prz.*. Taki zestaw miar pozwalał ocenić zarówno przebieg uczenia, jak i skuteczność modeli w bezpośredniej rywalizacji.

Tabela 4. Końcowa tabela rankingowa modeli z turnieju

Miejsce	Model	Alg.	Zwyc.	Rem.	Por.	Punkty	Prz.
1	Inception-Residual Constant	A2C	80	12	28	252	367:184
2	Inception-Residual	A2C	78	14	28	248	343:191
3	Inception	A2C	78	13	29	247	370:225
4	Drefsante AI v.0.7	bot	76	18	26	246	264:104
5	HC	A2C	73	18	29	237	311:184
6	Dynamic HC	A2C	72	12	36	228	318:183
7	Inception	PPO	70	15	35	225	322:212
8	Dynamic HC	PPO	48	19	53	163	208:219
9	Inception-Residual	PPO	44	20	56	152	203:254
10	HC	PPO	44	12	64	144	156:237
11	Inception Constant with Layer Normalization	A2C	0	31	89	31	0:276
12	RandomBot	bot	0	28	92	28	0:294
13	Inception-Residual with Layer Normalization	A2C	0	22	98	22	0:299

Tabela 5. Wyniki meczów bezpośrednich pomiędzy modelami z turnieju

	IR-LN A2C	Random Bot	IN-C-LN A2C	HC PPO	IR PPO	DHC PPO	IN PPO	DHC A2C	HC A2C	Drefsante bot	IN A2C	IR A2C	IR-C A2C
IR-C A2C	10-0-0 35:0	10-0-0 37:0	10-0-0 40:0	7-0-3 27:10	6-2-2 35:16	7-0-3 27:18	5-2-3 31:28	5-3-2 29:18	6-3-1 29:20	6-0-4 17:18	3-1-6 27:29	5-1-4 33:27	–
IR A2C	10-0-0 38:0	10-0-0 31:0	9-1-0 28:0	9-0-1 28:8	9-0-1 37:13	5-1-4 23:24	3-5-2 31:26	5-0-5 24:24	5-3-2 23:21	3-1-6 18:20	6-2-2 35:22	–	
IN A2C	10-0-0 29:0	10-0-0 38:0	10-0-0 38:0	8-0-2 34:16	6-3-1 33:17	8-2-0 36:15	6-0-4 37:25	6-0-4 31:28	4-2-4 33:30	2-3-5 10:32	–		
Drefsante bot	10-0-0 31:0	7-3-0 18:0	8-2-0 27:0	6-2-2 18:6	7-2-1 28:5	5-3-2 15:7	6-1-3 19:20	6-1-3 15:11	6-0-4 23:10	–			
HC A2C	10-0-0 35:0	10-0-0 31:0	10-0-0 29:0	9-0-1 34:13	7-3-0 27:10	5-3-2 23:14	6-1-3 28:17	5-3-2 23:22	–				
DHC A2C	9-1-0 28:0	9-1-0 35:0	9-1-0 34:0	10-0-0 34:8	8-1-1 30:10	8-0-2 31:15	3-1-6 23:28	–					
IN PPO	10-0-0 35:0	10-0-0 39:0	10-0-0 28:0	9-1-0 31:10	5-1-4 21:20	5-3-2 24:13	–						
DHC PPO	9-1-0 22:0	8-2-0 22:0	8-2-0 18:0	4-1-5 17:17	4-1-5 23:23	–							
IR PPO	10-0-0 24:0	9-1-0 27:0	8-2-0 24:0	2-4-4 14:20	–								
HC PPO	10-0-0 22:0	9-1-0 16:0	7-3-0 10:0	–									
IN-C-LN A2C	0-10-0 0:0	0-10-0 0:0	–										
Random Bot	0-10-0 0:0	–											
IR-LN A2C	–												

Na podstawie tabeli 4 można stwierdzić, że jedynymi architekturami, które nie wykształciły skutecznej polityki, były warianty wykorzystujące *Layer Normalization*. Obydwa modele zakończyły turniej bez ani jednego zwycięstwa, uzyskując odpowiednio 31 i 22 punkty wyłącznie dzięki remisom, przy bardzo słabych bilansach przyłożeń 0:276 oraz 0:299. Dla porównania wszystkie pozostałe sieci osiągnęły co najmniej kilkadziesiąt zwycięstw. Wyniki te wskazują, że polityka tych modeli była zbliżona do zachowania losowego, co potwierdza również fakt, że *RandomBot* zdobył porównywalną liczbę punktów, równą 28. Oznacza to, że w badanej konfiguracji *Layer Normalization* nie poprawiła procesu uczenia, lecz wyraźnie obniżyła skuteczność agentów.

Źródłem tego zjawiska mogła być niekorzystna zmiana charakterystyki aktywacji w całej sieci. *Layer Normalization* normalizuje aktywacje niezależnie dla każdej próbki, przez co zmienia ich skalę i rozkład na każdym etapie przetwarzania. W rozpatrywanym zadaniu mogło to prowadzić do

osłabienia informacji zakodowanej w bezwzględnych wartościach aktywacji, nadmiernego wygładzenia reprezentacji oraz niekorzystnej interakcji z połączeniami rezydualnymi. Możliwe jest również, że ta technika wymagała innego doboru hiperparametrów niż warianty bez normalizacji. Niezależnie od dokładnej przyczyny wyniki jednoznacznie pokazują, że w badanej konfiguracji *Layer Normalization* okazała się rozwiązaniem niekorzystnym.


Zestawienie wyników z tabeli 4 prowadzi do jednoznacznego wniosku: w badanej konfiguracji algorytm uczący PPO był mniej skuteczny od A2C dla każdej porównywanej architektury. Wariant *Inception* osiągnął przy uczeniu A2C 247 punktów, podczas gdy jego odpowiednik PPO uzyskał 225 punktów. Jeszcze większa rozbieżność wystąpiła dla architektury *Inception-Residual*, która zdobyła 248 punktów w wersji A2C i 152 punkty w wersji PPO, a także dla modeli *HC* oraz *Dynamic HC*, gdzie wyniki A2C wyniosły odpowiednio 237 i 228 punktów, wobec 144 i 163 punktów dla PPO. Jedynym wyjątkiem są wcześniej omówienie sieci z *Layer Normalization*.

Przewaga A2C nad PPO zapewne wynika z charakteru badanego środowiska oraz przyjętej konfiguracji treningu. Mechanizm *clippingu* w PPO ogranicza tempo zmian polityki, co zwykle stabilizuje uczenie, lecz jednocześnie może spowalniać proces optymalizacji polityki. Dodatkowo PPO jest bardziej wrażliwe na dobór hiperparametrów, takich jak współczynnik uczenia, liczba epok optymalizacji, wartość parametru w mechanizmie *clippingu* czy siła bonusu entropijnego. Ponieważ w pracy przyjęto możliwie ujednoliconą konfigurację badawczą, mogła ona sprzyjać A2C bardziej niż PPO. Znaczenie miał również ograniczony budżet obliczeniowy: A2C aktualizuje parametry na podstawie świeżo zebranych rolloutów, podczas gdy PPO wykonuje kilka kroków optymalizacji na tej samej paczce danych. W krótkim treningu prostszy schemat A2C mógł więc lepiej dopasować się do badanego środowiska.

Po wyłączeniu z analizy wariantów wykorzystujących *Layer Normalization*, na podstawie tabeli 4 można zauważyć, że w grupie modeli uczonych algorytmem A2C najwyższą skuteczność osiągnęły architektury oparte na połączeniach rezydualnych. Najlepszy wynik końcowy uzyskał model *Inception-Residual Constant A2C*, który zdobył 252 punkty przy bilansie 80 zwycięstw, 12 remisów i 28 porażek oraz stosunku przyłożeń 367:184. Bezpośrednio za nim uplasował się *Inception-Residual A2C* z 248 punktami i bilansem 343:191, natomiast trzecie miejsce zajął bazowy *Inception A2C*, który zdobył 247 punktów, a zarazem osiągnął najwyższą liczbę zdobytych przyłożeń w tej grupie, równą 370, przy wyraźnie słabszym bilansie defensywnym 370:225. Słabiej od tych trzech wariantów wypadły architektury wykorzystujące *Hyper-Connections*: *HC A2C* uzyskał 237 punktów, a *Dynamic HC A2C* 228 punktów. Oznacza to, że w badanej konfiguracji A2C najlepiej współpracowało z architekturami rezydualnymi, natomiast dodanie mechanizmu *Hyper-Connections* nie poprawiło wyników względem prostszych wariantów.

Wyniki meczów bezpośrednich przedstawione w tabeli 5 doprecyzowują ten obraz. *Inception-Residual Constant A2C* okazał się lepszy od *Inception-Residual A2C* (5–1–4), od *HC A2C* (6–3–1) oraz od *Dynamic HC A2C* (5–3–2), co potwierdza jego przewagę w obrębie modeli A2C. Z kolei *Inception-Residual A2C* wygrał z *Inception A2C* (6–2–2) i z *HC A2C* (5–3–2), ale zremisował bilans zwycięstw i porażek z *Dynamic HC A2C* (5–0–5). Interesujący jest przypadek modelu *Inception A2C*,

który mimo trzeciego miejsca w klasyfikacji ogólnej bezpośrednio pokonał *Dynamic HC A2C* (6–0–4), lecz nie uzyskał przewagi nad *HC A2C* (4–2–4). Wskazuje to, że o końcowej pozycji w lidze decydowała nie tylko siła w pojedynkach z najbliższymi konkurentami, ale również większa stabilność wyników przeciwko całemu przekrojowi przeciwników.



Rysunek 10. Win rate i reward w zależności od liczby kroków.

Na podstawie rysunku 10 można zauważyć, że modele uczone algorytmem A2C cechowały się zbliżoną dynamiką uczenia. Przez długi czas utrzymywały niski współczynnik zwycięstw, po czym w podobnym momencie treningu następował gwałtowny wzrost skuteczności. Oznacza to, że w A2C poprawa polityki miała charakter skokowy. Potwierdza to również dolny wykres na rysunek 10, na którym nagroda po okresie powolnych zmian zaczynała rosnąć znacznie szybciej.

Na podstawie rysunku 10 można również zauważyć, że w przypadku PPO zależność od architektury była znacznie silniejsza. Poszczególne modele zaczynały wygrywać w wyrażnie różnych momentach, a ich przebiegi były bardziej zróżnicowane i mniej jednorodne. Wzrost skuteczności miał tu zwykle charakter stopniowy, często z okresowymi wahaniami, a nie nagły jak w A2C. Oznacza to, że PPO prowadziło do bardziej rozciągniętego w czasie doskonalenia polityki, natomiast A2C częściej dawało efekt nagłego przejścia od gry słabej do wyrażnie skuteczniejszej.

Hiperparametry uczenia dobrano tak, aby porównanie modeli dotyczyło przede wszystkim wpływu zastosowanej architektury oraz algorytmu uczenia. Wszystkie warianty trenowano w środowisku

BotBowl o rozmiarze 3, z wykorzystaniem 8 równoległych instancji środowiska. Każde uczenie obejmowało 5 000 000 kroków środowiska, a optymalizację prowadzono algorytmem Adam ze współczynnikiem uczenia równym $3 \cdot 10^{-4}$. W obu metodach zastosowano współczynnik dyskontowania $\gamma = 0,99$, współczynnik regularyzacji entropii równy 0,01, wagę funkcji straty krytyka równą 0,5 oraz ograniczenie normy gradientu do 0,5. Dla A2C długość rollout'u wynosiła 20 kroków, co przy 8 środowiskach dawało 160 próbek na jedną aktualizację. W przypadku PPO zastosowano rollout o długości 64 kroków, parametr GAE $\gamma = 0,95$, zakres obcinania ilorazu prawdopodobieństw $\tau = 0,2$, 2 epoki optymalizacji oraz podział danych na 4 minibatch'e. Dzięki temu PPO wykonywało bardziej rozbudowaną aktualizację na większej porcji doświadczeń, natomiast A2C aktualizowało politykę częściej, ale na krótszych fragmentach trajektorii.

Kod źródłowy wykorzystany w pracy został udostępniony w publicznym repozytorium.¹

5.1 Wyniki w pełnej skali

Uczenie w pełnej skali wymaga większych zasobów i dłuższego czasu treningu niż eksperymenty w środowisku zredukowanym. Z tego powodu dalsze testy przeprowadzono tylko dla jednej architektury. Wybrano wariant Dynamic Hyper-Connections (DHC), ponieważ większa plansza i większa liczba zawodników mogły lepiej wykorzystać mechanizm dynamicznego mieszania reprezentacji.

W eksperymencie pełnoskalowym zastosowano rozbudowany wariant DHC. W porównaniu z modelem użytym w środowisku zredukowanym zwiększono szerokość reprezentacji przestrzennej z 28 do 64 kanałów, zastosowano konwolucję wejściową 1×1 , normalizację ChannelManifoldNorm, bias pozycyjny planszy oraz bramkowane połączenia rezydualne. Część przestrzenna składała się z czterech bloków ManifoldInceptionBlock w dynamicznym stosie Hyper-Connections z parametrem $\text{rate} = 3$. Zmiany te miały zwiększyć pojemność modelu i lepiej dopasować go do pełniejszej reprezentacji gry.

Proces uczenia podzielono na dwa etapy. Najpierw zastosowano 24-godzinne uczenie przez naśladowanie, w którym ekspertem był Drefsante AI v.0.7. Celem tego etapu było uzyskanie polityki lepszej od losowej. Następnie model trenowano metodą A2C, rozgrywając mecze przeciwko Drefsante AI v.0.7.

W tabeli 6 zestawiono wyniki turnieju dla kolejnych wersji modelu. Wariant *DHC after imitation* oznacza model po etapie uczenia przez naśladowanie, *DHC best* oznacza najlepszy zapis uzyskany podczas dalszego treningu, a *DHC final* oznacza model końcowy.

¹<https://github.com/greenhoody/Magisterka>

Tabela 6. Końcowa tabela rankingowa modeli z turnieju po uczeniu przez naśladowanie

Miejsce	Model	Alg.	Zwyc.	Rem.	Por.	Punkty	Prz.
1	Drefsante AI v.0.7	bot	40	0	0	120	210:0
2	DHC after imitation	A2C	18	11	11	65	31:49
3	DHC best	A2C	15	12	13	57	29:58
4	RandomBot	bot	0	18	22	18	0:78
5	DHC final	A2C	0	13	27	13	0:85

Na podstawie tabeli 6 można stwierdzić, że najlepszy wynik spośród modeli DHC osiągnął wariant po uczeniu przez naśladowanie. Zdobył on 65 punktów, przy bilansie 18 zwycięstw, 11 remisów i 11 porażek. Wariant *DHC best* uzyskał 57 punktów, natomiast model końcowy zdobył tylko 13 punktów i nie wygrał żadnego meczu. Oznacza to, że dalsze uczenie ze wzmocnieniem nie poprawiło polityki uzyskanej po etapie naśladowania.

Możliwą przyczyną pogorszenia wyników była zbyt duża różnica poziomu między uczonym modelem a Drefsante AI v.0.7. Agent często znajdował się w sytuacjach przegranych i defensywnych, przez co zbierał mało użytecznych danych do poprawy gry ofensywnej. W efekcie dalszy trening mógł osłabić wcześniej wyuczoną politykę.

Tabela 7. Wyniki meczów bezpośrednich pomiędzy modelami po uczeniu przez naśladowanie

	DHC final A2C	Random Bot	DHC best A2C	DHC after imitation	Drefsante bot
Drefsante bot	10-0-0 55:0	10-0-0 58:0	10-0-0 52:0	10-0-0 45:0	—
DHC after imitation	8-2-0 14:0	7-3-0 11:0	3-6-1 6:4	—	
DHC best A2C	9-1-0 16:0	5-5-0 9:0	—		
Random Bot	0-10-0 0:0	—			
DHC final A2C	—				

Wyniki bezpośrednie z tabeli 7 potwierdzają tę zależność. Drefsante AI v.0.7 wygrał wszystkie mecze i nie stracił żadnego przyłożenia. Model *DHC after imitation* był najlepszy spośród modeli uczonych: pokonał *DHC final* wynikiem 8–2–0, RandomBota wynikiem 7–3–0 oraz uzyskał dodatni

bilans z *DHC best* wynikiem 3–6–1. Wyniki te wskazują, że uczenie przez naśladowanie poprawiło punkt startowy polityki, ale dalszy trening przeciwko znacznie silniejszemu przeciwnikowi okazał się nieskuteczny.

5.2 Ograniczenia wykorzystania rozwiązań referencyjnych

Rozwiązania referencyjne Minigrod oraz GrodBot okazały się trudne do wykorzystania w procesie uczenia i ewaluacji. Boty te zostały przygotowane z myślą o starszej wersji frameworku BotBowl, przez co w obecnej wersji środowiska wielokrotnie próbowały wykonywać akcje niedozwolone lub niezgodne z aktualnym interfejsem. Ich poprawne uruchomienie wymagałoby przygotowania dodatkowej warstwy pośredniej, odpowiedzialnej za modyfikację stanu gry lub tłumaczenie decyzji bota na aktualny format akcji. Wprowadzenie takiego mechanizmu zaburzyło porównywalność wyników, przez ograniczenie ich umiejętności. Dlatego boty Minigrod oraz GrodBot nie zostały uwzględnione w końcowym zestawieniu eksperymentalnym.

Rozdział 6

Podsumowanie

Celem pracy było porównanie wybranych architektur sieci neuronowych uczonych metodami uczenia ze wzmocnieniem w środowisku BotBowl. Szczególną uwagę poświęcono części sieci odpowiedzialnej za analizę danych przestrzennych, ponieważ w grze Blood Bowl układ zawodników, piłki i stref zagrożenia ma kluczowe znaczenie dla podejmowania decyzji.

Przeprowadzone eksperymenty pokazały, że na skuteczność agenta wpływa zarówno zastosowany algorytm uczenia, jak i architektura sieci. Najlepsze wyniki osiągnęły modele wykorzystujące połączenia rezydualne, co wskazuje na znaczenie stabilnego przepływu informacji i gradientu. Jednocześnie bardziej złożone rozwiązania nie zawsze dawały lepsze rezultaty. Warianty z Hyper-Connections uzyskały słabsze wyniki, a modele z Layer Normalization nie nauczyły się skutecznej polityki. Oznacza to, że w badanym środowisku ważniejszy od samej złożoności modelu był właściwy dobór architektury.

Ograniczeniem badań był zmniejszony rozmiar środowiska. Pozwoliło to porównać wiele modeli w rozsądnym czasie, ale utrudnia bezpośrednie przeniesienie wniosków na pełną wersję gry. Należy również pamiętać, że uczenie ze wzmocnieniem jest wrażliwe na losowość, dlatego pojedyncze treningi nie zawsze wystarczają do pełnej oceny stabilności modeli.

Dalsze badania powinny objąć trzy kierunki. Po pierwsze, warto powtórzyć eksperymenty w większych wariantach środowiska BotBowl, na przykład dla rozmiaru 5, 7 oraz pełnej planszy. Po drugie, należy wykonać kilka niezależnych treningów dla każdej konfiguracji, z różnymi ziarnami losowymi, a następnie porównać średnie wyniki, odchylenia standardowe oraz pozycje w tabeli 4. Po trzecie, warto zbadać wpływ hiperparametrów, takich jak współczynnik uczenia, liczba kroków między aktualizacjami, współczynnik entropii, parametr γ oraz długość rolloutów. Pozwoliłoby to lepiej określić, czy o wyniku decyduje głównie architektura sieci, czy sposób jej uczenia.

Uzyskane wyniki pokazują, że BotBowl jest wartościowym środowiskiem do testowania metod uczenia ze wzmocnieniem. Praca potwierdza, że dobór architektury sieci ma istotny wpływ na jakość uczonej polityki, szczególnie w zadaniach o dużej przestrzeni decyzji.

Bibliografia

- [1] Ba, J. L., Kiros, J. R. i Hinton, G. E., *Layer Normalization*, 2016. doi: 10.48550/arXiv.1607.06450. arXiv: 1607.06450 [stat.ML]. adr.: <https://arxiv.org/abs/1607.06450>.
- [2] Bishop, C. M., *Pattern Recognition and Machine Learning*. New York: Springer, 2006, isbn: 978-0-387-31073-2. doi: 10.1007/978-0-387-45528-0.
- [3] Bot Bowl, *Bot Bowl I*, 2019. term. wiz. 29 kw. 2026. adr.: <https://njustesen.github.io/botbowl/bot-bowl-i>.
- [4] Bot Bowl, *Bot Bowl II*, 2020. term. wiz. 29 kw. 2026. adr.: <https://njustesen.github.io/botbowl/bot-bowl-ii.html>.
- [5] Bot Bowl, *Bot Bowl III*, 2021. term. wiz. 29 kw. 2026. adr.: <https://njustesen.github.io/botbowl/bot-bowl-iii.html>.
- [6] Bot Bowl, *Bot Bowl IV*, 2022. term. wiz. 29 kw. 2026. adr.: <https://njustesen.github.io/botbowl/bot-bowl-iv.html>.
- [7] Bot Bowl, *Bot Bowl V*, 2023. term. wiz. 29 kw. 2026. adr.: <https://njustesen.github.io/botbowl/bot-bowl-v.html>.
- [8] Cybenko, G., „Approximation by superpositions of a sigmoidal function”, *Mathematics of Control, Signals and Systems*, t. 2, nr. 4, s. 303–314, grud. 1989, issn: 1435-568X. doi: 10.1007/BF02551274. adr.: <https://doi.org/10.1007/BF02551274>.
- [9] Dai, Z. i Heckel, R., *Channel Normalization in Convolutional Neural Network avoids Vanishing Gradients*, lip. 2019. doi: 10.48550/arXiv.1907.09539.
- [10] Goodfellow, I., Bengio, Y. i Courville, A., *Deep Learning*. MIT Press, 2016. doi: 10.5555/3086952. adr.: <http://www.deeplearningbook.org>.
- [11] Goodfellow, I. J. i in., *Generative Adversarial Networks*, 2014. doi: 10.48550/arXiv.1406.2661. arXiv: 1406.2661 [stat.ML]. adr.: <https://arxiv.org/abs/1406.2661>.
- [12] He, K., Zhang, X., Ren, S. i Sun, J., *Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification*, 2015. doi: 10.1109/ICCV.2015.123. arXiv: 1502.01852 [cs.CV]. adr.: <https://arxiv.org/abs/1502.01852>.
- [13] Hinton, G., Srivastava, N. i Swersky, K., „Neural networks for machine learning lecture 6a overview of mini-batch gradient descent”, *Cited on*, t. 14, nr. 8, s. 2, 2012.

- [14] Hornik, K., Stinchcombe, M. i White, H., „Multilayer feedforward networks are universal approximators”, *Neural Networks*, t. 2, nr. 5, s. 359–366, 1989, issn: 0893-6080. doi: 10.1016/0893-6080(89)90020-8. adr.: <https://www.sciencedirect.com/science/article/pii/0893608089900208>.
- [15] Ioffe, S. i Szegedy, C., „Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift”, w *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 2015, s. 448–456. doi: 10.5555/3045118.3045167.
- [16] Justesen, N., *Bot Bowl Documentation*. term. wiz. 24 mar. 2026. adr.: <https://njustesen.github.io/botbowl/>.
- [17] Kingma, D. P. i Ba, J., „Adam: A Method for Stochastic Optimization”, *International Conference on Learning Representations (ICLR)*, 2015. doi: 10.48550/arXiv.1412.6980. arXiv: 1412.6980 [cs.LG]. adr.: <https://arxiv.org/abs/1412.6980>.
- [18] Kohonen, T., „The self-organizing map”, *Proceedings of the IEEE*, t. 78, nr. 9, s. 1464–1480, 1990. doi: 10.1109/5.58325.
- [19] LeCun, Y., Bottou, L., Bengio, Y. i Haffner, P., „Gradient-based learning applied to document recognition”, *Proceedings of the IEEE*, t. 86, nr. 11, s. 2278–2324, 1998. doi: 10.1109/5.726791.
- [20] McCulloch, W. S. i Pitts, W., „A logical calculus of the ideas immanent in nervous activity”, *The bulletin of mathematical biophysics*, t. 5, nr. 4, s. 115–133, grud. 1943, issn: 1522-9602. doi: 10.1007/BF02478259. adr.: <https://doi.org/10.1007/BF02478259>.
- [21] Mhaskar, H. N. i Poggio, T., „Function approximation by deep networks”, *Communications on Pure and Applied Analysis*, t. 19, nr. 8, s. 4085–4095, 2020, issn: 1534-0392. doi: 10.3934/cpaa.2020181. adr.: <https://www.aims sciences.org/article/id/519d7cfc-913a-45ea-9a9b-cee4dd60e31b>.
- [22] Minsky, M. L. i Papert, S. A., *Perceptrons: expanded edition*. Cambridge, MA, USA: MIT Press, 1988, isbn: 0262631113. doi: 10.5555/50066.
- [23] Mnih, V. e. a., „Asynchronous Methods for Deep Reinforcement Learning”, *Proceedings of the 33rd International Conference on Machine Learning*, 2016. doi: 10.48550/arXiv.1602.01783.
- [24] Nesterov, Y., „A method of solving a convex programming problem with convergence rate $O(1/k^2)$ ”, *Soviet Mathematics Doklady*, t. 27, s. 372–376, 1983.
- [25] OpenAI, *OpenAI Baselines: ACKTR & A2C*, OpenAI, 2017. adr.: <https://openai.com/index/openai-baselines-acktr-a2c/>.
- [26] Pezzotti, N., *MimicBot: Combining Imitation and Reinforcement Learning to win in Bot Bowl*, 2021. doi: 10.48550/arXiv.2108.09478. arXiv: 2108.09478 [cs.AI]. term. wiz. 29 kw. 2026. adr.: <https://arxiv.org/abs/2108.09478>.
- [27] Rolnick, D. i Tegmark, M., „The power of deeper networks for expressing natural functions”, maj 2017. doi: 10.48550/arXiv.1705.05502.

-
- [28] Schulman, J., Levine, S., Moritz, P., Jordan, M. I. i Abbeel, P., *Trust Region Policy Optimization*, 2015. doi: 10.48550/arXiv.1502.05477. arXiv: 1502.05477 [cs.LG]. adr.: <https://arxiv.org/abs/1502.05477>.
- [29] Schulman, J., Wolski, F., Dhariwal, P., Radford, A. i Klimov, O., „Proximal Policy Optimization Algorithms”, 2017. doi: 10.48550/arXiv.1707.06347. arXiv: 1707.06347 [cs.LG]. adr.: <https://arxiv.org/abs/1707.06347>.
- [30] Schulman, J. e. a., „High-Dimensional Continuous Control Using Generalized Advantage Estimation”, *International Conference on Learning Representations*, 2016. doi: 10.48550/arXiv.1506.02438.
- [31] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. i Salakhutdinov, R., „Dropout: A Simple Way to Prevent Neural Networks from Overfitting”, *Journal of Machine Learning Research*, t. 15, nr. 1, s. 1929–1958, 2014. doi: 10.5555/2627435.2670313.
- [32] Sutton, R. S. i Barto, A. G., *Temporal-difference learning*. MIT Press Cambridge, MA, USA, 2018, s. 131–132. doi: 10.5555/3312046.
- [33] Sutton, R. S. i Barto, A. G., *Reinforcement Learning: An Introduction*, 2nd. MIT Press, 2018. doi: 10.5555/3312046.
- [34] Telgarsky, M., „Benefits of Depth in Neural Networks”, w *Proceedings of the 29th Conference on Learning Theory*, ser. Proceedings of Machine Learning Research, t. 49, PMLR, 2016, s. 1517–1539. doi: 10.48550/arXiv.1602.04485. adr.: <https://proceedings.mlr.press/v49/telgarsky16.html>.
- [35] Vinyals, O. i in., „StarCraft II: A New Challenge for Reinforcement Learning”, 2017. doi: 10.48550/arXiv.1708.04782. arXiv: 1708.04782 [cs.LG]. adr.: <https://arxiv.org/abs/1708.04782>.
- [36] Zhu, T. i in., „Hyper-Connections”, 2024. doi: 10.48550/arXiv.2409.19606. arXiv: 2409.19606 [cs.LG]. adr.: <https://arxiv.org/abs/2409.19606>.

Spis rysunków

1	Porównanie płytkiej i głębokiej sieci neuronowej z wyrównanym położeniem neuronów wyjściowych.	15
2	Padding i Stride	18
3	Schemat sieci actor-critic	32
4	Połączenia Hyper-Connections.	44
5	Wspólny schemat architektury agenta typu actor–critic stosowanej w eksperymentach. Encoder przestrzenny składa się z trzech kolejnych bloków, natomiast po fuzji cech wspólna reprezentacja jest kierowana do części aktora i krytyka.	53
6	Schemat pojedynczego bloku Inception używanego jako podstawowy moduł części przestrzennej.	53
7	Schemat bloku Inception z połączeniem rezydualnym. Wejście bloku jest łączone ze ścieżką główną przez sumowanie, a wynik trafia dalej do następnego bloku encodera.	54
8	Schemat bloku Inception z mechanizmem Hyper-Connections. Mechanizm HC stanowi część pojedynczego bloku przestrzennego i łączy wejście bloku z rdzeniem Inception oraz jego wyjściem.	54
9	Plansza Blood Bowl	56
10	Win rate i reward w zależności od liczby kroków.	65

Spis tabel

1	Porównanie funkcji aktywacji oraz ich pochodnych	14
2	Zwycięskie modele BotBowl	59
3	Najlepsze rozwiązania wykorzystujące uczenie maszynowe w kolejnych edycjach BotBowl	59
4	Końcowa tabela rankingowa modeli z turnieju	62
5	Wyniki meczów bezpośrednich pomiędzy modelami z turnieju	63
6	Końcowa tabela rankingowa modeli z turnieju po uczeniu przez naśladowanie	67
7	Wyniki meczów bezpośrednich pomiędzy modelami po uczeniu przez naśladowanie .	67