

Politechnika Warszawska

W Y D Z I A Ł   E L E K T R Y C Z N Y



Instytut Sterowania i Elektroniki Przemysłowej

# Praca dyplomowa magisterska

na kierunku Informatyka Stosowana  
w specjalności Inżynieria Oprogramowania

Bot Bowl - nauka sieci neuronowej gry w grę Blood Bowl

inż. Mikołaj Klębowski

numer albumu 299253

promotor

dr inż. Krzysztof Hryniów

WARSZAWA 2026



## **Bot Bowl - nauka sieci neuronowej gry w grę Blood Bowl**

### **Streszczenie**

Praca dotyczy zastosowania metod uczenia ze wzmocnieniem oraz głębokich sieci neuronowych do nauki gry w Blood Bowl w środowisku symulacyjnym BotBowl. Blood Bowl stanowi wymagające środowisko badawcze ze względu na bardzo dużą przestrzeń stanów, wysoki współczynnik rozgałęzienia decyzji, losowość wynikającą z mechaniki rzutów kośćmi oraz długoterminowe zależności pomiędzy działaniami agenta. W takich warunkach klasyczne metody przeszukiwania drzew decyzyjnych okazują się niewystarczające, co czyni uczenie ze wzmocnieniem obiecującym podejściem do konstruowania agentów zdolnych do podejmowania skutecznych decyzji.

Celem pracy było porównanie różnych architektur sieci neuronowych stosowanych w agentach uczących się gry w Blood Bowl z wykorzystaniem algorytmów typu actor-critic. W badaniach zastosowano dwa algorytmy uczenia ze wzmocnieniem: Advantage Actor-Critic (A2C) oraz Proximal Policy Optimization (PPO). Analizowano modele oparte na klasycznych warstwach konwolucyjnych, blokach Inception, architekturze ResNet, blokach Inception-Residual oraz mechanizmie hyper-connections. W badanych sieciach wykorzystano również techniki stabilizacji uczenia, takie jak Layer Normalization, inicjalizacja He, funkcja aktywacji PReLU oraz maskowanie niedozwolonych akcji.

Reprezentacja stanu gry została podzielona na dwa strumienie: przestrzenny, opisujący układ planszy, oraz nieprzestrzenny, zawierający parametry bieżącego stanu rozgrywki. Dane przestrzenne były przetwarzane przez sieci konwolucyjne, natomiast dane nieprzestrzenne przez warstwy w pełni połączone. Eksperymenty przeprowadzono w środowisku BotBowl implementującym zasady gry Blood Bowl i udostępniającym interfejs zgodny ze standardem OpenAI Gym. Postęp uczenia oceniano na podstawie średniej nagrody, liczby przyłożeń na epizod oraz wskaźnika zwycięstw.

Uzyskane wyniki wskazują, że architektura sieci neuronowej istotnie wpływa na zdolność agenta do nauki skutecznej strategii. Najlepsze rezultaty osiągnęły modele wykorzystujące algorytm PPO oraz bardziej zaawansowane mechanizmy ekstrakcji cech przestrzennych, w szczególności bloki Inception i hyper-connections. Jednocześnie eksperymenty potwierdziły, że środowisko Blood Bowl generuje dużą wariancję wyników ze względu na losowość mechaniki gry i rzadkość nagród, co utrudnia ocenę jakości modeli na podstawie pojedynczych przebiegów treningu.

Wyniki pracy potwierdzają, że odpowiedni dobór architektury sieci neuronowej ma kluczowe znaczenie dla skutecznego zastosowania uczenia ze wzmocnieniem w złożonych środowiskach decyzyjnych. Otrzymane rezultaty wskazują również, że Blood Bowl może stanowić wartościowy benchmark do dalszych badań nad architekturami głębokiego uczenia i metodami RL w zadaniach o dużej przestrzeni decyzyjnej.

**Słowa kluczowe:** uczenie ze wzmocnieniem, Blood Bowl, BotBowl, sieci neuronowe, PPO, A2C, sieci konwolucyjne.



# **Bot Bowl - learning the neural network game of Blood Bowl**

## **Abstract**

This thesis concerns the application of reinforcement learning methods and deep neural networks to learning to play Blood Bowl in the BotBowl simulation environment. Blood Bowl is a challenging research environment due to its very large state space, high branching factor, randomness resulting from dice-based game mechanics, and long-term dependencies between an agent's actions. Under such conditions, classical tree-search methods become insufficient, which makes reinforcement learning a promising approach for constructing agents capable of making effective decisions.

The aim of this thesis was to compare different neural network architectures used in agents learning to play Blood Bowl with actor-critic algorithms. Two reinforcement learning algorithms were employed in the study: Advantage Actor-Critic (A2C) and Proximal Policy Optimization (PPO). The analyzed models were based on classical convolutional layers, Inception blocks, the ResNet architecture, Inception-Residual blocks, and the hyper-connections mechanism. The examined networks also incorporated training stabilization techniques such as Layer Normalization, He initialization, the PReLU activation function, and invalid action masking.

The game state representation was divided into two streams: a spatial stream describing the board layout and a non-spatial stream containing parameters of the current game state. Spatial data were processed by convolutional neural networks, whereas non-spatial data were processed by fully connected layers. The experiments were conducted in the BotBowl environment, which implements the rules of Blood Bowl and provides an interface compatible with the OpenAI Gym standard. Learning progress was evaluated using average reward, touchdowns per episode, and win rate.

The obtained results indicate that the neural network architecture significantly affects the agent's ability to learn an effective strategy. The best results were achieved by models using the PPO algorithm and more advanced spatial feature extraction mechanisms, in particular Inception blocks and hyper-connections. At the same time, the experiments confirmed that the Blood Bowl environment produces high variance in results due to the randomness of the game mechanics and the sparsity of rewards, which makes it difficult to assess model quality on the basis of single training runs.

The results of this thesis confirm that the proper selection of neural network architecture is crucial for the effective application of reinforcement learning in complex decision-making environments. The obtained findings also indicate that Blood Bowl may serve as a valuable benchmark for further research on deep learning architectures and reinforcement learning methods in tasks with a large decision space.

**Keywords:** reinforcement learning, Blood Bowl, BotBowl, neural networks, PPO, A2C, convolutional networks.



# Spis treści

|          |                                                                           |           |
|----------|---------------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Wstęp</b>                                                              | <b>9</b>  |
| <b>2</b> | <b>Sieci Neuronowe</b>                                                    | <b>11</b> |
| 2.1      | Funkcja aktywacji . . . . .                                               | 12        |
| 2.2      | Architektura sieci neuronowej . . . . .                                   | 14        |
| 2.3      | Sieci Splotowe . . . . .                                                  | 16        |
| 2.3.1    | Geneza . . . . .                                                          | 16        |
| 2.3.2    | Sposób działania . . . . .                                                | 16        |
| 2.4      | Techniki uczenia sieci neuronowych . . . . .                              | 19        |
| 2.5      | Funkcje straty w uczeniu ze wzmocnieniem . . . . .                        | 21        |
| 2.6      | Algorytmy optymalizacji . . . . .                                         | 22        |
| 2.7      | Problemy gradientowe . . . . .                                            | 26        |
| 2.8      | Techniki stabilizacji i usprawnienia procesu uczenia . . . . .            | 28        |
| <b>3</b> | <b>Zestawienie użytych rozwiązań</b>                                      | <b>31</b> |
| 3.1      | Algorytmy aktor–krytyk . . . . .                                          | 31        |
| 3.2      | Advantage Actor-Critic (A2C) . . . . .                                    | 34        |
| 3.3      | PPO . . . . .                                                             | 36        |
| 3.4      | Współdzielenie części konwolucyjnej . . . . .                             | 38        |
| 3.5      | Reprezentacja danych wejściowych . . . . .                                | 38        |
| 3.6      | Architektura typu CNN z blokiem Inception . . . . .                       | 39        |
| 3.7      | Resnet . . . . .                                                          | 41        |
| 3.8      | Inception-Residual . . . . .                                              | 41        |
| 3.9      | Hyper-Connections . . . . .                                               | 42        |
| 3.10     | Rozszerzenia architektury sieci i techniki stabilizacji uczenia . . . . . | 47        |
| 3.11     | Architektury sieci neuronowych zastosowanych w środowisku . . . . .       | 51        |
| 3.11.1   | Analizowane warianty architektur . . . . .                                | 51        |
| <b>4</b> | <b>Środowisko testowe</b>                                                 | <b>53</b> |
| 4.1      | Bloodbowl jako benchmark dla uczenia ze wzmocnieniem. . . . .             | 54        |
| 4.2      | Środowisko BotBowl . . . . .                                              | 55        |

|                                                   |           |
|---------------------------------------------------|-----------|
| <b>5 Wyniki</b>                                   | <b>57</b> |
| 5.1 Możliwości dalszych prac badawczych . . . . . | 61        |
| <b>Wykaz skrótów i symboli</b>                    | <b>67</b> |
| <b>Spis rysunków</b>                              | <b>69</b> |
| <b>Spis tabel</b>                                 | <b>71</b> |



# Rozdział 1

## Wstęp

W ostatnich latach sztuczna inteligencja, a w szczególności metody oparte na głębokich sieciach neuronowych, stały się jednym z kluczowych obszarów rozwoju współczesnej informatyki. Ich zastosowania obejmują zarówno zadania percepcyjne, takie jak rozpoznawanie obrazów i mowy, jak i problemy decyzyjne występujące w systemach autonomicznych, analizie danych czy optymalizacji procesów przemysłowych. Dynamiczny postęp w tej dziedzinie wynika w dużej mierze z rosnących możliwości obliczeniowych oraz rozwoju algorytmów umożliwiających skuteczne uczenie modeli na podstawie dużych zbiorów danych. Coraz częściej systemy te potrafią podejmować złożone decyzje w sposób autonomiczny, bez bezpośredniego nadzoru człowieka.

Szczególną rolę w tym kontekście odgrywa uczenie ze wzmocnieniem, stanowiące jeden z podstawowych paradygmatów uczenia maszynowego, skoncentrowany na problemach sekwencyjnego podejmowania decyzji przez agenta, czyli system wchodzący w interakcję ze środowiskiem. W przeciwieństwie do uczenia nadzorowanego, w którym model otrzymuje pary danych wejściowych i oczekiwanych odpowiedzi, w uczeniu ze wzmocnieniem agent zdobywa wiedzę poprzez interakcję ze środowiskiem oraz obserwację konsekwencji podejmowanych działań. Takie podejście pozwala modelować problemy, w których nagroda jest opóźniona w czasie, a decyzje podejmowane na wczesnym etapie wpływają na dalszy przebieg procesu. Z tego względu metody te znajdują zastosowanie m.in. w robotyce, systemach sterowania, logistyce, finansach oraz w grach.

Gry od wielu lat pełnią funkcję kluczowych środowisk testowych dla algorytmów sztucznej inteligencji. Ich popularność wynika z kilku cech: jasno zdefiniowanych reguł, możliwości precyzyjnego pomiaru wyników oraz łatwości powtarzania eksperymentów w identycznych warunkach początkowych. Dzięki temu umożliwiają obiektywne porównywanie skuteczności różnych metod i architektur modeli uczących się. W historii rozwoju sztucznej inteligencji gry planszowe, karciane oraz komputerowe wielokrotnie wykorzystywano jako środowiska badawcze pozwalające analizować zachowanie agentów w warunkach wysokiej złożoności decyzyjnej.

Istotnym wyzwaniem w środowiskach decyzyjnych jest duża przestrzeń stanów oraz wysoki współczynnik rozgałęzienia akcji (*ang. branching factor*). W takich warunkach liczba potencjalnych trajektorii działania agenta rośnie wykładniczo wraz z długością sekwencji decyzji, co znacząco

utrudnia zarówno eksplorację przestrzeni rozwiązań, jak i stabilne uczenie modeli. Dodatkową trudność stanowi obecność losowości, która wprowadza niepewność co do skutków podejmowanych działań i wymusza na agencie uczenie się strategii odpornych na zmienne warunki.

Gra Blood Bowl, będąca turową grą strategiczną wywodzącą się z gry planszowej, stanowi przykład środowiska spełniającego wszystkie powyższe kryteria. Rozgrywka łączy elementy planowania długoterminowego, zarządzania ryzykiem oraz reagowania na zdarzenia losowe, takie jak wyniki rzutów kośćmi. W każdej turze gracz ma do dyspozycji wiele akcji, których kolejność i wybór mają istotny wpływ na dalszy przebieg meczu. Wysoki poziom złożoności decyzyjnej oraz wieloetapowy charakter gry sprawiają, że Blood Bowl stanowi wymagające i jednocześnie wartościowe środowisko do badań nad algorytmami uczenia ze wzmocnieniem.

Motywacją niniejszej pracy jest potrzeba lepszego zrozumienia, w jaki sposób różne architektury sieci neuronowych radzą sobie w środowiskach charakteryzujących się wysoką złożonością decyzyjną i znaczną losowością. W literaturze przedmiotu często prezentuje się wyniki uzyskiwane w relatywnie prostych środowiskach, takich jak klasyczne gry Atari czy zadania o ograniczonej liczbie akcji. Tymczasem bardziej złożone problemy decyzyjne, bliższe rzeczywistym zastosowaniom, mogą ujawniać istotne różnice między poszczególnymi podejściami architektonicznymi i algorytmicznymi.

Celem niniejszej pracy jest porównanie wybranych rozwiązań uczenia ze wzmocnieniem w kontekście gry Blood Bowl, ze szczególnym uwzględnieniem wpływu architektury sieci neuronowej na efektywność procesu uczenia. Analizie poddane zostaną różne podejścia do przetwarzania informacji, a także ich zdolność do wypracowywania skutecznych strategii w złożonym środowisku gry. Porównanie to pozwoli na ocenę, w jakim stopniu określone rozwiązania sprzyjają stabilnemu uczeniu oraz szybkiej adaptacji agenta do reguł rozgrywki.

Zakres pracy obejmuje zarówno omówienie teoretycznych podstaw uczenia ze wzmocnieniem i sieci neuronowych, jak i analizę praktycznych aspektów ich zastosowania w środowisku gry. W kolejnych rozdziałach przedstawiono podstawy teoretyczne, środowisko symulacyjne wykorzystane w badaniach, opis zastosowanych modeli oraz metodykę przeprowadzonych eksperymentów. Pracę kończy analiza uzyskanych wyników oraz wnioski dotyczące przydatności poszczególnych architektur w kontekście złożonych problemów decyzyjnych.

## Rozdział 2

# Sieci Neuronowe

Idea sztucznych sieci neuronowych narodziła się podczas prób modelowania pracy ludzkiego mózgu. Warren S. McCulloch oraz Walter Pitts w swojej pracy "A logical calculus of the ideas immanent in nervous activity" [15] zaproponowali model sieci neuronowej, jako grafu skierowanego, gdzie węzły to matematyczne modele neuronu takie, że

$$N_i(t+1) = H\left(\sum_{j=1}^n w_{ij}(t)N_j(t) - \Theta_i(t)\right)$$

gdzie:

- $N$  - stan neuronu, może przyjąć wartość 0 lub 1
- $H()$  - funkcja skokowa Heaviside'a
- $w_{ij}$  - waga połączenia między wektorem  $j$  oraz  $i$ .
- $\Theta$  - próg wyzwalania, neuron aktywuje się, gdy sygnał wejściowy go przekroczy.

Sieć złożona z takich neuronów jest nazywana dzisiaj perceptronem. Służy ona do zadań klasyfikacji binarnej. Potrafi określić przynależność badanego obiektu do jednej z klas na podstawie wybranych cech. W 1957 roku Frank Rosenblatt opracował pierwszy uczący się perceptron, który stanowił przełom w rozwoju sztucznych sieci neuronowych. Pomimo swojej innowacyjności, model ten miał istotne ograniczenia – nie potrafił rozwiązywać problemów nieliniowych, takich jak klasyczny przykład funkcji XOR, a jego struktura uniemożliwiała zastosowanie metod uczenia opartych na obliczaniu pochodnych. Źródłem tego ograniczenia była funkcja skokowa Heaviside'a, wykorzystywana jako funkcja aktywacji neuronu. Współcześnie zastępuje się ją funkcjami ciągłymi i różniczkowalnymi, takimi jak sigmoid, tangens hiperboliczny czy ReLU (Rectified Linear Unit) wraz z jej modyfikacjami (np. Leaky ReLU, Parametric ReLU), które umożliwiają skuteczne stosowanie algorytmów gradientowych, takich jak propagacja wsteczna błędów. [17] Jak zostało wcześniej wspomniane ten model został stworzony w celu opisanie sposobu działania biologicznego neuronu. Można go uogólnić, pozwalając stworzyć bardziej uniwersalny model matematyczny.

$$y = f \left( \sum_{i=1}^m w_i(t) x_i(t) + b \right)$$

gdzie:

- $w_i$  – waga
- $x_i$  – wejście,
- $f$  – funkcja aktywacji,
- $y$  – wyjście,
- $m$  – liczba wejść,
- $b$  – stała wartość (ang. bias).

Do funkcji aktywacji  $f$  przekazywana jest ważona suma sygnałów wejściowych, do której dodaje się opcjonalnie parametr bias. Taki opis umożliwia zastosowanie dowolnej funkcji aktywacji, co pozwala sieci neuronowej modelować nieliniowe zależności.

## 2.1 Funkcja aktywacji

Jednym z kluczowych elementów sztucznego neuronu jest funkcja aktywacji, która określa, w jaki sposób sygnał wejściowy jest przekształcany w sygnał wyjściowy. Od jej właściwości zależy zdolność sieci neuronowej do modelowania złożonych zależności nieliniowych.

Pierwszym powszechnie stosowanym rozwiązaniem była funkcja skokowa Heaviside'a:

$$H(x) = \begin{cases} 0, & x < 0, \\ 1, & x \geq 0. \end{cases}$$

która aktywuje neuron dopiero po przekroczeniu określonego progu. Funkcja ta stanowi uproszczony model działania neuronu biologicznego, który reaguje po osiągnięciu odpowiedniego poziomu pobudzenia, jednak z matematycznego punktu widzenia ma istotną wadę — nie jest różniczkowalna. Jej pochodna jest równa zero dla wszystkich wartości oprócz punktu  $x = 0$ , gdzie jest nieokreślona. W konsekwencji uniemożliwia to stosowanie metod uczenia opartych na gradiencie, takich jak propagacja wsteczna błędów.

Aby umożliwić płynne i różniczkowalne przejście między stanami aktywacji, wprowadzono funkcje ciągłe, takie jak sigmoid i tangens hiperboliczny ( $\tanh$ ). Funkcja sigmoidalna ma postać:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

a tangens hiperboliczny:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Obie funkcje zapewniają gładką i różniczkowalną zależność między sygnałem wejściowym a wyjściem neuronu, co umożliwia stosowanie gradientowych metod optymalizacji. Dodatkową zaletą funkcji  $\tanh(x)$  jest zakres wartości  $(-1, 1)$  oraz symetria względem zera, co sprzyja uczeniu głębokich sieci neuronowych. Ich istotną wadą jest jednak zjawisko nasycenia: dla dużych wartości argumentu pochodna tych funkcji przyjmuje wartości bliskie zero, co prowadzi do problemu zanikającego gradientu.

W odpowiedzi na te ograniczenia opracowano funkcję ReLU (Rectified Linear Unit), definiowaną jako:

$$\text{ReLU}(x) = \max(0, x) = \begin{cases} 0, & x \leq 0, \\ x, & x > 0. \end{cases}$$

Funkcja ta jest ciągła w całej swojej dziedzinie, również w punkcie  $x=0$ , lecz nie jest różniczkowalna w tym punkcie — lewa pochodna wynosi 0, a prawa 1. W praktyce jednak przyjmuje się, że funkcja jest „różniczkowalna prawie wszędzie”, co pozwala skutecznie stosować ją w uczeniu sieci metodami gradientowymi. ReLU eliminuje zjawisko zanikającego gradientu dla dodatnich wartości wejść, dzięki czemu znacząco przyspiesza uczenie głębokich modeli. Współczesne warianty, takie jak Leaky ReLU, Parametric ReLU czy ELU (Exponential Linear Unit), pozwalają dodatkowo ograniczyć problem tzw. martwych neuronów, które przestają reagować na sygnał uczący.









| Porównanie funkcji i ich pochodnych                                                 |                                                                                      |
|-------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------|
| Funkcja Heaviside $H(x)$                                                            | Pochodna $H(x)$                                                                      |
|    |    |
| Funkcja ReLU(x)                                                                     | Pochodna ReLU(x)                                                                     |
|    |    |
| Tangens hiperboliczny $\tanh(x)$                                                    | Pochodna $\tanh(x)$                                                                  |
|    |    |
| $\sigma(x)$                                                                         | Pochodna $\sigma(x)$                                                                 |
|  |  |

Tabela 1. Porównanie funkcji aktywacji oraz ich pochodnych

## 2.2 Architektura sieci neuronowej

### Architektura sieci neuronowej i zdolność reprezentacyjna

Sieć neuronowa jest modelem obliczeniowym złożonym z kolejnych warstw przetwarzających dane wejściowe w coraz bardziej użyteczne reprezentacje. Typowa architektura obejmuje warstwę wejściową, jedną lub większą liczbę warstw ukrytych oraz warstwę wyjściową. W klasycznych modelach warstwy są zazwyczaj w pełni połączone (ang. *fully connected*), co oznacza, że każdy neuron danej warstwy jest połączony z każdym neuronem warstwy następnej.

Pojedyncza warstwa sieci realizuje przekształcenie postaci

$$\mathbf{h}^{(l)} = f^{(l)} \left( \mathbf{W}^{(l)} \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)} \right), \quad (1)$$

gdzie:

- $\mathbf{h}^{(l)}$  – wektor aktywacji warstwy  $l$ ,

- $W^{(l)}$  – macierz wag warstwy  $l$ ,
- $b^{(l)}$  – wektor przesunięć (*bias*),
- $f^{(l)}(\cdot)$  – funkcja aktywacji stosowana w warstwie  $l$ .

Cała sieć może być opisana jako złożenie kolejnych transformacji:

$$f(x) = f^{(L)}\left(f^{(L-1)}\left(\dots f^{(1)}(x) \dots\right)\right), \quad (2)$$

gdzie  $L$  oznacza liczbę warstw, a  $x$  jest wektorem wejściowym.

Jednym z podstawowych parametrów opisujących architekturę sieci jest jej głębokość. Mianem *płytkiej sieci* (*shallow network*) określa się model zawierający pojedynczą warstwę ukrytą, natomiast *głębokie sieci* (*deep networks*) zawierają wiele warstw ukrytych. Zwiększenie głębokości pozwala przedstawiać złożone zależności za pomocą sekwencji prostszych przekształceń, co w praktyce często prowadzi do bardziej efektywnej reprezentacji niż w przypadku architektur płytszych.


Teoretyczne podstawy zdolności aproksymacyjnych sieci neuronowych opisuje twierdzenie o uniwersalnej aproksymacji. Zgodnie z nim sieć z jedną warstwą ukrytą i odpowiednio dużą liczbą neuronów może przybliżać dowolną funkcję ciągłą na zwartym zbiorze z dowolną zadaną dokładnością [3, 9]. Działanie takiej sieci można zapisać jako

$$f(x) = \sum_{i=1}^N \alpha_i \sigma(w_i^\top x + b_i), \quad (3)$$


gdzie  $\sigma(\cdot)$  oznacza nieliniową funkcję aktywacji, natomiast  $\alpha_i$ ,  $w_i$  oraz  $b_i$  są parametrami modelu wyznaczanymi w procesie uczenia.

Choć twierdzenie to potwierdza dużą moc aproksymacyjną sieci płytkich, w praktyce uzyskanie wysokiej jakości odwzorowania może wymagać bardzo szerokiej warstwy ukrytej. Z tego względu architektury głębokie są często korzystniejsze, ponieważ umożliwiają osiągnięcie porównywalnej lub większej zdolności reprezentacyjnej przy bardziej zwartej strukturze modelu.

**Płytką sieć neuronową**



**Głęboką sieć neuronową**



**Rysunek 1.** Porównanie płytkiej i głębokiej sieci neuronowej z wyrównanym położeniem neuronów wyjściowych.

Badania [16, 21, 28] wykazały istnienie tzw. **hierarchii głębokości**, zgodnie z którą zwiększanie liczby warstw jest znacznie bardziej efektywne niż ich poszerzanie. Dla pewnych klas funkcji ograniczenie głębokości prowadzi do wykładniczego wzrostu liczby neuronów wymaganych do osiągnięcia tej samej jakości aproksymacji. Zależność tę można opisać asymptotycznie:

$$N_{\text{shallow}} = \mathcal{O}(2^k), \quad N_{\text{deep}} = \mathcal{O}(k^3), \quad (4)$$

gdzie  $k$  oznacza głębokość sieci. Zwiększenie głębokości modelu pozwala zatem uzyskać porównywalną zdolność aproksymacji określonych klas funkcji przy istotnie mniejszej liczbie neuronów i parametrów.

## 2.3 Sieci Splotowe

### 2.3.1 Geneza

Sieci splotowe (*Convolutional Neural Networks*, CNN) stanowią jedną z podstawowych klas modeli stosowanych w głębokim uczeniu do analizy danych o strukturze przestrzennej. Ich rozwój był inspirowany badaniami nad organizacją kory wzrokowej, w której neurony reagują na bodźce występujące w ograniczonych obszarach pola widzenia. W odróżnieniu od klasycznych sieci w pełni połączonych, CNN wykorzystują lokalne filtry przesuwane po całym wejściu, co umożliwia automatyczne wydobywanie cech przestrzennych przy znacznie mniejszej liczbie parametrów.

Kluczową własnością sieci splotowych jest współdzielenie wag, polegające na stosowaniu tych samych filtrów w różnych położeniach danych wejściowych. Pozwala to wykrywać te same wzorce niezależnie od ich położenia oraz ogranicza złożoność modelu. Dzięki temu sieci splotowe są szczególnie przydatne w zadaniach, w których istotne są lokalne zależności pomiędzy elementami danych.

W kontekście gry Blood Bowl sieci splotowe mogą pełnić rolę ekstraktora cech przestrzennych opisujących stan planszy, takich jak położenie zawodników, strefy zagrożenia, pozycja piłki czy układy taktyczne. Umożliwia to przekształcenie surowej reprezentacji stanu w bardziej użyteczne cechy przekazywane następnie do części decyzyjnej agenta. [14]

### 2.3.2 Sposób działania

#### Operacja splotu

Podstawowym elementem sieci splotowej jest warstwa splotowa. Operacja splotu polega na obliczaniu lokalnych sum ważonych pomiędzy fragmentami danych wejściowych a wagami filtra, co prowadzi do powstania mapy aktywacji uwypuklającej obecność określonych wzorców.

$$y(i) = \sum_{m \in \mathcal{M}} x(i + m) w(m) + b,$$



gdzie:

- $i$  oznacza wektor indeksów wyjścia,
- $m$  oznacza wektor przesunięć w obrębie jądra,
- $x(i + m)$  oznacza fragment danych wejściowych,
- $w(m)$  oznacza wagę filtra,
- $b$  oznacza wyraz wolny,
- $y(i)$  oznacza wartość wyjściową.

Dla danych dwuwymiarowych operacja ta przyjmuje postać:

$$y(i, j) = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} x(i + m, j + n) w(m, n) + b.$$

W wyniku przesuwania filtra po wejściu powstaje mapa cech (*feature map*), wskazująca miejsca, w których dany wzorec został wykryty.

### Dane wielokanałowe

W praktyce dane wejściowe mają zwykle wiele kanałów. W klasycznych zadaniach wizji komputerowej kanały te odpowiadają na przykład składowym RGB obrazu, natomiast w analizie stanu gry mogą reprezentować różne cechy planszy, takie jak pozycje zawodników, położenie piłki, zajętość pól czy dodatkowe informacje taktyczne.

Jeżeli wejście opisane jest tensorem

$$X \in \mathbb{R}^{C_{in} \times H \times W},$$

to pojedyncza mapa wyjściowa obliczana jest jako suma splotów po wszystkich kanałach wejściowych:

$$Y_k(i, j) = b_k + \sum_{c=1}^{C_{in}} \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} X_c(i + m, j + n) W_{k,c}(m, n),$$

gdzie  $k$  oznacza indeks filtra wyjściowego, a  $C_{in}$  liczbę kanałów wejściowych. Każdy filtr wykorzystuje zatem pełną informację zawartą we wszystkich kanałach, tworząc jedną mapę cech opisującą określony typ wzorca.

### Funkcje aktywacji i normalizacja

Po wykonaniu operacji splotu wynik jest zazwyczaj przekazywany przez nieliniową funkcję aktywacji, taką jak ReLU. Dzięki temu sieć może modelować zależności nieliniowe i budować bardziej złożone reprezentacje niż modele oparte wyłącznie na przekształceniach liniowych.

W wielu architekturach pomiędzy warstwą splotową a funkcją aktywacji stosuje się również warstwy normalizacyjne, takie jak Batch Normalization lub Layer Normalization. Ich zadaniem jest stabilizacja procesu uczenia poprzez ograniczanie nadmiernych zmian rozkładu aktywacji. W praktyce typowy

blok przetwarzania może więc przyjmować postać warstwy splotowej, następnie normalizacji, a na końcu funkcji aktywacji.


### Stride i padding

Istotnymi parametrami warstwy splotowej są krok przesuwania filtra (*stride*) oraz sposób uzupełniania brzegów wejścia (*padding*). Parametr *stride* określa, o ile pozycji filtr przesuwany jest przy każdym kroku, natomiast *padding* pozwala kontrolować sposób przetwarzania elementów znajdujących się przy krawędziach wejścia.

Parametry te wpływają bezpośrednio na rozmiar mapy cech. Dla wejścia o wysokości  $H$  i szerokości  $W$ , filtra o rozmiarze  $K$ , kroku  $S$  oraz paddingu  $P$ , rozmiar wyjścia można zapisać jako:

$$H_{\text{out}} = \left\lfloor \frac{H + 2P - K}{S} \right\rfloor + 1, \quad W_{\text{out}} = \left\lfloor \frac{W + 2P - K}{S} \right\rfloor + 1.$$

Zwiększenie kroku przesuwania prowadzi do zmniejszenia rozdzielczości mapy cech, natomiast zastosowanie paddingu pozwala zachować większą ilość informacji brzegowej i ograniczyć szybkie zmniejszanie wymiarów reprezentacji.



### Hierarchia reprezentacji

Kolejne warstwy splotowe tworzą hierarchię reprezentacji. Warstwy płytsze uczą się prostych zależności lokalnych, natomiast warstwy głębsze budują na ich podstawie bardziej złożone reprezentacje przestrzenne. W klasycznych zastosowaniach pierwsze warstwy wykrywają proste wzorce, takie jak krawędzie lub tekstury, a dalsze warstwy łączą je w coraz bardziej złożone układy.

W zastosowaniach związanych z grami planszowymi hierarchia ta może odpowiadać przejściu od prostych zależności pomiędzy sąsiednimi polami do bardziej złożonych układów pozycyjnych

obejmujących większy fragment planszy. Dzięki temu sieć może kodować zarówno lokalne zagrożenia, jak i bardziej globalne zależności taktyczne.

### Warstwy wspierające

W sieciach spłotowych stosuje się również warstwy wspierające, które uzupełniają działanie samych operacji spłotu. Warstwy *pooling* redukują rozdzielczość map cech poprzez lokalną agregację, co zmniejsza koszt obliczeniowy i zwiększa zakres zależności analizowanych przez kolejne warstwy. Warstwy normalizacyjne stabilizują proces uczenia, natomiast *dropout* ogranicza ryzyko przeuczenia przez losowe wyłączanie części aktywacji w trakcie treningu.

Dobór tych mechanizmów zależy od charakteru zadania. W problemach wymagających zachowania precyzyjnej informacji przestrzennej, takich jak analiza planszy gry, nadmierna redukcja rozdzielczości może być niekorzystna. Z tego względu warstwy wspierające powinny być dobierane z uwzględnieniem kompromisu pomiędzy efektywnością obliczeniową a dokładnością reprezentacji.

Wynik działania części spłotowej jest następnie przekazywany do dalszych warstw modelu, na przykład warstw gęstych lub głów aktora i krytyka w algorytmach uczenia ze wzmocnieniem.

## 2.4 Techniki uczenia sieci neuronowych

Uczenie sieci neuronowych to proces, podczas którego model dopasowuje swoje parametry w taki sposób, aby minimalizować błąd predykcji. Efektywność tego procesu decyduje o zdolności modelu do generalizacji, czyli poprawnego działania na podstawie danych, których nie widział podczas treningu.

Uczenie odbywa się w sposób iteracyjny poprzez modyfikację wag modelu w kierunku przeciwnym do gradientu funkcji kosztu. Każdy cykl uczenia (epoka) obejmuje cztery główne etapy:

- Propagacja w przód (*forward pass*) – dane wejściowe przechodzą przez kolejne warstwy modelu, aż do uzyskania przewidywania  $\hat{y}$ .
- Obliczenie błędu (*loss*) – funkcja kosztu  $(y, \hat{y})$  mierzy jakość otrzymanej predykcji.
- Propagacja wsteczna (*backpropagation*) – na podstawie reguły łańcuchowej obliczane są gradienty funkcji kosztu względem wag.
- Aktualizacja wag (*update*) – parametry są modyfikowane zgodnie z wybranym algorytmem optymalizacji, np. SGD lub Adamem.

Na podstawie sposobu pozyskiwania informacji zwrotnej i dostępności danych uczących wyróżnia się trzy główne paradygmaty uczenia: uczenie nadzorowane, uczenie nienadzorowane oraz uczenie ze wzmocnieniem. [2]

### Uczenie nadzorowane

Uczenie nadzorowane (*supervised learning*) jest najczęściej stosowanym paradygmatem uczenia sieci neuronowych. Wymaga on zbioru danych uczących składający się z par  $(x, y)$ , gdzie  $x$  reprezentuje wektor cech opisujących przykład, a  $y$  jest przypisaną do niego etykietą lub wartością wyjściową.

Celem modelu jest nauczenie się odwzorowania  $f : x \rightarrow y$  w taki sposób, aby przewidywane wyjście  $\hat{y}$  było jak najbardziej zbliżone do wartości rzeczywistej  $y$  [5].

W ramach uczenia nadzorowanego wyróżnia się dwa główne typy zadań:

- **Klasyfikacja** – gdy etykiety  $y$  należą do skończonego zbioru klas, a model ma za zadanie przypisać dany przykład do jednej z nich. Przykłady zastosowań obejmują rozpoznawanie obrazów, klasyfikację dokumentów tekstowych czy diagnozowanie chorób na podstawie danych medycznych.
- **Regresja** – gdy etykieta  $y$  ma charakter ciągły lub liczbowy, a zadaniem modelu jest oszacowanie jej wartości na podstawie dostępnych danych wejściowych. Przykładami takich zadań są prognozowanie cen, przewidywanie popytu oraz estymacja parametrów fizycznych w eksperymentach naukowych.

Dzięki swojej uniwersalności, uczenie nadzorowane jest stosowane w szerokim zakresie dziedzin, od rozpoznawania mowy i analizy obrazu, przez systemy rekomendacyjne, aż po prognozy finansowe i modelowanie procesów przemysłowych.

## Uczenie nienadzorowane

Uczenie nienadzorowane (*unsupervised learning*) obejmuje metody, w których model uczy się wyłącznie na podstawie danych wejściowych  $x$ , bez dostępu do odpowiadających im etykiet wynikowych. Celem jest odkrycie wewnętrznej struktury danych, zależności pomiędzy przykładami lub reprezentacji pozwalających na ich bardziej efektywne opisanie [5].

W ramach uczenia nienadzorowanego wyróżnić można kilka głównych typów zadań:

- **Grupowanie (*clustering*)** – podział zbioru danych na zbiory w taki sposób, aby przykłady w tym samym zbiorze były do siebie możliwie podobne, a między nimi różnice jak najbardziej wyraźne. Przykładami takich algorytmów są *k-means*, DBSCAN czy sieci Kohonena (SOM) [13].
- **Redukcja wymiarów** – przekształcenie danych do przestrzeni o mniejszej liczbie wymiarów przy zachowaniu jak największej ilości informacji. Popularne metody to analiza głównych składowych (PCA) czy autoenkodery.
- **Uczenie reprezentacji** – poszukiwanie wewnętrznych opisów danych (tzw. reprezentacji ukrytych), które mogą ułatwić dalsze zadania, np. klasyfikację lub generowanie nowych przykładów. Przykładem są modele generatywne, takie jak *Variational Autoencoder* (VAE) czy *Generative Adversarial Networks* (GAN) [6].

Uczenie nienadzorowane znajduje zastosowanie m.in. w segmentacji obrazów, eksploracji danych, kompresji informacji, wyszukiwaniu podobnych obiektów, detekcji anomalii czy jako etap wstępny w uczeniu nadzorowanym (tzw. *pretraining*).

## Uczenie ze wzmocnieniem

Uczenie ze wzmocnieniem (*reinforcement learning*, RL) to proces, w którym agent uczy się poprzez interakcję ze środowiskiem. W każdym kroku czasowym  $t$  agent obserwuje stan  $s_t$ , wybiera akcję  $a_t$ , otrzymuje nagrodę  $r_t$  i przechodzi do kolejnego stanu  $s_{t+1}$ . Celem jest maksymalizacja zdyskontowanej sumy nagród:

$$R_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k}$$

gdzie  $\gamma \in (0, 1)$  to współczynnik dyskontowania, który określa znaczenie przyszłych nagród. Uczenie ze wzmocnieniem znajduje zastosowanie w problemach decyzyjnych – w tym w robotyce, sterowaniu i grach strategicznych, takich jak BloodBowl, Go czy StarCraft, gdzie sieci neuronowe pełnią rolę polityki decyzyjnej (*policy network*).

## 2.5 Funkcje straty w uczeniu ze wzmocnieniem

Funkcja straty (ang. *loss function*) pełni istotną rolę również w uczeniu ze wzmocnieniem, jednak jej znaczenie różni się od roli, jaką pełni w klasycznych zadaniach uczenia nadzorowanego. W przypadku uczenia nadzorowanego funkcja straty opisuje bezpośrednią rozbieżność pomiędzy przewidywaniem modelu  $\hat{y}$  a znaną wartością docelową  $y$ . Natomiast w uczeniu ze wzmocnieniem model nie dysponuje jednoznacznymi etykietami poprawnych odpowiedzi dla poszczególnych przykładów. Zamiast tego agent uczy się na podstawie sygnału nagrody otrzymywanego ze środowiska, którego wpływ może ujawniać się dopiero po wielu kolejnych decyzjach. [27]

W konsekwencji funkcja straty w uczeniu ze wzmocnieniem nie służy wyłącznie do minimalizacji błędu predykcji względem z góry zadanej odpowiedzi, lecz do takiej modyfikacji parametrów modelu, aby zwiększać oczekiwaną skumulowaną nagrodę. Wartości docelowe wykorzystywane podczas optymalizacji są najczęściej estymowane na podstawie obserwowanych przejść, uzyskanych nagród oraz przewidywań samego modelu.

Na podstawie funkcji straty algorytm optymalizacji wyznacza gradienty, które informują, w jaki sposób należy modyfikować parametry sieci, aby poprawić jakość podejmowanych decyzji, trafność estymacji wartości stanów lub działań oraz skuteczność całej polityki działania. Proces ten prowadzi do iteracyjnego dostosowywania parametrów modelu w kierunku maksymalizacji oczekiwanego zwrotu, przy czym w praktyce często realizuje się to poprzez minimalizację odpowiednio zdefiniowanej funkcji straty.

W praktyce można wyróżnić kilka głównych grup funkcji straty stosowanych w uczeniu ze wzmocnieniem:

- **Funkcje straty dla metod opartych na funkcji wartości** – stosowane, gdy model estymuje wartość stanu  $V(s)$  lub wartość akcji  $Q(s, a)$ :
  - *Mean Squared Error (MSE)* – używana do minimalizacji różnicy pomiędzy przewidywaną wartością a wartością docelową wyznaczoną na podstawie nagrody i bootstrappingu.

- *Huber loss* – często stosowana jako bardziej odporna alternatywa dla MSE, ograniczająca wpływ dużych błędów estymacji.
- **Funkcje straty dla metod gradientu polityki** – stosowane, gdy model bezpośrednio optymalizuje politykę wyboru działań:
  - strata polityki oparta na logarytmie prawdopodobieństwa wybranego działania, ważona estymowanym zwrotem lub przewagą (*advantage*),
  - funkcje celu z mechanizmami ograniczającymi zbyt duże zmiany polityki, jak w metodzie PPO.

Dobór funkcji straty w uczeniu ze wzmocnieniem powinien uwzględniać kilka istotnych czynników:

- **Rodzaj stosowanego algorytmu** – inna postać funkcji straty jest wykorzystywana w metodach opartych na funkcji wartości, inna w metodach gradientu polityki, a jeszcze inna w podejściach actor–critic.
- **Sposób wyznaczania celu optymalizacji** – w uczeniu ze wzmocnieniem wartości docelowe są zwykle estymowane, a nie znane z góry, co wpływa na stabilność uczenia i jakość uzyskiwanych gradientów.
- **Wariancję i szum sygnału uczącego** – sygnał nagrody może być rzadki, opóźniony i obciążony dużą losowością, dlatego funkcja straty powinna sprzyjać stabilnemu uczeniu mimo niepewności estymowanych celów.
- **Równowagę pomiędzy eksploracją a eksploatacją** – w wielu metodach do funkcji straty dodawany jest składnik entropijny, który zachęca agenta do dalszego badania przestrzeni możliwych działań.
- **Stabilność optymalizacji** – ze względu na niestacjonarny charakter danych treningowych oraz zależność kolejnych obserwacji od aktualnej polityki, szczególne znaczenie ma ograniczanie zbyt gwałtownych aktualizacji parametrów.

Ostateczny dobór funkcji straty ma istotny wpływ na stabilność procesu uczenia, szybkość konwergencji oraz końcową skuteczność agenta. W przeciwieństwie do klasycznych zadań nadzorowanych funkcja straty w uczeniu ze wzmocnieniem ma charakter bardziej pośredni, ponieważ nie odnosi się do jawnie zadanej poprawnej odpowiedzi, lecz do estymowanego wpływu działań na przyszłą sumę nagród.

## 2.6 Algorytmy optymalizacji

Kluczowym elementem procesu uczenia są Algorytmy optymalizacji. Odpowiadają one za aktualizację parametrów modelu w celu minimalizacji wartości funkcji straty. W praktyce optymalizacja odbywa się iteracyjnie, a parametry modelu są aktualizowane zgodnie z kierunkiem przeciwnym do gradientu funkcji kosztu względem wag. [5]

$$\theta_{t+1} = \theta_t - \eta \nabla_{\theta} L(\theta_t)$$

gdzie  $\eta$  oznacza współczynnik uczenia (learning rate). Zbyt duża wartość  $\eta$  może powodować niestabilność uczenia, a zbyt mała – spowolnienie konwergencji. Dlatego opracowano szereg metod adaptacyjnych i usprawnień klasycznego spadku gradientu.

### Metoda najszybszego spadku

Podstawowy algorytm optymalizacji, stosowany zarówno w wersji pełnej (batch gradient descent), jak i stochastycznej (stochastic gradient descent, SGD). W przypadku danych dzielonych na partie (mini-batches), aktualizacja parametrów przyjmuje postać:

$$\theta_{t+1} = \theta_t - \eta \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} L_i(\theta_t)$$

gdzie  $m$  to liczba próbek w partii danych.

W praktyce metoda spadku gradientu występuje w trzech głównych wariantach, różniących się sposobem obliczania gradientu. W pełnym spadku gradientu (batch gradient descent) gradient wyznacza się na podstawie całego zbioru treningowego, co daje dokładny kierunek spadku, ale jest obliczeniowo kosztowne i mało praktyczne przy dużych danych. W przeciwieństwie do tego, stochastyczny spadek gradientu (stochastic gradient descent, SGD) aktualizuje wagi po każdej próbce danych, co znacząco przyspiesza uczenie i umożliwia ucieczkę z minimów lokalnych, jednak wprowadza losowe oscylacje w kierunku gradientu. Kompromisem pomiędzy tymi podejściami jest mini-batch gradient descent, który wykorzystuje niewielkie partie danych (zazwyczaj od kilkunastu do kilkuset przykładów). Takie podejście poprawia stabilność uczenia i umożliwia efektywne wykorzystanie równoległości obliczeń, np. na procesorach GPU.

Choć klasyczna metoda spadku gradientu jest intuicyjna i prosta w implementacji, ma istotne ograniczenia. Jest bardzo wrażliwa na dobór współczynnika uczenia i może łatwo utknąć w minimach lokalnych lub punktach siodłowych. Ponadto w obszarach o silnie nachylonych dolinach funkcji kosztu często występują oscylacje, które spowalniają konwergencję

### Spadek gradientu z momentem (Momentum)

Metoda *momentum* to usprawnienie klasycznego spadku gradientu, które wprowadza do aktualizacji wag składnik bezwładności (momentum) odpowiednio skalowany przez parametr  $\gamma$ . Pozwala to na użycie większego współczynnika uczenia. Tempo konwergencji znacząco wzrasta, w szczególności w trudnych obszarach funkcji kosztu z dużą ilością minimów lokalnych.

$$\begin{aligned} 1 &= \gamma + \eta \\ v_t &= \gamma v_{t-1} + \eta \nabla_{\theta} L(\theta_t), \\ \theta_{t+1} &= \theta_t - v_t. \end{aligned}$$

- $\theta_t$  — wektor parametrów modelu w kroku  $t$ .
- $\theta_{t+1}$  — wektor parametrów modelu po wykonaniu aktualizacji.

- $L(\theta_t)$  — wartość funkcji straty dla parametrów  $\theta_t$ .
- $\nabla_{\theta}L(\theta_t)$  — gradient funkcji straty względem parametrów modelu, obliczony w punkcie  $\theta_t$ .
- $v_t$  — wektor aktualizacji w kroku  $t$ , uwzględniający zarówno bieżący gradient, jak i wpływ poprzednich aktualizacji.
- $v_{t-1}$  — wektor aktualizacji z poprzedniego kroku.
- $\eta$  — współczynnik uczenia (*learning rate*), określający wielkość kroku aktualizacji.
- $\gamma \in [0, 1)$  — współczynnik momentu (*momentum coefficient*), określający stopień zachowania informacji o poprzednich aktualizacjach.
- $t$  — numer iteracji procesu optymalizacji.

Efektom jest filtr wygładzający historię gradientów, co przyspiesza konwergencję i redukuje oscylacje, a także ułatwia przeciskanie przez lokalne minima.

### Metoda przyspieszonego gradientu

Metoda przyspieszonego gradientu, nazywana metodą Nestorova od nazwiska autora, jest dalszym usprawnieniem metody z momentem, w którym gradient jest obliczany nie w bieżącym położeniu parametrów, a w przewidywanym „przyszłym” położeniu modelu. Dzięki temu aktualizacja jest bardziej precyzyjna i stabilna, co pozwala uniknąć nadmiernego przeskoczenia minimum [19]

$$v_t = \gamma v_{t-1} + \eta \nabla_{\theta}L(\theta_t - \gamma v_{t-1}),$$

$$\theta_{t+1} = \theta_t - v_t.$$

W praktyce metoda Nesterova jest bardziej stabilna od klasycznego momentu i często prowadzi do szybszej konwergencji, zwłaszcza w sieciach głębokich

### RMSProp (Root Mean Square Propagation)

RMSProp to metoda optymalizacji z adaptacyjnymi współczynnikami uczenia. Jest ona modyfikacją optymalizatora AdaGrad (Adaptive Gradient). Algorytmy tego typu dostosowują tempo uczenia dla każdego parametru indywidualnie. [8].

Aktualizacje w RMSProp zapisuje się jako:

$$V_t = \beta V_{t-1} + (1 - \beta) (\nabla_{\theta}L(\theta_t))^2,$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{V_t + \epsilon}} \nabla_{\theta}L(\theta_t),$$

gdzie:

- $\beta$  (typowo ok. 0.9) — współczynnik wygładzania,
- $\epsilon$  — mała stała dla stabilności numerycznej i uniknięcia dzielenia przez zero
- $\eta$  — współczynnik uczenia.



Dzięki temu zwiększamy tempo nauki parametrów, których gradient jest mały oraz zwalnimy proces nauki parametrów z porównywalnie stromym gradientem. Chroni to sieć przed pominięciem optimum w regionie o stromym gradiencie oraz przyspiesza proces nauki w przeciwnym przypadku.

**Zalety RMSProp:**

- Utrzymuje adaptacyjny krok uczenia bez jego nadmiernej redukcji,
- Poprawia zbieżność w problemach o zmiennych gradientach — często stosowany w RNN.

**Wady:**

- Wymaga starannego doboru hiperparametrów,
- Może być mniej skuteczny w przypadku ekstremalnie rzadkich gradientów — wtedy lepszy jest Adam.

**Adam (Adaptive Moment Estimation)**

Adam stara się łączyć zalety optymalizatorów momentum i RMSProp. Uwzględnia kierunek zmian gradientu i wygładza aktualizacje tak jak momentum oraz adaptacyjnie skaluje krok uczenia względem wariancji gradientów jak RMSProp. Z tego powodu jest on obecnie, wraz z wariantami, najpopularniejszym optymalizatorem sieci neuronowych.

W Adamie dla każdego parametru  $\theta$  śledzi się dwa momenty:

Pierwszy moment, średnia gradientów

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

Drugi moment, średnia kwadratów gradientów

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$$

Ze względu na początkowe wartości zerowe  $m_t$  oraz  $v_t$  wprowadza się poprawki biasu. Dzięki nim na początku uczenie nie jest spowolnione.

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t,$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2,$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t}$$

Finalna aktualizacja wag ma postać

$$\theta_{t+1} = \theta_t - \frac{\eta \hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon},$$

gdzie  $g_t = \nabla_{\theta} L(\theta_t)$ ,  $\beta_1$ ,  $\beta_2$  są współczynnikami wygładzania (np. 0.9 i 0.999), a  $\epsilon$  to mała wartość stabilizująca.

**Zalety:**

- Adaptacyjny krok dla każdego parametru,

- Efektywny obliczeniowo i pamięciowo,
- Działa dobrze przy danych z szumem, gradientach niestabilnych.

**Wady:**

- Możliwe problemy ze zbieżnością w funkcjach wypukłych,
- Czasem gorsza generalizacja niż klasyczne SGD z momentum,
- Wymaga dostrojenia wielu hiperparametrów.

[12]

## 2.7 Problemy gradientowe

Wraz ze wzrostem głębokości sieci neuronowych proces uczenia staje się coraz bardziej podatny na problemy związane z propagacją błędów i stabilnością optymalizacji. Kluczowym czynnikiem wpływającym na skuteczność uczenia jest sposób, w jaki gradienty funkcji kosztu rozchodzą się przez kolejne warstwy modelu. Jeżeli wartości te zanikają lub eksplodują, uczenie głębokiej sieci staje się nieefektywne lub wręcz niemożliwe. Poniżej przedstawiono najważniejsze zjawiska i techniki ich łagodzenia

### Nasylenie

Zjawisko nasycenia występuje, gdy dla dużych wartości wejścia funkcja aktywacji osiąga swoje asymptotyczne maksimum lub minimum, a jej pochodna staje się bliska zeru. W takich warstwach gradient błędów praktycznie nie przepływa dalej, co prowadzi do spowolnienia lub całkowitego zatrzymania procesu uczenia.

Typowym przykładem są funkcje sigmoidalne i tangens hiperboliczny, które dla dużych wartości  $|x|$  przestają reagować na zmiany sygnału wejściowego. Wprowadzenie funkcji ReLU i jej wariantów rozwiązało ten problem dla dodatnich wartości argumentu, choć nadal może prowadzić do tzw. martwych neuronów – przypadków, w których gradient po stronie ujemnej jest stale równy zero.

Dodatkowe techniki, takie jak Leaky ReLU czy ELU, wprowadzają niewielkie nachylenie w obszarze ujemnym, co pozwala zachować przepływ gradientu i utrzymać aktywność neuronów w całej sieci.

### Skośność rozkładu aktywacji

Kolejnym problemem, często pomijanym, jest skośność rozkładu aktywacji (ang. bias shift). Występuje on, gdy funkcje aktywacji generują wyłącznie dodatnie wartości, jak w przypadku sigmoidy, której zakres wynosi  $(0, 1)$ . W takiej sytuacji średnia wartość aktywacji jest dodatnia, co powoduje przesunięcie rozkładu wejść kolejnych warstw w kierunku dodatnich wartości. W efekcie sieć pracuje w obszarze nasycenia funkcji aktywacji, a gradienty stopniowo zanikają.

Skośność rozkładu aktywacji utrudnia także utrzymanie stabilnego przepływu sygnału i powoduje, że wagi w kolejnych warstwach są zmuszane do kompensowania przesunięć statystycznych. Rozwiązaniem tego problemu jest stosowanie funkcji aktywacji o zakresie symetrycznym względem zera,

takich jak  $\tanh(x)$ , lub metod normalizacji danych, które utrzymują średnią aktywacji blisko zera (np. Batch Normalization).

### Zanikanie gradientu

Zjawisko zanikającego gradientu polega na tym, że wartości gradientów w trakcie propagacji wstecznej stają się coraz mniejsze w miarę przechodzenia przez kolejne warstwy. W konsekwencji wcześniejsze warstwy sieci uczą się bardzo wolno, podczas gdy końcowe – położone bliżej wyjścia – aktualizują swoje wagi znacznie szybciej. Problem ten wynika głównie z własności funkcji aktywacji, takich jak sigmoida lub tangens hiperboliczny, których pochodne przyjmują wartości bliskie zeru dla dużych wartości argumentu. Dla przykładu, w przypadku tangensa hiperbolicznego:

$$\tanh'(x) = 1 - \tanh^2(x)$$

co oznacza, że dla  $|x| > 3$  pochodna staje się praktycznie zerowa. Jeżeli gradient pochodnej jest mniejszy niż jeden, a sieć zawiera wiele warstw, iloczyn kolejnych pochodnych szybko dąży do zera, przez co sygnał błędu praktycznie nie dociera do wcześniejszych warstw.

Aby przeciwdziałać zanikaniu gradientu, wprowadza się funkcje aktywacji, które nie nasycają się dla dodatnich wartości argumentu, takie jak ReLU i jej warianty (LeakyReLU, PReLU, ELU). Dodatkowo stosuje się odpowiednie metody inicjalizacji wag (np. He lub Xavier) oraz techniki normalizacji, które utrzymują rozkład aktywacji w kontrolowanym zakresie. [4]

### Eksplodujący gradient

Przeciwstawnym zjawiskiem jest eksplodujący gradient, który występuje wtedy, gdy wartości gradientów w trakcie propagacji wstecznej stają się coraz większe, często osiągając wartości prowadzące do niestabilności numerycznej. W takim przypadku wagi sieci zaczynają przyjmować bardzo duże wartości, co skutkuje rozbieżnością funkcji kosztu i przerwaniem procesu uczenia. Problem ten występuje szczególnie często w głębokich sieciach rekurencyjnych oraz w modelach o źle dobranych współczynnikach uczenia.

Jednym z najczęściej stosowanych sposobów zapobiegania eksplozji gradientów jest ograniczanie ich normy (ang. gradient clipping), które polega na skalowaniu wektora gradientu, jeśli jego długość przekracza ustalony próg  $\tau$ :

$$g \leftarrow \frac{g}{\max\left(1, \frac{\|g\|}{\tau}\right)}$$

gdzie:

- $g$  — wektor gradientu
- $\|g\|$  - jego norma (najczęściej euklidesowa, czyli  $_2$ )
- $\tau$  - ustalony próg (np. 1.0)

Dzięki temu uczenie pozostaje stabilne nawet w sytuacjach, gdy lokalny gradient przyjmuje bardzo duże wartości. Innym sposobem łagodzenia tego problemu jest obniżenie współczynnika uczenia lub zastosowanie metod optymalizacji adaptacyjnej, takich jak RMSProp czy Adam, które automatycznie dopasowują krok optymalizacji dla każdego parametru.

## 2.8 Techniki stabilizacji i usprawnienia procesu uczenia

Występowanie problemów takich jak zanikający gradient, eksplodujący gradient czy nasycenie funkcji aktywacji powoduje, że odpowiednie metody stabilizacji są niezbędne do osiągnięcia zbieżności. Współczesne sieci wykorzystują szereg technik, które poprawiają przepływ gradientu, ograniczają przeuczenie oraz przyspieszają proces optymalizacji. Do najczęściej stosowanych należą: Batch Normalization, Dropout oraz Learning Rate Scheduling.

### Batch Normalization

Jedną z najważniejszych metod poprawiających stabilność uczenia jest Batch Normalization, zaproponowana przez Ioffe i Szegedy'ego w 2015 roku. Jej głównym celem jest utrzymanie stabilnego rozkładu aktywacji w kolejnych warstwach poprzez normalizację danych wejściowych do każdej z nich. W praktyce polega to na przeskalowaniu i przesunięciu aktywacji w taki sposób, aby ich średnia i wariancja w obrębie mini-batcha pozostawały w ustalonych granicach.

Dla danej partii danych oblicza się średnią i odchylenie standardowe:

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i, \quad \sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$$

a następnie normalizuje się wejście:

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}},$$

gdzie  $\epsilon$  to mała stała zapobiegająca dzieleniu przez zero. Taka normalizacja sprawia, że aktywacje w każdej warstwie mają średnią równą zero i wariancję równą jeden, co stabilizuje propagację gradientów wstecz i zapobiega zarówno ich zanikaniu, jak i eksplozji.

Jednakże, całkowite znormalizowanie aktywacji mogłoby ograniczyć zdolność sieci do reprezentacji nieliniowych przekształceń. Dlatego w Batch Normalization wprowadza się dodatkowe parametry skalujące i przesuwające, oznaczane odpowiednio jako  $\gamma$  (skala) i  $\beta$  (przesunięcie). Ostateczna postać wyjścia warstwy po normalizacji to:

$$y_i = \gamma \hat{x}_i + \beta$$

Batch Normalization redukuje wpływ zjawiska internal covariate shift – zmiany rozkładu aktywacji w trakcie uczenia, stabilizując tym samym propagację gradientu i umożliwiając stosowanie wyższego

współczynnika uczenia. W praktyce BN znacząco przyspiesza trening i często poprawia dokładność końcową modelu.

[10]

## Dropout

Drugą powszechnie stosowaną metodą stabilizacji jest Dropout, zaproponowany przez Srivastavę i wsp. w 2014 roku. Technika ta ma na celu ograniczenie zjawiska przeuczenia (ang. overfitting) poprzez losowe wyłączenie części neuronów w trakcie uczenia. W każdej iteracji treningu każdy neuron z prawdopodobieństwem  $p$  zostaje „wyłączony” (tj. jego wyjście zostaje ustawione na zero), co można formalnie zapisać jako:

$$\tilde{h}^{(l)} = h^{(l)} \odot r^{(l)}, \quad r^{(l)} \sim \text{Bernoulli}(p)$$

gdzie  $\odot$  oznacza mnożenie element po elemencie, a w fazie testowej aktywacje są odpowiednio skalowane:

$$h_{\text{test}}^{(l)} = p h_{\text{train}}^{(l)}$$

aby zachować oczekiwaną wartość wyjść. Dropout można interpretować jako rodzaj losowego „ensemble learning” — w każdej iteracji trenowany jest inny podzbiór sieci, a końcowy model działa jak uśrednienie wielu słabszych klasyfikatorów. W efekcie sieć staje się bardziej odporna na szum w danych i lepiej generalizuje na zbiorze testowym [25].

## Pooling

W sieciach spłotowych często stosuje się również operację *poolingu*, której celem jest redukcja rozdzielczości map cech przy zachowaniu najważniejszych informacji o lokalnie wykrytych wzorcach. Mechanizm ten polega na agregacji wartości aktywacji w niewielkich obszarach wejścia, co prowadzi do zmniejszenia wymiaru reprezentacji oraz ograniczenia kosztu obliczeniowego kolejnych warstw.

Najczęściej wykorzystywaną odmianą jest *max pooling*, w której z każdego lokalnego obszaru wybierana jest wartość maksymalna. Dla okna o rozmiarze  $K \times K$  operację tę można zapisać w postaci:

$$y(i,j) = \max_{\substack{0 \leq m < K \\ 0 \leq n < K}} x(i \cdot S + m, j \cdot S + n),$$

gdzie  $S$  oznacza krok przesuwania okna, natomiast  $x$  i  $y$  są odpowiednio mapą wejściową i wyjściową. Alternatywę stanowi *average pooling*, w którym zamiast maksimum obliczana jest średnia wartość aktywacji w danym obszarze:

$$y(i,j) = \frac{1}{K^2} \sum_{m=0}^{K-1} \sum_{n=0}^{K-1} x(i \cdot S + m, j \cdot S + n).$$

Zastosowanie poolingu zmniejsza czułość modelu na niewielkie przesunięcia i lokalne zakłócenia danych wejściowych, a także pozwala zwiększyć efektywny zakres zależności analizowanych przez kolejne warstwy. Jednocześnie nadmierna redukcja rozdzielczości może prowadzić do utraty precyzyjnej informacji przestrzennej, dlatego w zadaniach wymagających dokładnej lokalizacji obiektów lub relacji przestrzennych pooling stosuje się ostrożnie albo zastępuje innymi mechanizmami redukcji wymiaru.

## Learning Rate Scheduling

Proces uczenia sieci neuronowych jest w dużej mierze zależny od wartości współczynnika uczenia  $\eta$ . Stała wartość tego parametru może być nieoptymalna w różnych fazach treningu — zbyt duży krok w pobliżu minimum może powodować oscylacje, a zbyt mały na początku wydłuża proces konwergencji. Z tego powodu stosuje się Learning Rate Scheduling, czyli adaptacyjne strategie zmiany tempa uczenia w czasie.

Najprostszym podejściem jest harmonogram malejący wykładniczo:

$$\eta_t = \eta_0 e^{-kt}$$

gdzie  $\eta_0$  to początkowy współczynnik uczenia,  $t$  — numer epoki, a  $k$  — stała określająca szybkość spadku. Popularne są również strategie krokowe (ang. step decay), w których współczynnik uczenia jest zmniejszany skokowo po określonej liczbie epok, oraz metody adaptacyjne, które dostosowują tempo uczenia dynamicznie w zależności od wartości błędu walidacyjnego (ReduceLROnPlateau).

## Rozdział 3

# Zestawienie użytych rozwiązań

W niniejszym rozdziale przedstawiono zestawienie rozwiązań wykorzystanych w badaniach eksperymentalnych przeprowadzonych w ramach tej pracy. Celem rozdziału jest jednoznaczne zdefiniowanie architektur sieci neuronowych oraz technik uczenia zastosowanych w agentach uczących się gry Blood Bowl z wykorzystaniem metod uczenia ze wzmocnieniem.

Analizie poddano agentów opartych na algorytmach A2C oraz PPO, które stanowią podstawę zastosowanych metod uczenia we wszystkich rozważanych wariantach. W celu zapewnienia porównywalności wyników algorytmu uczenia, sposób reprezentacji stanu oraz mechanizmy interakcji ze środowiskiem zostały w maksymalnym stopniu ujednolicone. Zmienną badawczą pozostają zastosowane algorytmy oraz architektury sieci neuronowych.


W kolejnych podrozdziałach opisano strukturę badanych agentów, sposób reprezentacji danych wejściowych, a następnie szczegółowo omówiono zastosowane architektury konwolucyjne, w tym warianty oparte na blokach ResNet, Inception oraz ich kombinacjach. Rozdział obejmuje również opis technik stabilizacji i usprawnień procesu uczenia, które okazały się istotne w kontekście złożonego środowiska decyzyjnego gry Blood Bowl.

### 3.1 Algorytmy aktor–krytyk

Algorytmy typu aktor–krytyk (ang. *actor–critic*) stanowią klasę metod uczenia ze wzmocnieniem, w których agent uczy się jednocześnie polityki decyzyjnej oraz funkcji wartości. Podejście to łączy zalety metod opartych bezpośrednio na polityce z metodami wykorzystującymi estymację jakości stanów, dzięki czemu umożliwia bardziej stabilne i efektywne uczenie w środowiskach o dużej przestrzeni stanów i akcji, takich jak gra Blood Bowl.

Do tej klasy należą między innymi algorytmy A2C oraz PPO, wykorzystane w niniejszej pracy. Oba podejścia są metodami *on-policy*, co oznacza, że aktualizacja parametrów polityki odbywa się na podstawie trajektorii wygenerowanych przez bieżącą wersję tej polityki. Innymi słowy, agent uczy się bezpośrednio na danych pochodzących z własnej, aktualnie stosowanej strategii działania.

Podejście *on-policy* ma istotne konsekwencje praktyczne. Po każdej aktualizacji parametrów polityki wcześniej zebrane trajektorie przestają w pełni odpowiadać nowemu rozkładowi decyzji, dlatego nie mogą być wykorzystywane w dowolny sposób przez wiele kolejnych iteracji uczenia. Ogranicza to efektywność wykorzystania próbek, ale jednocześnie zwiększa spójność między zachowaniem agenta a optymalizowaną funkcją celu, co sprzyja stabilności uczenia w złożonych, dynamicznych środowiskach decyzyjnych [18, 27].



### Architektura aktor–krytyk (*Actor–Critic*)

W architekturze aktor–krytyk model składa się z dwóch współpracujących komponentów: aktora oraz krytyka. Aktor odpowiada za wybór akcji na podstawie aktualnego stanu środowiska, natomiast krytyk ocenia jakość danego stanu z punktu widzenia oczekiwanych przyszłych nagród.

Aktor reprezentuje politykę decyzyjną agenta, opisaną rozkładem prawdopodobieństwa

$$\pi_{\theta}(a | s),$$

gdzie  $s$  oznacza stan środowiska,  $a$  – akcję, a  $\theta$  – parametry polityki. W przypadku dyskretnej przestrzeni akcji wyjściem aktora jest wektor prawdopodobieństw, na podstawie którego wybierana lub próbkowana jest akcja wykonywana przez agenta.

Krytyk aproksymuje funkcję wartości stanu, czyli oczekiwaną zdyskontowaną sumę przyszłych nagród przy założeniu, że agent będzie postępował zgodnie z bieżącą polityką:

$$V_{\phi}(s) \approx V^{\pi_{\theta}}(s) = \mathbb{E}_{\pi_{\theta}} \left[ \sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid s_t = s \right],$$

gdzie  $r_{t+k}$  oznacza nagrodę otrzymaną w kroku  $t+k$ ,  $\gamma \in (0, 1)$  jest współczynnikiem dyskontowania, a  $\phi$  oznacza parametry krytyka. W praktycznych implementacjach aktor i krytyk często współdzielą



część warstw sieci odpowiedzialnych za ekstrakcję cech, a następnie rozdzielają się na dwie odrębne głowy wyjściowe.

Zastosowanie krytyka pozwala ograniczyć wariancję estymacji gradientu polityki w porównaniu z metodami czysto politycznymi, takimi jak REINFORCE. Krytyk dostarcza bowiem dodatkowego sygnału uczącego, który informuje aktora, czy wynik uzyskany po wykonaniu danej akcji był lepszy, czy gorszy od oczekiwań. Dzięki temu aktualizacje polityki są bardziej stabilne i skuteczniejsze, co ma szczególne znaczenie w środowiskach o wysokiej złożoności decyzyjnej [18].

### Funkcja przewagi (*Advantage Function*)

W algorytmach typu aktor–krytyk aktualizacja parametrów polityki opiera się nie na samej sumie nagród, lecz na funkcji przewagi (ang. *advantage function*). Jej zadaniem jest określenie, na ile dana akcja była lepsza lub gorsza od przeciętnego zachowania polityki w danym stanie.

Formalnie funkcja przewagi definiowana jest jako różnica pomiędzy wartością funkcji akcji a wartością stanu:

$$A(s, a) = Q(s, a) - V(s),$$

gdzie  $Q(s, a)$  oznacza wartość wykonania akcji  $a$  w stanie  $s$ , a  $V(s)$  jest wartością stanu. Interpretacyjnie  $A(s, a) > 0$  oznacza, że akcja  $a$  była lepsza od średniej oczekiwanej w stanie  $s$ , natomiast  $A(s, a) < 0$  wskazuje, że była gorsza.

W praktycznych algorytmach  $Q(s, a)$  nie jest obliczane jawnie, ponieważ jego estymacja jest kosztowna i obciążona dużą wariancją. Zamiast tego funkcja przewagi jest aproksymowana na podstawie obserwowanych nagród oraz estymaty krytyka. Typowym przybliżeniem jest  $n$ -krokowy zwrot:

$$A_t \approx R_t^{(n)} - V(s_t),$$

gdzie  $R_t^{(n)}$  oznacza zdyskontowaną sumę  $n$  kolejnych nagród z oszacowaniem wartości stanu końcowego przez krytyka. Bardziej zaawansowanym podejściem jest uogólniona estymacja przewagi (GAE), która wykorzystuje ważoną sumę błędów TD z wielu kroków czasowych.

Zastosowanie funkcji przewagi pełni rolę tzw. *baseline* i prowadzi do istotnego zmniejszenia wariancji estymatora gradientu. W rezultacie polityka uczona jest nie na podstawie surowych nagród, lecz informacji o tym, czy dana decyzja była lepsza czy gorsza od oczekiwań w danym stanie. Mechanizm ten stanowi kluczowy element stabilności i efektywności algorytmów A2C oraz PPO. [18, 24, 26].

### Błąd różnicy czasowej

Kluczowym pojęciem w algorytmach aktor–krytyk jest błąd różnicy czasowej (ang. *Temporal Difference error*, TD error), który stanowi lokalną miarę niedokładności estymacji funkcji wartości przez krytyka. Błąd TD łączy w sobie idee metod Monte Carlo oraz dynamicznego programowania,

umożliwiając aktualizację wartości stanu na podstawie pojedynczego kroku interakcji ze środowiskiem.

Dla pojedynczego kroku czasowego błąd TD ma postać:

$$\delta_t = r_t + \gamma V_\theta(s_{t+1}) - V_\theta(s_t),$$

- $s_t$  — stan środowiska w chwili  $t$ ,
- $a_t$  — akcja wykonana w stanie  $s_t$ ,
- $r_t$  — nagroda otrzymana po wykonaniu akcji  $a_t$ ,
- $s_{t+1}$  — stan osiągnięty po przejściu środowiska,
- $V_\theta(s_t)$  — estymowana przez krytyka wartość stanu  $s_t$ ,
- $\gamma \in [0, 1]$  — współczynnik dyskontowania,
- $\delta_t$  — błąd różnicy czasowej.

Wartość  $\delta_t$  informuje, czy rzeczywisty rezultat przejścia był lepszy czy gorszy od przewidywania krytyka. Jeżeli  $\delta_t > 0$ , to uzyskany wynik okazał się korzystniejszy od oczekiwanego, natomiast gdy  $\delta_t < 0$ , przejście było gorsze niż wskazywała bieżąca estymacja funkcji wartości.

W praktyce błąd TD pełni w metodach aktor–krytyk dwie podstawowe funkcje. Po pierwsze, stanowi sygnał uczący dla krytyka, którego parametry są aktualizowane tak, aby zmniejszać różnicę pomiędzy przewidywaną wartością stanu a wartością docelową. Po drugie, może służyć jako najprostsze przybliżenie funkcji przewagi:

$$A_t \approx \delta_t.$$

Takie przybliżenie jest szczególnie naturalne w jednokrokowych metodach aktor–krytyk [27].

## 3.2 Advantage Actor-Critic (A2C)

### A2C, a A3C

Różnica pomiędzy A2C i A3C dotyczy przede wszystkim sposobu równoległego zbierania doświadczeń i aktualizacji parametrów sieci. W A3C (*Asynchronous Advantage Actor–Critic*) wiele niezależnych procesów (aktorów-uczących) równolegle oddziałuje ze środowiskiem i wyznacza gradienty, które są następnie stosowane do wspólnego modelu w sposób asynchroniczny (bez globalnej synchronizacji kroków), co prowadzi do mniej skorelowanych próbek i może stabilizować uczenie [18]. Z kolei A2C (*Advantage Actor–Critic*) stanowi wariant synchroniczny tego podejścia: próbki z wielu równoległych środowisk są agregowane w jedną paczkę (batch), po czym wykonywana jest pojedyncza, wspólna aktualizacja parametrów, co upraszcza implementację oraz czyni przebieg uczenia bardziej deterministycznym przy zachowaniu tej samej ogólnej struktury aktor–krytyk [20].

### Generowanie danych uczących: rollout i długość trajektorii w A2C

W algorytmie A2C dane uczące powstają w sposób iteracyjny poprzez równoległe generowanie doświadczeń w wielu instancjach środowiska. W każdej iteracji uruchamia się  $N$  środowisk działających równoległe (ang. *vectorized environments*), które wykorzystują tę samą, aktualną politykę  $\pi_\theta$ . Następnie z każdego środowiska zbierany jest fragment trajektorii (rollout) o stałej długości  $T$  kroków, często oznaczanej jako  $t_{\max}$ . Otrzymana paczka danych składa się z obserwacji, akcji i nagród:

$$\mathcal{B} = \left\{ \left( s_t^{(i)}, a_t^{(i)}, r_t^{(i)}, s_{t+1}^{(i)} \right) : i = 1, \dots, N, t = 0, \dots, T-1 \right\}.$$

Po zebraniu paczki  $\mathcal{B}$  wyznacza się na jej podstawie wielkości wymagane do uczenia, w szczególności przybliżone zwroty (np.  $n$ -krokowe) oraz estymaty przewagi  $A_t$ , a następnie wykonuje się jedną synchroniczną aktualizację parametrów sieci na całej paczce. Dopiero po tej aktualizacji generowana jest kolejna paczka danych, już z użyciem zaktualizowanej polityki, co jest zgodne z charakterem on-policy A2C [18, 20].

Wzory zawierające operator wartości oczekiwanej  $\mathbb{E}_t[\cdot]$  interpretowane są w praktyce jako uśrednienie po wszystkich próbkach z paczki rollout:

$$\mathbb{E}_t[f_t] \approx \frac{1}{NT} \sum_{i=1}^N \sum_{t=0}^{T-1} f_t^{(i)}.$$

Takie ujęcie jednoznacznie określa, że estymacja gradientu oraz wartości strat aktora i krytyka opiera się na skończonej próbce doświadczeń zebranych w bieżącej iteracji uczenia.

### Funkcja straty w A2C

Uczenie w algorytmie A2C realizowane jest poprzez minimalizację funkcji straty złożonej z komponentów odpowiadających aktorowi (polityce) oraz krytykowi (funkcji wartości), często uzupełnionej o składnik entropii wspierający eksplorację. Taka konstrukcja umożliwia jednocześnie doskonalenie polityki oraz estymację wartości stanu, co stabilizuje proces uczenia w środowiskach o dużej złożoności decyzyjnej [18].

Składnik aktora wynika z twierdzenia o gradiencie polityki i przyjmuje postać ujemnej logarytmicznej wiarygodności wybranej akcji, ważonej estymowaną funkcją przewagi:

$$\mathcal{L}_{\text{actor}}^{\text{A2C}}(\theta) = -\mathbb{E}_t [\log \pi_\theta(a_t | s_t) A_t].$$

Postać ta wzmacnia decyzje przynoszące wyniki ponadprzeciętne ( $A_t > 0$ ) oraz tłumi decyzje gorsze od oczekiwanych ( $A_t < 0$ ) [26].

Składnik krytyka odpowiada za aproksymację funkcji wartości stanu i najczęściej definiowany jest jako błąd średniokwadratowy względem przybliżonej wartości docelowej:

$$\mathcal{L}_{\text{critic}}^{\text{A2C}}(\theta) = \mathbb{E}_t \left[ \left( V_\theta(s_t) - \hat{V}_t \right)^2 \right],$$

gdzie  $\hat{V}_t$  może oznaczać np. n-krokowy zwrot lub wartość opartą na błędzie TD. Krytyk pełni rolę funkcji bazowej (baseline), zmniejszając wariancję estymatora gradientu aktora i poprawiając stabilność uczenia [18].

W wielu implementacjach A2C stosuje się również bonus entropijny:

$$\mathcal{L}_{\text{entropy}}^{\text{A2C}}(\theta) = -\mathbb{E}_t [\mathcal{H}(\pi_\theta(\cdot | s_t))].$$

Całkowita funkcja straty może być zapisana jako:

$$\mathcal{L}^{\text{A2C}}(\theta) = \mathcal{L}_{\text{actor}}^{\text{A2C}} + c_v \mathcal{L}_{\text{critic}}^{\text{A2C}} - c_e \mathcal{L}_{\text{entropy}}^{\text{A2C}},$$

gdzie  $c_v$  oraz  $c_e$  są współczynnikami wagowymi regulującymi wpływ krytyka i entropii.

### 3.3 PPO

Proximal Policy Optimization (PPO) jest algorytmem typu actor–critic zaproponowanym jako praktyczna alternatywa dla metod z ograniczeniem kroku aktualizacji polityki, takich jak TRPO. Główna idea PPO polega na wykonywaniu kilku kroków optymalizacji na tej samej paczce trajektorii, ale w taki sposób, aby nowa polityka nie odsunęła się zbyt gwałtownie od polityki, która wygenerowała dane. Osiąga się to przez zastosowanie funkcji celu opartej na ilorazie prawdopodobieństw (importance sampling ratio) oraz mechanizmie *clippingu*, który ogranicza wpływ zbyt dużych zmian polityki [22, 24].

#### Funkcja celu PPO (clipped surrogate objective)

Niech  $\theta_{\text{old}}$  oznacza parametry polityki użytej do wygenerowania danych (rolloutu), a  $\theta$  – parametry aktualizowanej polityki. Definiuje się iloraz:

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)}.$$

W PPO maksymalizuje się tzw. *surrogate objective* z obciążeniem (clipping):

$$\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t [\min(r_t(\theta)A_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) A_t)],$$

gdzie  $A_t$  jest estymatą przewagi (np. z GAE), a  $\epsilon$  jest hiperparametrem ograniczającym dopuszczalną zmianę polityki w pojedynczej aktualizacji. Mechanizm  $\min(\cdot)$  wraz z  $\text{clip}$  powoduje, że gdy  $r_t(\theta)$

wychodzi poza przedział  $[1 - \epsilon, 1 + \epsilon]$ , dalsze zwiększanie  $r_t(\theta)$  nie przynosi już korzyści w funkcji celu, co stabilizuje uczenie i zapobiega destrukcyjnym, zbyt agresywnym krokom optymalizacji [24].

W praktycznych implementacjach PPO optymalizuje się łączną funkcję straty, zawierającą również komponent krytyka (aproksymacja wartości) oraz bonus entropijny:

$$\mathcal{L}^{\text{PPO}}(\theta) = -\mathcal{L}^{\text{CLIP}}(\theta) + c_v \mathbb{E}_t \left[ \left( V_\theta(s_t) - \hat{V}_t \right)^2 \right] - c_e \mathbb{E}_t [\mathcal{H}(\pi_\theta(\cdot | s_t))],$$

gdzie  $\hat{V}_t$  oznacza wartość docelową (np. zwrot  $R_t$ ), a  $c_v, c_e$  są wagami części krytyka i entropii. Taka postać odpowiada standardowej praktyce w actor–critic, natomiast różnica PPO polega na zastosowaniu członu  $\mathcal{L}^{\text{CLIP}}$  zamiast klasycznej straty polityki bez ograniczenia kroku [24].

### Algorytm PPO w ujęciu praktycznym (pętla uczenia)

W odróżnieniu od A2C, w którym po zebraniu rolloutu wykonuje się zwykle pojedynczą aktualizację, PPO wykorzystuje tę samą paczkę danych przez kilka epok optymalizacji (mini-batche). Typowy schemat jest następujący:

1. Zbierz rollout o długości  $T$  w  $N$  równoległych środowiskach, używając polityki  $\pi_{\theta_{\text{old}}}$ . Zapisz m.in.  $(s_t, a_t, r_t)$  oraz  $\log \pi_{\theta_{\text{old}}}(a_t | s_t)$  i estymaty  $V_{\theta_{\text{old}}}(s_t)$ .
2. Wyznacz  $\hat{V}_t$  (zwroty) oraz  $A_t$  (np. z GAE) na podstawie zebranej trajektorii [23].
3. Przez  $K$  epok wykonuj optymalizację SGD/Adam na losowanych mini-batchach z tej samej paczki, minimalizując  $\mathcal{L}^{\text{PPO}}(\theta)$ .
4. Ustaw  $\theta_{\text{old}} \leftarrow \theta$  i powtórz proces dla kolejnego rolloutu.

Dzięki ilorazowi  $r_t(\theta)$  PPO pozostaje metodą bliską on-policy, ale efektywniej wykorzystuje próbki, ponieważ dopuszcza kilka przejść optymalizacyjnych po tych samych danych przy jednoczesnym ograniczeniu odchylenia polityki.

### Rodzaj sieci neuronowej w PPO

PPO nie wymaga odrębnego typu sieci względem ogólnej architektury actor–critic: najczęściej stosuje się jedną sieć z *współdzielonym trzonem* (np. CNN przetwarzające wejście przestrzenne), a następnie dwie głowy:

- **głowa polityki (aktor)**: generuje parametry rozkładu  $\pi_\theta(a | s)$  (w Blood Bowl zwykle logity dla akcji dyskretnych),
- **głowa wartości (krytyk)**: generuje skalar  $V_\theta(s)$ .

Kluczowa różnica implementacyjna względem prostszych wariantów actor–critic polega na tym, że podczas uczenia PPO potrzebuje stabilnego odniesienia do polityki zbierającej dane, czyli przechowywania  $\log \pi_{\theta_{\text{old}}}(a_t | s_t)$  (lub równoważnie  $\pi_{\theta_{\text{old}}}(a_t | s_t)$ ), aby obliczać  $r_t(\theta)$ . Pozostałe elementy (np. maskowanie akcji w przestrzeni dyskretniej) mogą być zastosowane analogicznie jak

w innych agentach actor-critic, ponieważ wpływają jedynie na postać  $\pi_{\theta}(\cdot | s)$ , a nie na samą konstrukcję PPO.

### 3.4 Współdzielenie części konwolucyjnej

We wszystkich analizowanych architekturach zastosowano wspólną część konwolucyjną (ang. *trunk*), która przetwarza przestrzenne wejście sieci. Dopiero po ekstrakcji cech następuje rozdzielenie na dwie głowy: polityki i wartości. Takie podejście ma kilka istotnych zalet:

- redukuje liczbę parametrów modelu
- pozwala obu głowom korzystać z tej samej reprezentacji stanu,
- znacząco obniża koszty obliczeniowe w porównaniu do tworzenia dwóch oddzielnych sieci.

W praktyce trunk CNN odpowiada za mapowanie danych przestrzennych na wektor cech, który następnie jest łączony z danymi nieprzestrzennymi i przekazywany do końcowych warstw gęstych obu głów.

### 3.5 Reprezentacja danych wejściowych

W przypadku gry Blood Bowl stan gry ma charakter złożony i heterogeniczny: zawiera zarówno informacje przestrzenne (układ zawodników, lokalizacja piłki, strefy zagrożeń), jak i nieprzestrzenne (licznik tur, aktywny etap procedury gry, dostępne przerzuty). Dlatego konieczne jest zastosowanie reprezentacji umożliwiającej jednoczesne efektywne przetwarzanie danych o różnych charakterystykach strukturalnych.

W pracy przyjęto podział reprezentacji danych wejściowych na dwa niezależne strumienie: strumień przestrzenny, przetwarzany przez konwolucyjne sieci neuronowe, oraz strumień nieprzestrzenny, analizowany za pomocą klasycznych warstw w pełni połączonych.

#### Strumień Przestrzenny

Strumień przestrzenny stanowi tensor opisujący układ gry na planszy w formie wielowarstwowej mapy cech. Tensor wejściowy ma postać:

$$X \in \mathbb{R}^{C \times H \times W}$$

gdzie

- $C$  oznacz liczbę kanałów cech,
- $H \times W$  odpowiada wymiarom planszy.

Botbowl w formule turniejowej udostępnia 44 kanały. Kanały te zawierają między innymi informacje o

- położenie zawodników drużyny gracza
- położenie zawodników przeciwnika
- parametry zawodników (siła, zwinności, prędkość)

- położenie piłki
- strefa punktowa własnej drużyny
- strefa punktowa przeciwnej drużyny
- pozycje na których można wykonać akcję push
- pozycja wybranego zawodnika
- stany zawodników(ogłuszony, po ruchu)
- szanse na wykonanie bloku

### strumień nie przestrzenny

Drugim komponentem reprezentacji danych jest strumień nieprzestrzenny, zawierający wszystkie informacje dotyczące gry, których nie da się w sposób naturalny odwzorować jako mapę dwuwymiarową. Są to np. numer aktualnej tury, flagi opisujące możliwe operacje w danej chwili, dostępne ponowne rzuty obydwu drużyn. Jest on zapisywany w postaci wektora.

$$y \in \mathbb{R}^d$$

gdzie  $d$  oznacza liczbę cech.

Strumień nieprzestrzenny jest przetwarzany przez warstwy gęste, które mapują go na reprezentację ukrytą

$$h = \sigma(Wy + b)$$

### Integracja strumieni danych

Po przetworzeniu oddzielnych strumieni następuje ich agregacja:

$$z = [\text{flatten}(f_{\text{CNN}}(X)), h]$$

gdzie

- $f_{\text{CNN}}(\cdot)$  oznacza działanie trzonu konwolucji
- $h$  jest przetworzonym wektorem cech skalarnych
- operator  $[\cdot]$  oznacza konkatenację wektorową.

Powstały wektor  $z$  stanowi skondensowaną reprezentację stanu gry zawierającą zarówno informacje przestrzenne, jak i skalarne. W tej formie trafia on do kolejnych warstw sieci, które generują:

- wartości polityki (logity akcji)
- estymatę funkcji wartości  $V_{\theta}(s)$

## 3.6 Architektura typu CNN z blokiem Inception

W wersji podstawowej sieci konwolucyjne posiadają stałe rozmiary filtrów (np.  $3 \times 3$ ), co ogranicza ich zdolność do równoczesnego wychwytywania cech lokalnych i bardziej globalnych. Aby zwiększyć

elastyczność i reprezentatywność ekstraktora cech, w niniejszej pracy zastosowano rozszerzenie w postaci bloku Inception, inspirowanego architekturą GoogLeNet

Blok Inception został zaprojektowany tak, aby umożliwić równoległe przetwarzanie tych samych danych za pomocą operatorów konwolucyjnych o różnych rozmiarach filtrów. Każdy z filtrów bada dane w innej skali przestrzennej, co pozwala na lepsze uchwycenie wieloskalowych zależności obecnych na planszy Blood Bowl, takich jak:

- lokalne konfiguracje zawodników (bloki, strefy ataku, pojedyncze zagrożenia)
- średnie struktury pozycyjne (np. zagęszczenia w centrum, formacje ofensywne)
- zależności dalekiego zasięgu (np. ścieżki podań, ustawienia defensywne)

Formalnie, niech wejście do bloku oznaczone będzie jako tensor:

$$X \in \mathbb{R}^{C \times H \times W}$$

Blok inception składa się z zestawu równoległych ścieżek konwolucyjnych, z których każda operuje na filtrach o innym rozmiarze jądra:

$$Y_k = f_k(X), k = 1, 2, 3, \dots, K$$

gdzie  $f_k(\cdot)$  to operacja konwolucji o jądrze  $k \times k$ , Następnie wszystkie przetworzone reprezentacje są łączone wzdłuż wymiaru kanałów:

$$Y = \text{concat}(Y_1, Y_2, \dots, Y_k)$$

Tak powstała cecha końcowa łączy informacje wieloskalowe w jednym tensorze.

Zastosowanie bloków Inception w sieci konwolucyjnej daje kilka istotnych korzyści.

Decyzje podejmowane przez agenta w Blood Bowl zależą zarówno od lokalnych interakcji (np. możliwości bloku), jak i globalnych struktur (np. ustawienie do biegu po przyłożeniu). Architektura Inception pozwala modelować oba rodzaje zależności w ramach jednej warstwy.

Blok Inception jest modularny i dobrze współpracuje z pozostałymi elementami architektur A2C i PPO.

Może być on nakładany sekwencyjnie, zwiększając głębokość modelu. W praktyce zastosowano od kilku do kilkunastu takich bloków w zależności od rozmiaru planszy i dostępnych zasobów obliczeniowych.

## Ograniczenia

Mimo licznych zalet, klasyczny Inception stosowany jako wielowarstwowy trunk ma pewne ograniczenia:

- brak mechanizmu kompensacji zanikania gradientu przy głębokich sieciach,
- możliwe zwiększenie kosztów obliczeń przy dużej liczbie kanałów wyjściowych,
- brak informacji rezydualnej, co utrudnia stabilne uczenie w głębokich modelach.



Z tego względu w kolejnych architekturach wprowadzono połączenia rezydualne oraz klasyczną strukturę ResNet, co pozwala poprawić stabilność i jakość ekstrakcji cech.

## 3.7 Resnet

Kolejną analizowaną architekturą jest sieć konwolucyjna oparta na klasycznym modelu ResNet, charakteryzującym się zastosowaniem bloków rezydualnych o stałej liczbie kanałów. Architektura ta jest uznawana za jedną z najbardziej stabilnych struktur CNN do głębokiej ekstrakcji cech. W przeciwieństwie do bloku Inception, blok rezydualny w ResNet wykorzystuje konwolucje o stałym rozmiarze (zwykle  $3 \times 3$ ), jednak równoważy brak wieloskalarności większą głębokością i stabilnością gradientu. Podstawowy blok ResNet składa się z dwóch konwolucji  $3 \times 3$  z normalizacją i nieliniowością:

$$F(X) = \sigma(\text{BN}(W_2 * \sigma(\text{BN}(W_1 * X))))$$

gdzie,

- $W_1, W_2$  są filtrami konwolucyjnymi
- BN oznacza normalizację BatchNorm
- $\sigma$  jest funkcją aktywacji

Wyjście bloku powstaje poprzez dodanie wejścia do przetworzonej reprezentacji:

$$Y = X + F(X)$$

### Zalety ResNet

ResNety zostały zaprojektowane specjalnie w celu umożliwienia trenowania bardzo głębokich sieci, nawet powyżej 100 warstw. Połączenia rezydualne stabilizują gradient, co istotnie poprawia możliwości ekstrapolacyjne sieci.

Bloki ResNet dobrze radzą sobie z wykrywaniem średniego i globalnego kontekstu przestrzennego, co jest istotne w ocenie pozycji zawodników, wyznaczaniu ścieżek ruchu i szacowaniu zagrożeń.

### Wady ResNet

Choć ResNet jest stabilny i prosty w implementacji, brak mechanizmu wieloskalarności może prowadzić do utraty informacji istotnych dla niektórych sytuacji taktycznych, np. jednoczesnej oceny bloków lokalnych i formacji globalnych. W praktyce jednak jego stabilność i przewidywalność czynią go doskonałą bazą do porównania z bardziej złożonymi architekturami.

## 3.8 Inception-Residual

Trzecią z analizowanych architektur jest model oparty na blokach Inception, wzbogacony o mechanizm połączeń rezydualnych (residual connections). Rozwiązanie to stanowi połączenie wieloskalowej

analizy cech, charakterystycznej dla modułu Inception, z właściwościami stabilizującymi proces uczenia, typowymi dla sieci ResNet. Architektura ta została zaprojektowana w celu zwiększenia głębokości sieci oraz poprawy jakości gradientu podczas optymalizacji, co jest szczególnie istotne w środowiskach o dużej złożoności, takich jak Blood Bowl.

W klasycznym bloku Inception wykorzystuje się równoległe konwolucje o różnych rozmiarach filtrów, które następnie są konkatencjonowane. W obecnej architekturze wynik działania bloku Inception oznaczamy jako:

$$F(X) = \text{concat}(f_1(X), f_3(X), f_5(X))$$

Aby zwiększyć stabilność uczenia i umożliwić efektywne propagowanie gradientu, wprowadzono połączenie rezydualne, które dodaje wejście bloku do jego wyjścia:

$$Y = F(X) + R(X)$$

gdzie  $R(X)$  jest transformacją dopasowującą wymiar kanałów wejściowych i wyjściowych. W przypadku zgodnej liczby kanałów stosuje się połączenie tożsamościowe  $R(X) = X$ . W przypadku rozbieżności stosuje się projekcję:

$$R(X) = W_s * X$$

, gdzie  $W_s$  oznacza konwolucję  $1 \times 1$  dopasowującą wymiar kanałów. Zabieg ten jest analogiczny do rozwiązań stosowanych w ResNet.

Architektura Residual Inception Network łączy komplementarne zalety modułów Inception oraz bloków rezydualnych ResNet, tworząc model o wysokiej zdolności reprezentacyjnej przy jednoczesnej stabilności uczenia. Zastosowanie wielu równoległych filtrów o różnych rozmiarach w bloku Inception umożliwia wydobywanie cech wieloskalowych – od lokalnych interakcji po bardziej globalne wzorce pozycyjne – co jest szczególnie istotne w złożonych środowiskach przestrzennych. Dodanie połączeń rezydualnych znacząco poprawia przepływ gradientu, eliminując problem zanikania sygnału i umożliwiając trenowanie głębszych modeli bez degradacji jakości reprezentacji. Połączenie tych dwóch podejść pozwala sieci zachować elastyczność i ekspresyjność architektury Inception, a jednocześnie wykorzystać właściwości stabilizujące charakterystyczne dla ResNet, prowadząc do skuteczniejszej i bardziej odpornej ekstrakcji cech w złożonych zadaniach decyzyjnych.

### 3.9 Hyper-Connections

*Hyper-Connections*, zaproponowane przez Zhu i in. [30], rozszerzają klasyczne połączenia rezydualne poprzez wprowadzenie uczonych zależności pomiędzy reprezentacjami z różnych głębokości sieci. Mechanizm ten ma na celu ograniczenie kompromisu pomiędzy efektywnym przepływem gradientu a ryzykiem kolapsu reprezentacji, czyli sytuacji, w której kolejne warstwy generują bardzo podobne

reprezentacje cech, a wzrost głębokości modelu przestaje prowadzić do istotnego wzbogacania informacji.

W odróżnieniu od klasycznego podejścia, w którym, w każdej warstwie propagowana jest pojedyncza reprezentacja, w mechanizmie *Hyper-Connections* utrzymywany jest zbiór  $n$  równoległych reprezentacji ukrytych:

$$H_l = \begin{bmatrix} h_l^{(1)} \\ h_l^{(2)} \\ \vdots \\ h_l^{(n)} \end{bmatrix} \in \mathbb{R}^{n \times d}, \quad (5)$$

gdzie  $n$  oznacza współczynnik rozszerzenia, a  $d$  jest wymiarem pojedynczej reprezentacji.

Dla wejścia sieci  $h_0$  tworzona jest początkowa macierz ukryta:

$$H_0 = \begin{bmatrix} h_0 \\ h_0 \\ \vdots \\ h_0 \end{bmatrix}. \quad (6)$$

### Sposób działania

Dla warstwy  $l$  mechanizm *Hyper-Connections* opisuje blokowa macierz:

$$HC_l = \begin{pmatrix} 0_{1 \times 1} & B_l \\ A_{m,l} & A_{r,l} \end{pmatrix} \in \mathbb{R}^{(n+1) \times (n+1)}, \quad (7)$$

gdzie:

- $B_l \in \mathbb{R}^{1 \times n}$  określa wpływ wyjścia bieżącej transformacji warstwy,
- $A_{m,l} \in \mathbb{R}^{n \times 1}$  wyznacza sposób agregacji równoległych reprezentacji do wejścia bieżącej warstwy,
- $A_{r,l} \in \mathbb{R}^{n \times n}$  odpowiada za przenoszenie oraz mieszanie wcześniejszych reprezentacji.

Najpierw wyznaczane jest wejście do bieżącej transformacji warstwy:

$$\tilde{h}_l^\top = A_{m,l}^\top H_{l-1}. \quad (8)$$

Następnie obliczana jest część rezydualna:

$$H'_l = A_{r,l}^\top H_{l-1}. \quad (9)$$

Po zastosowaniu transformacji warstwy  $F_l(\cdot)$  otrzymujemy wynik:

$$\hat{H}_l = B_l^\top (F_l(\tilde{h}_l))^\top + H'_l. \quad (10)$$

W przeciwieństwie do klasycznego połączenia rezydualnego, w którym wejście i wyjście warstwy są łączone przez sztywno zadaną sumę, tutaj sieć uczy się wag połączeń pomiędzy wieloma równoległymi reprezentacjami. Pozwala to modelować bardziej elastyczne zależności pomiędzy kolejnymi głębokościami sieci.

### Depth-connections i width-connections

W interpretacji autorów mechanizm ten można rozdzielić na dwa typy połączeń:

- **depth-connections** – odpowiedzialne za integrację informacji pomiędzy wyjściem bieżącej warstwy a reprezentacjami propagowanymi wzdłuż głębokości sieci,
- **width-connections** – odpowiedzialne za wymianę informacji pomiędzy równoległymi reprezentacjami w obrębie tej samej warstwy.

Dzięki temu jedna warstwa nie operuje na pojedynczym strumieniu informacji, lecz na zbiorze strumieni, które mogą wzajemnie na siebie oddziaływać.

### Dynamiczne Hyper-Connections

Rozszerzeniem podstawowego wariantu są dynamiczne *Hyper-Connections*, w których wagi połączeń zależą od aktualnego wejścia:

$$HC_l(H_{l-1}) = \begin{pmatrix} 0_{1 \times 1} & B_l(H_{l-1}) \\ A_{m,l}(H_{l-1}) & A_{r,l}(H_{l-1}) \end{pmatrix}. \quad (11)$$

W tym celu najpierw normalizuje się wejściową macierz ukrytą:

$$\bar{H}_{l-1} = \text{norm}(H_{l-1}), \quad (12)$$

a następnie oblicza dynamiczne składniki:

$$B_l(H_{l-1}) = s_\beta \odot \tanh\left((\bar{H}_{l-1} W_\beta)^\top\right) + B_l, \quad (13)$$

$$A_{m,l}(H_{l-1}) = s_\alpha \odot \tanh(\bar{H}_{l-1} W_m) + A_{m,l}, \quad (14)$$

$$A_{r,l}(H_{l-1}) = s_\alpha \odot \tanh(\bar{H}_{l-1} W_r) + A_{r,l}, \quad (15)$$

gdzie  $W_\beta$ ,  $W_m$  oraz  $W_r$  są parametrami uczonymi, natomiast  $s_\beta$  i  $s_\alpha$  są współczynnikami skalującymi.


Wariant dynamiczny zwiększa elastyczność architektury, ponieważ siła połączeń może być dopasowywana do aktualnych danych wejściowych, a nie tylko ustalana raz na etapie treningu.

### Znaczenie architektoniczne

Istotną własnością *Hyper-Connections* jest możliwość uczenia różnych wzorców przepływu informacji w jednej architekturze. Mechanizm ten nie ogranicza się do sztywnego układu sekwencyjnego charakterystycznego dla klasycznych sieci głębokich, lecz pozwala modelowi uczyć się zarówno silniejszych zależności sekwencyjnych, jak i częściowo równoległych sposobów organizacji przetwarzania.

Autorzy pracy wskazują również, że kluczowe znaczenie ma stosowanie więcej niż jednego strumienia reprezentacji, tj.  $n > 1$ . Dopiero w takim przypadku możliwe jest jednoczesne modelowanie różnych wzorców połączeń pomiędzy warstwami oraz ograniczenie kompromisu pomiędzy zanikaniem gradientu a kolapsem reprezentacji.

W eksperymentach przedstawionych przez Zhu i in. [30] *Hyper-Connections* prowadziły do szybszej konwergencji oraz lepszej jakości reprezentacji niż klasyczne połączenia rezydualne, przy niewielkim narzucie dodatkowych parametrów.



**Rysunek 2.** Schemat działania mechanizmu hyper-connections.

Mechanizm ten umożliwia jednocześnie integrację informacji pomiędzy różnymi głębokościami sieci oraz wymianę informacji pomiędzy równoległymi reprezentacjami.

### Dynamiczne hyper-connections

Rozszerzeniem podstawowego mechanizmu są dynamiczne *hyper-connections*, w których macierz połączeń nie jest stała, lecz zależy od aktualnych reprezentacji ukrytych. Oznacza to, że sposób agregacji i przekazywania informacji pomiędzy warstwami może zmieniać się w zależności od danych przetwarzanych przez sieć.

Dla warstwy  $l$  dynamiczną macierz połączeń można zapisać w postaci:

$$HC_l(H_{l-1}) = \begin{pmatrix} 0_{1 \times 1} & B_l(H_{l-1}) \\ A_{m,l}(H_{l-1}) & A_{r,l}(H_{l-1}) \end{pmatrix}. \quad (16)$$

Zapis ten oznacza, że trzy główne składniki mechanizmu, tj. macierz  $B_l$ , wektor  $A_{m,l}$  oraz macierz  $A_{r,l}$ , są wyznaczone na podstawie aktualnej macierzy reprezentacji  $H_{l-1}$ . W rezultacie warstwa może dostosowywać siłę połączeń do bieżącego kontekstu wejściowego.

Najpierw wykonywana jest normalizacja reprezentacji z poprzedniej warstwy:

$$\bar{H}_{l-1} = \text{norm}(H_{l-1}). \quad (17)$$

Celem tego kroku jest ustabilizowanie wartości wejściowych przed obliczeniem składników dynamicznych. Dzięki temu dalsze transformacje są mniej wrażliwe na skalę reprezentacji.

Następnie obliczana jest dynamiczna wersja macierzy  $B_l$ :

$$B_l(H_{l-1}) = s_\beta \tanh\left((\bar{H}_{l-1} W_\beta)^\top\right) + B_l. \quad (18)$$

Wyrażenie to można interpretować jako sumę dwóch części: statycznej macierzy  $B_l$ , uczonej podczas treningu, oraz poprawki zależnej od aktualnego wejścia. Składnik dynamiczny jest wyznaczany przez transformację liniową z wagami  $W_\beta$ , a następnie ograniczany funkcją  $\tanh$ . Współczynnik  $s_\beta$  kontroluje siłę tej poprawki. Macierz  $B_l(H_{l-1})$  określa, w jakim stopniu wynik bieżącej transformacji warstwy wpływa na poszczególne równoległe reprezentacje.

W analogiczny sposób wyznaczany jest dynamiczny składnik agregujący wejście do bieżącej warstwy:

$$A_{m,l}(H_{l-1}) = s_\alpha \tanh(\bar{H}_{l-1} W_m) + A_{m,l}. \quad (19)$$

Macierz ta określa, w jaki sposób równoległe reprezentacje z poprzedniej warstwy są łączone w reprezentację wejściową dla aktualnej transformacji. Innymi słowy, decyduje ona o tym, z których strumieni informacji i z jaką siłą zostanie zbudowane wejście warstwy.

Ostatnim składnikiem jest dynamiczna macierz odpowiedzialna za część rezydualną:

$$A_{r,l}(H_{l-1}) = s_\alpha \tanh(\bar{H}_{l-1} W_r) + A_{r,l}. \quad (20)$$

Macierz  $A_{r,l}(H_{l-1})$  opisuje sposób przenoszenia oraz mieszania wcześniejszych reprezentacji w ścieżce rezydualnej. Pozwala to modelowi dynamicznie decydować, które informacje z poprzednich reprezentacji powinny zostać zachowane, a które osłabione.

W powyższych zależnościach:

- $H_{l-1} \in \mathbb{R}^{n \times d}$  oznacza macierz reprezentacji ukrytych z poprzedniej warstwy,
- $\bar{H}_{l-1}$  oznacza jej znormalizowaną postać,
- $W_\beta$ ,  $W_m$ ,  $W_r$  są macierzami wag dodatkowych transformacji liniowych,
- $B_l$ ,  $A_{m,l}$ ,  $A_{r,l}$  są bazowymi, statycznymi parametrami uczonymi w trakcie treningu,
- $s_\beta$  oraz  $s_\alpha$  są współczynnikami skalującymi wpływ składnika dynamicznego.

W rezultacie dynamiczne *hyper-connections* łączą zalety parametrów statycznych i adaptacji zależnej od wejścia. Oznacza to, że model nie korzysta z jednej, niezmienniej struktury połączeń, lecz może modyfikować przepływ informacji pomiędzy warstwami zależnie od aktualnie przetwarzanych reprezentacji.

### Znaczenie architektoniczne

Istotną własnością *hyper-connections* jest możliwość reprezentowania różnych struktur architektury sieci neuronowej w ramach jednego modelu. W zależności od wartości macierzy HC sieć może przyjmować charakter:

- sekwencyjny (podobnie jak klasyczna sieć głęboka),
- równoległy (jak w architekturach typu transformer),
- hybrydowy, łączący oba podejścia.

W rezultacie architektura może automatycznie uczyć się optymalnego sposobu organizacji przepływu informacji pomiędzy warstwami sieci neuronowej.

Badania eksperymentalne pokazują, że zastosowanie hyper-connections prowadzi do szybszej konwergencji procesu uczenia oraz poprawy jakości reprezentacji w głębokich modelach [30].

## 3.10 Rozszerzenia architektury sieci i techniki stabilizacji uczenia

### Layer Normalization

Normalizacja warstwowa (ang. Layer Normalization, LN) to technika normalizacji zaproponowana przez Ba i wsp. (2016) jako alternatywa dla normalizacji wsadowej (BN). [1] W przeciwieństwie do BN, która wykorzystuje statystyki z mini-batcha, LN oblicza statystyki normalizacji dla każdej próbki osobno, uwzględniając wszystkie neurony danej warstwy w próbce. Formalnie, dla wektora aktywacji  $\mathbf{a}^{(l)} = (a_1^{(l)}, a_2^{(l)}, \dots, a_H^{(l)})$  w warstwie  $l$ , normalizacja warstwowa oblicza średnią  $\mu^{(l)} = \frac{1}{H} \sum_{i=1}^H a_i^{(l)}$  oraz wariancję  $\sigma^{2(l)} = \frac{1}{H} \sum_{i=1}^H (a_i^{(l)} - \mu^{(l)})^2$ . Następnie każda aktywacja zostaje przeskalowana do postaci znormalizowanej:

$$\hat{a}_i^{(l)} = \frac{a_i^{(l)} - \mu^{(l)}}{\sqrt{\sigma^{2(l)} + \epsilon}}$$

gdzie  $\epsilon$  to niewielka stała zapobiegająca dzieleniu przez zero. Po normalizacji, dla każdego neuronu stosuje się jeszcze parametry adaptacyjne: skalowanie  $\gamma_i$  oraz przesunięcie  $\beta_i$ , analogiczne jak w BN, co daje wyjście  $y_i^{(l)} = \gamma_i \hat{a}_i^{(l)} + \beta_i$ . Takie podejście powoduje, że wszystkie neurony w warstwie mają jednakowe wartości średniej i wariancji dla danej próbki, ale każda próbka (każdy element batcha) jest normalizowana względem własnych statystyk. W rezultacie znika zależność od rozmiaru batcha – LN działa poprawnie nawet przy batch size = 1, czyli w trybie online. Co więcej, algorytm normalizacji jest identyczny podczas trenowania i testowania modelu, gdyż statystyki liczone są lokalnie dla próbki (nie ma potrzeby utrzymywania średnich z bieżącej partii czy populacji)

Normalizację warstwową stosuje się zazwyczaj bezpośrednio po warstwie liniowej lub konwolucyjnej, a przed funkcją aktywacji, analogicznie do sposobu użycia Batch Normalization. W testowanych architekturach agentów A2C – takich jak warianty z blokami Inception oraz ich warianty rezydualne – warstwy LayerNorm mogą być stosowana zarówno w trunku konwolucyjnym, jak i w częściach gęstych. W przeciwieństwie do BatchNorm, LN oblicza średnią i wariancję osobno dla każdej próbki, niezależnie od innych elementów batcha. Dzięki temu działa poprawnie nawet przy batch size = 1, co jest szczególnie przydatne w algorytmach on-policy, takich jak PPO i A2C. LN jest także odporny na niestacjonarność rozkładów – nie bazuje na statystykach historycznych, lecz zawsze normalizuje względem bieżącej próbki. Ułatwia to adaptację do zmieniającej się przestrzeni stanów oraz upraszcza

implementację, ponieważ nie wymaga przełączania między trybem treningu i ewaluacji. LN lepiej sprawdza się również przy korelowanych danych, typowych dla trajektorii w RL – normalizacja odbywa się niezależnie dla każdej próbki, co zapobiega mieszaniu informacji pomiędzy krokami czasowymi. Badania pokazują, że sieci z LN osiągają stabilniejsze i skuteczniejsze uczenie niż z BatchNorm, zwłaszcza w warunkach zmiennych i silnie skorelowanych danych.

W architekturach głębokich, takich jak Inception-Residual, LN dodatkowo stabilizuje propagację sygnału przez ścieżki rezydualne i przeciwdziała problemom z gradientami. Choć w klasycznej wizji komputerowej preferuje się inne metody, LN okazuje się szczególnie użyteczna w RL, gdzie małe batch size i niestacjonarne dane utrudniają skuteczne użycie BatchNorm.

## Parametric Relu

Parametric ReLU (PReLU) to uogólnienie klasycznej funkcji aktywacji ReLU, w którym nachylenie dla ujemnych wartości wejścia nie jest stałe, lecz jest parametryczne (uczony podczas trenowania sieci). Formalnie funkcja PReLU jest zdefiniowana wzorem:

$$f(x) = \begin{cases} x, & x > 0 \\ ax, & x \leq 0 \end{cases} \quad (21)$$

gdzie  $x$  oznacza wejście neuronu, zaś  $a$  (często oznaczane też  $\alpha$ ) to współczynnik kontrolujący nachylenie dla ujemnych wartości [7]. W odróżnieniu od zwykłego ReLU (dla którego  $a = 0$ ) wartość  $a$  w PReLU jest uczonym parametrem modelu (stąd nazwa Parametric ReLU) i może przyjmować różne wartości w różnych kanałach lub neuronach.

W trakcie przepływu wstecznego (backpropagation) wyznaczane są gradienty zarówno względem wejścia  $x$ , jak i względem parametru  $a$ . Parametr  $a$  jest więc dostosowywany wraz z wagami sieci metodami optymalizacji gradientowej – podczas treningu sieć uczy się optymalnej wartości nachylenia dla ujemnych wartości każdej funkcji aktywacji. W praktyce uczenie parametru  $a$  odbywa się standardowo za pomocą algorytmu wstecznej propagacji błędu (np. z zastosowaniem optymalizatora z momentum). Ważne jest, że nie stosuje się zwykle regularizacji  $L_2$  (tzw. weight decay) na parametr  $a$ , aby nie biasować go w kierunku zera (co sprowadziłoby PReLU do zwykłego ReLU). Zamiast tego pozwala się wartości  $a$  swobodnie dostosować – badania wskazują, że nawet bez ograniczania zakresu  $a$  jego wartości rzadko przekraczają 1 (współczynniki pozostają umiarkowane). Typową inicjalizacją jest nadanie  $a$  małej dodatniej wartości (np. 0.25) przed treningiem

## He Initialization

Inicjalizacja He (znana też jako Kaiming initialization) to metoda losowego ustawiania początkowych wag sieci neuronowej zaproponowana przez Kaiminga He i wsp. [7] specjalnie z myślą o sieciach z aktywacją ReLU. Wagi każdej warstwy są inicjalizowane jako niezależne zmienne losowe o średniej zero i odpowiednio dobranej wariancji. Formalnie dla wariantu normalnego (rozkład Gaussa) przyjmuje się:



$$w_{ij}^{(1)} \sim N(0, \sigma^2), \text{ gdzie } \sigma^2 = \frac{2}{n_{in}}$$

, czyli wagi pochodzą z rozkładu normalnego o średniej 0 i wariancji  $2/n_{in}$  (tu  $n_{in}$  oznacza liczbę wejściowych połączeń neuronu, tzw. fan-in danej warstwy). Istnieje też wariant z rozkładu jednostajnego – wówczas wagi losuje się z przedziału symetrycznego:

$$w_{ij}^{(1)} \sim U(-a, +a), \text{ gdzie } a = \sqrt{\frac{6}{n_{in}}}$$

,  
tak aby wariancja była równa  $2/n_{in}$  (ponieważ dla  $U(-a, a)$  wariancja wynosi  $a^2/3$ , stąd  $a = \sqrt{6/n_{in}}$ ). Metoda He bywa nazywana również MSRA initialization (od Microsoft Research Asia) albo Kaiming initialization, od imienia głównego autora pracy. Celem inicjalizacji He jest zachowanie odpowiedniej skali sygnału (wariancji aktywacji) przy propagacji przez bardzo głęboką sieć. W sieciach głębokich niewłaściwe skalowanie wag może skutkować zanikaniem sygnału albo eksplozją sygnału w kolejnych warstwach.

He i wsp. analizowali wariancję aktywacji warstwy po warstwie i wymagali, by iloczyn wariancji sygnału przez kolejne warstwy pozostawał stały (w przybliżeniu równy 1). Warunek ten prowadzi do doboru wariancji wag  $\text{Var}(w) \approx 2/n_{in}$ , co odpowiada powyższym wzorom. Intuicyjnie, współczynnik 2 wynika z faktu, że aktywacja ReLU zeruje średnio połowę wejść – aby utrzymać stałą wariancję sygnału na wyjściu neuronu ReLU, wariancja wag musi być dwa razy większa niż w przypadku funkcji liniowej [7]. Dzięki temu rozwiązaniu amplituda sygnałów nie zanika wraz z głębokością sieci, co ułatwia trenowanie bardzo głębokich modeli.

### Inicjalizacja He, a Glorot

Inicjalizacja He została zaprojektowana z myślą o architekturach wykorzystujących niesymetryczne funkcje aktywacji, takie jak ReLU oraz jej rozszerzenia, w szczególności PReLU. W przeciwieństwie do wcześniejszych metod – jak inicjalizacja Glorota (znana też jako Xavier), która była dostosowana do aktywacji o symetrycznym rozkładzie wyjść (np. funkcji tanh lub sigmoidalnej) – inicjalizacja He uwzględnia fakt, że funkcje typu ReLU przekazują tylko część dodatnich sygnałów do kolejnych warstw. To asymetryczne zachowanie aktywacji czyni wcześniejsze strategie inicjalizacji mniej skutecznymi w kontekście głębokich modeli wykorzystujących rektyfikację.

W przypadku metody Glorota wagi warstw są dobierane tak, aby równoważyć propagację sygnału do przodu i gradientów wstecz. Wariancja wag zależy od średniej liczby połączeń wejściowych i wyjściowych danego neuronu (fan-in i fan-out), przez co inicjalizacja ta bywa niewystarczająca w sytuacji, gdy aktywacja istotnie zmniejsza amplitudę sygnału. W rezultacie może dojść do szybkiego wygaszenia aktywacji w głębokich warstwach, co utrudnia efektywne trenowanie modelu.

Inicjalizacja He, poprzez skupienie się wyłącznie na liczbie wejść do neuronu, lepiej dopasowuje skalę wag do rektyfikowanych funkcji aktywacji, zachowując stabilność propagowanego sygnału nawet

w bardzo głębokich sieciach. Empiryczne wyniki autorów metody potwierdzają, że zastosowanie tej strategii umożliwia skuteczne trenowanie modeli złożonych z wielu warstw, które przy klasycznej inicjalizacji nie zbiegały lub zbiegały bardzo wolno. Ponadto, mimo że metoda He nie została zaprojektowana z myślą o kontroli przepływu gradientu wstecznego, w praktyce pozwala ona również uniknąć problemów eksplodujących lub zanikających gradientów, szczególnie w sieciach wykorzystujących ReLU lub PReLU.

### Obsługa maskowania akcji

W algorytmach typu actor-critic kluczowe jest zapewnienie, aby przestrzeń akcji dostępna dla agenta była zgodna z formalnymi ograniczeniami środowiska. W grze Blood Bowl liczba wszystkich możliwych do zakodowania akcji jest bardzo wysoka, lecz w danym stanie jedynie niewielki ich podzbiór stanowi akcje legalne. Pozostałe działania są strukturalnie niedozwolone (np. ruch na zajęte pole, podniesienie nieistniejącej piłki, wykonanie blitzu przez zawodnika, który wykonał już akcję w danej turze).

Aby zapewnić zgodność polityki z regułami środowiska oraz poprawić stabilność procesu uczenia, zastosowano formalny mechanizm *maskowania akcji* (ang. *action masking*). Mechanizm ten polega na modyfikacji wektora logitów polityki poprzez przypisanie logitom odpowiadającym nielegalnym akcjom w stanie  $s$  wartości nieskończenie ujemnej.

$$\text{logit}_i = -\infty \quad (22)$$

Po zastosowaniu funkcji softmax

$$\pi_{\theta}(a_i | s) = \frac{\exp(\text{logit}_i)}{\sum_j \exp(\text{logit}_j)}, \quad (23)$$

otrzymujemy w sposób bezpośredni

$$\pi_{\theta}(a_i | s) = 0 \quad \text{jeśli akcja } i \text{ jest nielegalna.} \quad (24)$$

Maskowanie można interpretować jako projekcję rozkładu polityki na zbiór akcji dopuszczalnych:

$$\pi_{\theta}(\cdot | s) \longrightarrow \pi_{\theta}(\cdot | s)|_{\mathcal{A}(s)}, \quad (25)$$

gdzie  $\mathcal{A}(s) \subseteq \mathcal{A}$  oznacza zbiór akcji legalnych w stanie  $s$ .

Formalnie mechanizm ten można również zapisać jako dodanie wektora maski:

$$\tilde{z}_i = z_i + m_i, \quad (26)$$

gdzie

$$m_i = \begin{cases} 0, & i \in \mathcal{A}(s), \\ -\infty, & i \notin \mathcal{A}(s), \end{cases} \quad (27)$$

a  $z_i$  oznacza oryginalne logity polityki.

Tak zdefiniowana transformacja zapewnia, że wartość prawdopodobieństwa każdej akcji spoza zbioru  $\mathcal{A}(s)$  równa jest zero, przy jednoczesnym braku wpływu na rozkład prawdopodobieństwa wśród akcji legalnych. W konsekwencji maskowanie poprawia efektywność eksploracji, redukuje wariancję gradientów oraz zapobiega generowaniu trajektorii niezgodnych z regułami gry. Mechanizm ten został zaimplementowany analogicznie do praktyk stosowanych w środowisku BotBowl.

### 3.11 Architektury sieci neuronowych zastosowanych w środowisku

W eksperymentach przeprowadzonych dla wariantu środowiska `env_size=3` porównano osiem modeli, odpowiadających czterem architekturom trenowanym z użyciem dwóch algorytmów uczenia ze wzmocnieniem: A2C oraz PPO. Taki dobór modeli był zgodny z przyjętą konfiguracją turniejową.

Każdy model miał architekturę typu actor-critic i wykorzystywał dwa strumienie wejściowe:

$$\mathbf{x}_s \in \mathbb{R}^{C \times H \times W}, \quad \mathbf{x}_{ns} \in \mathbb{R}^N.$$

Strumień przestrzenny  $\mathbf{x}_s$  koduje stan planszy, natomiast strumień nieprzestrzenny  $\mathbf{x}_{ns}$  zawiera cechy wektorowe opisujące bieżący stan gry. Po przetworzeniu obu wejść i ich połączeniu otrzymywana jest wspólna reprezentacja  $z$ , która stanowi wejście dla części aktora i krytyka. Na jej podstawie wyznaczone są logity polityki  $l \in \mathbb{R}^{|\mathcal{A}_3|}$  oraz estymata wartości stanu  $V(s) \in \mathbb{R}$ .

W implementacji liczba neuronów warstwy ukrytej po etapie fuzji cech była dobierana dynamicznie i ustawiana zgodnie z rozmiarem przestrzeni akcji:

$$\text{hidden\_nodes} = \text{action\_space} = |\mathcal{A}_3|.$$

We wszystkich wariantach architektury stosowano mechanizm maskowania akcji nielegalnych:


$$\tilde{l}_i = \begin{cases} l_i, & m_i = 1, \\ -\infty, & m_i = 0, \end{cases} \quad \pi(a_i|s) = \text{softmax}(\tilde{l})_i.$$

Dzięki temu agent przypisuje niezerowe prawdopodobieństwo wyłącznie akcjom dopuszczalnym w danym stanie przez silnik gry.


#### 3.11.1 Analizowane warianty architektur

1. **Inception Block** – wariant oparty na równoległych konwolucjach o parametrach  $(32, 3 \times 3)$ ,  $(16, 5 \times 5)$ ,  $(16, 7 \times 7)$  oraz  $(8, 9 \times 9)$ .


2. **Hyperconnection Inception (statyczny)** – wariant z dwoma blokami Inception połączonymi mechanizmem HyperConnectionStack ( $\text{rate}=2$ ), ze statycznymi wagami mieszania  $\alpha$  oraz  $\beta$ .
3. **Inception Residual Block** – sekwencja bloków Inception–Residual z połączeniami skrótowymi oraz warstwami LayerNorm2d.
4. **Hyperconnection Inception (dynamiczny)** – wariant analogiczny do wersji statycznej, lecz z dynamiczną korektą wag  $\alpha$  oraz  $\beta$ , zależną od bieżących cech wejściowych.



**Rysunek 3.** Wspólny schemat architektury sieci stosowanej w eksperymentach dla  $\text{env\_size}=3$ .



**Rysunek 4.** Schemat bloku HyperConnection–Inception (wariant statyczny i dynamiczny) stosowanego dla  $\text{env\_size}=3$ .



**Rysunek 5.** Schemat bloku Inception–Residual stosowanego w wariantcie residualnym.

## Rozdział 4

# Środowisko testowe

Blood Bowl to strategiczna gra planszowa łącząca elementy footballu amerykańskiego oraz gier bitewnych. Rozgrywka toczy się na planszy w formie boiska o wymiarach 26×15 pól. Dwóch graczy prowadzi przeciwne drużyny złożone z figurek (zwanymi zawodnikami) i dąży do zdobycia większej liczby przyłożeń (ang. touchdown) niż przeciwnik. Mecz składa się z dwóch połówek po 8 tur dla każdego gracza. W każdej turze trener może aktywować wielu swoich zawodników, wykonując nimi szereg akcji na boisku. Do podstawowych typów akcji należą m.in.: ruch (przesunięcie zawodnika o kilka pól zależnie od jego parametru szybkości), podanie piłki, przekazanie piłki innemu zawodnikowi (handoff), blok (atak na sąsiadującego przeciwnika w próbie powalenia go), blitz (połączenie ruchu i ataku), a nawet sfaulowanie leżącego przeciwnika (foul). Gdy zawodnik z piłką dotrze do strefy punktowej rywala, jego drużyna zdobywa punkt. Po upływie ustalonej liczby tur mecz kończy się, a wygrywa drużyna z większą liczbą przyłożeń.

Istotnym elementem Blood Bowl jest losowość oraz wynikające z niej zarządzanie ryzykiem. Większość istotnych akcji – takich jak bloki, uniki, podania czy chwyt piłki – wymaga powodzenia testu kośćmi. Szanse zależą od atrybutów zawodników (np. Siły przy blokowaniu, Zręczności przy chwytaniu czy uniku) oraz posiadanych umiejętności specjalnych (np. Dodge, Block). Niepowodzenie testu zwykle oznacza natychmiastową utratę tury (tzw. turnover). W związku z tym trenerzy muszą rozważnie planować kolejność działań – zazwyczaj zaczynają od ruchów bezpiecznych (niewymagających rzutów lub z bardzo dużą szansą powodzenia), odkładając ryzykowne akcje na koniec tury. Gra przyznaje też ograniczoną liczbę żetonów przerzutów, które pozwalają powtórzyć nieudany rzut kością, co dodaje element decyzyjny dotyczący zarządzania zasobami szczęścia. Stan gry w Blood Bowl jest złożony i bogaty: obejmuje on nie tylko położenie wszystkich zawodników na planszy, ale również ich stan (stojący, powalony, ogłuszony itp.), posiadane atrybuty i umiejętności, stan piłki, warunki pogodowe, licznik tur, rezerwy i kontuzje graczy w drużynach, dostępne przerzuty i inne elementy. W odróżnieniu od gier takich jak Go czy szachy, reprezentacja stanu w Blood Bowl ma charakter wielowymiarowy przestrzennie oraz nieprzestrzennie, a przestrzeń akcji nie jest stała – dostępne ruchy zależą od kontekstu sytuacyjnego każdego kroku.

## 4.1 Bloodbowl jako benchmark dla uczenia ze wzmocnieniem.

Blood Bowl jest uważany za kolejne wielkie wyzwanie dla sztucznej inteligencji w grach planszowych [njustesen.github.io](https://njustesen.github.io). Kilka cech tej gry sprawia, że stanowi ona wartościowe środowisko testowe dla metod uczenia ze wzmocnieniem i sieci neuronowych:

1. Wysoki branching factor – Każda tura oferuje olbrzymią liczbę możliwych sekwencji ruchów. Trener może poruszać wieloma zawodnikami w dowolnej kolejności, a każdy z nich może wykonać kilka akcji. Średni rozgałęźnik (branching factor) pojedynczej akcji zawodnika szacuje się na ok.  $10^5$  możliwych przebiegów. W rezultacie pojedyncza tura (maksymalnie 10 zawodników) może rozwidlać się nawet na rząd  $10^{50}$  możliwych ciągów akcji. Dla porównania, w szachach średni branching factor wynosi ok. 30, a w go ok. 300. Tak ogromna przestrzeń decyzji przekracza możliwości tradycyjnych algorytmów przeszukiwania i stanowi poważne wyzwanie dla metod RL.
2. Nieregularne drzewa decyzyjne – W Blood Bowl długość tury oraz dostępne akcje nie są z góry ustalone. Z jednej strony, lista dozwolonych ruchów w danym momencie zależy od



Rysunek 6. Plansza Bloodbowl



stanu gry (np. tylko niektórzy zawodnicy mogą wykonać określone akcje, możliwe pola ruchu są ograniczone zasięgiem, itp.), co oznacza dynamicznie zmieniającą się przestrzeń akcji. Z drugiej strony, skutek losowości tura gracza może zakończyć się wcześniej (np. nieudany rzut kończy turę), przez co drzewo rozgrywki ma zmienną głębokość gałęzi. Strukturę decyzyjną Blood Bowl można określić jako niestandardową lub zagnieżdżoną: tura składa się z serii ruchów zawodników (podtur), z których każdy z kolei bywa sekwencją kilku akcji (np. ruch przez kilka pól, a następnie blok). Taka nieregularność utrudnia zastosowanie klasycznych algorytmów planowania, które zakładają stałą liczbę ruchów na turę i jednolitą strukturę drzewa.

3. Wieloetapowy charakter rozgrywki – Blood Bowl wymaga długoterminowego planowania oraz podejmowania szeregu skorelowanych decyzji w ramach jednej tury i całego meczu. Pełna rozgrywka to kilkanaście tur na stronę, łącznie około 1600 kroków decyzyjnych według szacunków. Punkty (przyłożenia) są zdobywane rzadko – w wielu partiach pada bardzo mało goli, zwłaszcza przy losowej lub słabej grze zdarza się remis 0:0. Taka długa horyzontalnie sekwencja decyzji ze sporadyczną nagrodą (sparse reward) powoduje, że algorytmy oparte na przeszukiwaniu oraz klasyczne metody RL mają trudność z uzyskaniem sygnału uczącego. Konieczne jest więc planowanie wieloetapowe – zarówno taktyczne (w obrębie jednej tury, optymalna kolejność akcji pod ryzykiem turnover), jak i strategiczne (przez cały mecz, np. zabezpieczenie piłki, kontrola czasu gry itp.).
4. Aspekty przestrzenne gry – Gra ma wyraźny charakter przestrzenny: położenie zawodników na planszy i kontrola terytorium (strefy ataku, krycie przeciwników, droga do pola punktowego) są kluczowe dla sukcesu. Stan gry można przedstawić w formie siatki cech (mapy zajętości pól, stref wpływu, pozycji piłki, itp.), co przypomina reprezentacje stanów znane z gier takich jak StarCraft II. Równocześnie jednak Blood Bowl posiada elementy symboliczne i atrybutowe (cechy postaci, liczniki, efekty), których nie da się ująć wyłącznie na obrazowej planszy. Ta kombinacja informacji przestrzennej i nieprzestrzennej wymaga od agentów uczenia się zarówno rozumienia układów geometrycznych na polu gry, jak i śledzenia zmiennych nienumerycznych (punkty, przerzuty, statusy). Stanowi to dobre pole do badań nad połączeniem sieci konwolucyjnych (do map cech) z sieciami gęstymi lub mechanizmami uwagi, analogicznie do podejść stosowanych w środowisku StarCraft II Learning Environment (SC2LE) [29].

## 4.2 Środowisko BotBowl

W celu badania opisanych wyżej zagadnienia, stworzono BotBowl – otwartoźródłowe środowisko symulujące pełne zasady Blood Bowl, znane też jako Fantasy Football AI (FFAI). Platforma ta dostarcza szereg funkcjonalności wspierających efektywne szkolenie agentów sztucznej inteligencji.

BotBowl udostępnia interfejs zgodny z popularnym schematem OpenAI Gym, co ułatwia integrację z istniejącymi algorytmami RL. Środowisko zostało zaimplementowane w języku Python, dzięki

czemu można bezpośrednio korzystać z bibliotek uczenia maszynowego, a sam interfejs obejmuje standardowe metody jak `reset()` (inicjalizacja nowej gry) oraz `step(akcja)` (wykonanie kroku).

Framework BotBowl umożliwia łatwe tworzenie i włączenie własnych agentów. Udostępniane jest API wysokiego poziomu: wystarczy zaimplementować klasę bota dziedziczącą po abstrakcyjnej klasie `Agent` (z metodami m.in. `act()` definiującą decyzje na podstawie stanu gry). Następnie takiego bota można zarejestrować w systemie pod unikalną nazwą i używać go w symulacjach lub turniejach. BotBowl zawiera też przykładowe zaimplementowane boty (np. losowy `RandomBot`, heurystyczny `GrodBot`) mogące służyć jako punkt wyjścia lub przeciwnicy do testów.

Środowisko pozwala na resetowanie stanu gry oraz rozgrywanie meczów między wybranymi agentami w trybie symulowanym bez interakcji użytkownika. Możliwe jest również równoległe uruchamianie wielu instancji gry (`multi-env`) w celu przyspieszenia treningu. Dodatkowo BotBowl zawiera forward model (silnik przewidywania następstw akcji), co umożliwia zastosowanie metod planowania czy przeszukiwania drzewa gry (np. MCTS) obok czystego RL. Wbudowane funkcje turniejowe pozwalają automatycznie rozegrać serię gier między botami, kontrolując limity czasu na turę oraz wykrywając ewentualne zawieszenia lub awarie agentów (co jest istotne przy treningu i testowaniu na szeroką skalę).

Stan rozgrywki zwracany przez środowisko jest podzielony na część przestrzenną i nieprzestrzenną. Część przestrzenna to tensor wymiaru  $(L, H, W)$ , gdzie  $H \times W$  odpowiada polu gry (wraz z ewentualnymi obrzeżami), zaś  $L$  to liczba warstw cech. Domyślnie dostarczanych jest kilkadziesiąt warstw, m.in. zajętość pola przez zawodników, strefy ataku, pozycja piłki, pola dostępne do ruchu, prawdopodobieństwa powodzenia rzutów itp. . Część nieprzestrzenna to wektor liczbowy zawierający inne informacje o stanie gry – np. liczba tur, punkty, pozostałe przerzuty obu drużyn, aktualna faza/procedura gry – a także wskazania, które typy akcji są obecnie dostępne. Co ważne, BotBowl dostarcza również maskę dozwolonych akcji, dzięki czemu agent otrzymuje informację, które konkretne akcje (z ogromnej puli wszystkich możliwych) są w danym momencie legalne. Przestrzeń wszystkich potencjalnych akcji jest bowiem bardzo duża – rzędu tysięcy możliwych kodowanych decyzji – jednak w danej sytuacji tylko niewielki podzbiór ruchów wchodzi w grę. Maski (oraz alternatywnie struktura danych `game.state.available_actions`) pozwala ograniczyć wybór do ruchów legalnych, co znacznie ułatwia trenowanie modelu i konwergencję algorytmów RL.


Podsumowując, Blood Bowl dostarcza unikalne, wymagające środowisko o wysokiej złożoności, które dzięki platformie BotBowl jest dostępne do eksperymentów z algorytmami uczenia ze wzmocnieniem. Połączenie czynników takich jak ogromny rozgałęźnik decyzyjny, losowość i wieloetapowość decyzji oraz potrzeba percepcji przestrzennej czyni z niego atrakcyjny poligon doświadczalny dla nowoczesnych metod AI. BotBowl zapewnia zaś odpowiednie narzędzia – od interfejsu Gym, poprzez bogatą reprezentację stanów i mechanizmy ułatwiające implementację własnych agentów, aż po możliwość symulacji gier na masową skalę – aby skutecznie trenować i testować modele uczące się gry w Blood Bowl [11].







## Rozdział 5

# Wyniki

Na poniższych wykresach przedstawiono porównanie przebiegów uczenia dla wszystkich analizowanych konfiguracji architektur sieci neuronowych. Wykresy pokazują zmiany rozpatrywanych metryk w funkcji liczby iteracji treningowych. Dla każdej metryki zaprezentowano zarówno przebieg w skali liniowej, jak i logarytmicznej. Umożliwia to jednoczesną ocenę końcowych efektów uczenia oraz różnic widocznych we wczesnej fazie treningu, gdy wartości metryk są jeszcze bardzo małe.







Pierwszy wykres przedstawia średnią liczbę przyłożeń na epizod ( $TD/Episode$ ) obliczaną w oknie obejmującym ostatnie 50 epizodów, natomiast drugi przedstawia wskaźnik zwycięstw wyznaczany w analogicznym oknie. Przez epizod rozumiany jest tutaj pojedynczy pełny mecz rozegrany przez agenta w środowisku BotBowl, od stanu początkowego do zakończenia rozgrywki. Obie miary są ze sobą silnie powiązane, ponieważ w analizowanym środowisku o wyniku wielu meczów decydowało pojedyncze przyłożenie. Wzrost liczby przyłożeń na epizod zwykle przekładał się więc bezpośrednio na wzrost odsetka zwycięstw.

Analiza pierwszych dwóch wykresów pokazuje wyraźną przewagę modeli trenowanych algorytmem PPO nad wariantami uczonymi z użyciem A2C. Najlepsze przebiegi uzyskują przede wszystkim modele *Dynamic HC + Inception PPO* oraz *HC + Inception PPO*. Model *HC + Inception PPO* osiąga istotną poprawę już w środkowej fazie treningu i przez długi czas utrzymuje wysokie wartości obu metryk. Z kolei *Dynamic HC + Inception PPO* początkowo uczy się nieco wolniej, lecz w dalszej części treningu uzyskuje najwyższe wartości zarówno  $TD/Episode$ , jak i okiennego wskaźnika zwycięstw. Jednocześnie w końcowej fazie dla tego modelu widoczny jest wyraźny spadek metryk okiennych, co może wskazywać na częściową utratę stabilności wyuczonej polityki.

Model *Inception PPO* przez większość treningu pozostaje słabszy od dwóch najlepszych wariantów PPO, jednak w końcowej fazie uczenia notuje wyraźną poprawę. Oznacza to, że architektura ta uczyła się wolniej, ale ostatecznie wypracowała konkurencyjną politykę. Odmienne przebieg obserwowany jest dla wariantów A2C. Spośród nich jedynie *Inception-Residual A2C* wykazuje istotny postęp w pierwszej połowie treningu, osiągając najwyższe wartości metryk w grupie modeli A2C. Poprawa ta nie okazuje się jednak trwała, ponieważ w dalszej części uczenia następuje systematyczny spadek skuteczności, a końcowe wartości obu miar zbliżają się do zera. Pozostałe warianty A2C przez większość czasu utrzymują się na bardzo niskim poziomie, co wskazuje na brak stabilnego i skutecznego uczenia.

Wariant *Inception-Residual PPO* osiąga umiarkowane wyniki na początku treningu, jednak nie przechodzi w fazę wyraźnej poprawy i ostatecznie również traci skuteczność.

Trzeci wykres przedstawia skumulowany wskaźnik zwycięstw w funkcji liczby iteracji treningowych. W odróżnieniu od miary okiennej ma on charakter narastający, dlatego lepiej odzwierciedla całkowity przebieg procesu uczenia niż aktualną jakość polityki w końcowej fazie treningu.

Na wykresie skumulowanego wskaźnika zwycięstw najwyższą wartość końcową osiąga model *Dynamic HC + Inception PPO*, natomiast drugą pozycję zajmuje *HC + Inception PPO*. Potwierdza to, że połączenie architektury Inception z mechanizmem hyper-connections było najbardziej efektywne w badanym środowisku. Warto jednak zauważyć, że model *Inception-Residual A2C*, mimo silnego spadku metryk okiennych pod koniec treningu, przez długi czas utrzymuje stosunkowo wysoką wartość skumulowanego wskaźnika zwycięstw. Wynika to z faktu, że miara skumulowana zachowuje efekt wcześniejszej, relatywnie dobrej fazy uczenia. Z kolei model *Inception PPO* przez większą część treningu ma niższą wartość skumulowanego wskaźnika zwycięstw, mimo że pod koniec osiąga lepsze wyniki w metrykach okiennych.

Zestawienie wszystkich trzech wykresów prowadzi do dwóch głównych wniosków. Po pierwsze, algorytm PPO zdecydowanie lepiej wykorzystywał potencjał badanych architektur niż A2C. Po drugie, najlepsze rezultaty uzyskano dla modeli łączących PPO z blokami Inception oraz mechanizmem hyper-connections. Jednocześnie przebiegi uczenia pokazują, że nawet najlepsze warianty nie były całkowicie wolne od niestabilności, co jest zgodne z wysoką wariancją i dużą losowością środowiska Blood Bowl.

Po zakończeniu procesu uczenia przeprowadzono rozgrywki pomiędzy wszystkimi wytrenowanymi modelami. Każda sieć rozegrała z każdą inną po 4 mecze.

**Tabela 4.** Końcowa tabela ligi wytrenowanych modeli

| Miejsce | Model                  | Alg. | Zwyc. | Rem. | Por. | Punkty | TD   |
|---------|------------------------|------|-------|------|------|--------|------|
| 1       | Dynamic HC + Inception | PPO  | 7     | 20   | 1    | 41     | 10:3 |
| 2       | HC + Inception         | PPO  | 6     | 19   | 3    | 37     | 6:4  |
| 3       | Inception              | PPO  | 6     | 18   | 4    | 36     | 8:6  |
| 4       | Inception-Residual     | A2C  | 0     | 27   | 1    | 27     | 0:1  |
| 5       | Inception              | A2C  | 0     | 26   | 2    | 26     | 0:2  |
| 6       | Inception-Residual     | PPO  | 0     | 26   | 2    | 26     | 0:2  |
| 7       | Dynamic HC + Inception | A2C  | 0     | 25   | 3    | 25     | 0:3  |
| 8       | HC + Inception         | A2C  | 0     | 25   | 3    | 25     | 0:3  |

Wyniki ligi potwierdzają przewagę modeli uczonych algorytmem PPO. Trzy pierwsze miejsca zajęły kolejno konfiguracje *Dynamic HC + Inception PPO*, *HC + Inception PPO* oraz *Inception PPO*, które uzyskały odpowiednio 41, 37 i 36 punktów. Najlepszy model osiągnął bilans 7 zwycięstw, 20 remisów i 1 porażki oraz najwyższy dodatni bilans przyłożeń równy 10:3. Oznacza to, że połączenie bloków

Inception z dynamicznymi hyper-connections okazało się najskuteczniejszym rozwiązaniem spośród wszystkich analizowanych wariantów.

Na uwagę zasługuje fakt, że żaden z modeli A2C nie odniósł ani jednego zwycięstwa. Jednocześnie duża liczba remisów pokazuje, że modele te nie były w stanie wypracować żadnej formy przewagi, i zapewne wykonywały losowe ruchy bez analizy stanu gry. Wyjątkiem jest model *Inception-Residual A2C*, który zakończył ligę z bilansem 0 zwycięstw, 27 remisów i 1 porażki. Oznacza to, że pomimo braku umiejętności ofensywnych, w jakimś stopniu umiał się bronić przed innymi sieciami.

Całość wyników wskazuje więc, że kluczowe znaczenie miał zarówno dobór architektury, jak i algorytmu uczenia. W badanym środowisku najlepiej sprawdziły się rozwiązania oparte na PPO oraz blokach Inception rozszerzonych o mechanizm hyper-connections, natomiast warianty A2C okazały się zbyt słabe, aby skutecznie konkurować z najlepszymi modelami.

## 5.1 Możliwości dalszych prac badawczych

Uzyskane wyniki pokazują, że skuteczność agenta w środowisku Blood Bowl zależy zarówno od zastosowanego algorytmu uczenia, jak i od budowy sieci neuronowej. W dalszych badaniach warto więc dokładniej sprawdzić, które elementy architektury najbardziej wpływają na końcowy wynik. Można to zrobić poprzez porównanie większej liczby wariantów sieci, przeprowadzenie większej liczby niezależnych treningów oraz testy dla różnych wartości hiperparametrów. Zasadne byłoby także rozszerzenie ewaluacji o grę przeciwko innym przeciwnikom oraz o trening *self-play*.

Interesującym kierunkiem jest również dalszy rozwój mechanizmu hyper-connections. W nowszych pracach, takich jak *mHC: Manifold-Constrained Hyper-Connections*, proponowane są zmiany mające poprawić stabilność uczenia i działanie tego typu połączeń. Może to być inspiracją do sprawdzenia, czy podobne rozwiązania przyniosłyby korzyści także w uczeniu ze wzmocnieniem. Warto również zbadać zaproponowane architektury w innych grach o dużej liczbie możliwych decyzji, aby ocenić, czy uzyskane wnioski są ogólne, czy głównie związane ze środowiskiem Blood Bowl.



# Bibliografia

- [1] Ba, J. L., Kiros, J. R. i Hinton, G. E., *Layer Normalization*, 2016. arXiv: 1607.06450 [stat.ML]. adr.: <https://arxiv.org/abs/1607.06450>.
- [2] Bishop, C. M., *Pattern Recognition and Machine Learning*. New York: Springer, 2006, isbn: 978-0-387-31073-2.
- [3] Cybenko, G., „Approximation by superpositions of a sigmoidal function”, *Mathematics of Control, Signals and Systems*, t. 2, nr. 4, s. 303–314, grud. 1989, issn: 1435-568X. doi: 10.1007/BF02551274. adr.: <https://doi.org/10.1007/BF02551274>.
- [4] Dai, Z. i Heckel, R., *Channel Normalization in Convolutional Neural Network avoids Vanishing Gradients*, lip. 2019. doi: 10.48550/arXiv.1907.09539.
- [5] Goodfellow, I., Bengio, Y. i Courville, A., *Deep Learning*. MIT Press, 2016. adr.: <http://www.deeplearningbook.org>.
- [6] Goodfellow, I. J. i in., *Generative Adversarial Networks*, 2014. arXiv: 1406.2661 [stat.ML]. adr.: <https://arxiv.org/abs/1406.2661>.
- [7] He, K., Zhang, X., Ren, S. i Sun, J., *Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification*, 2015. arXiv: 1502.01852 [cs.CV]. adr.: <https://arxiv.org/abs/1502.01852>.
- [8] Hinton, G., Srivastava, N. i Swersky, K., „Neural networks for machine learning lecture 6a overview of mini-batch gradient descent”, *Cited on*, t. 14, nr. 8, s. 2, 2012.
- [9] Hornik, K., Stinchcombe, M. i White, H., „Multilayer feedforward networks are universal approximators”, *Neural Networks*, t. 2, nr. 5, s. 359–366, 1989, issn: 0893-6080. doi: 10.1016/0893-6080(89)90020-8. adr.: <https://www.sciencedirect.com/science/article/pii/0893608089900208>.
- [10] Ioffe, S. i Szegedy, C., „Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift”, w *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 2015, s. 448–456.
- [11] Justesen, N., *Bot Bowl Documentation*. term. wiz. 24 mar. 2026. adr.: <https://njustesen.github.io/botbowl/>.
- [12] Kingma, D. P. i Ba, J., „Adam: A Method for Stochastic Optimization”, *International Conference on Learning Representations (ICLR)*, 2015. arXiv: 1412.6980 [cs.LG]. adr.: <https://arxiv.org/abs/1412.6980>.

- [13] Kohonen, T., „The self-organizing map”, *Proceedings of the IEEE*, t. 78, nr. 9, s. 1464–1480, 1990. doi: 10.1109/5.58325.
- [14] LeCun, Y., Bottou, L., Bengio, Y. i Haffner, P., „Gradient-based learning applied to document recognition”, *Proceedings of the IEEE*, t. 86, nr. 11, s. 2278–2324, 1998.
- [15] McCulloch, W. S. i Pitts, W., „A logical calculus of the ideas immanent in nervous activity”, *The bulletin of mathematical biophysics*, t. 5, nr. 4, s. 115–133, grud. 1943, issn: 1522-9602. doi: 10.1007/BF02478259. adr.: <https://doi.org/10.1007/BF02478259>.
- [16] Mhaskar, H. N. i Poggio, T., „Function approximation by deep networks”, *Communications on Pure and Applied Analysis*, t. 19, nr. 8, s. 4085–4095, 2020, issn: 1534-0392. doi: 10.3934/cpaa.2020181. adr.: <https://www.aims sciences.org/article/id/519d7cfc-913a-45ea-9a9b-cee4dd60e31b>.
- [17] Minsky, M. L. i Papert, S. A., *Perceptrons: expanded edition*. Cambridge, MA, USA: MIT Press, 1988, isbn: 0262631113.
- [18] Mnih, V. e. a., „Asynchronous Methods for Deep Reinforcement Learning”, *Proceedings of the 33rd International Conference on Machine Learning*, 2016.
- [19] Nesterov, Y., „A method of solving a convex programming problem with convergence rate  $O(1/k^2)$ ”, *Soviet Mathematics Doklady*, t. 27, s. 372–376, 1983.
- [20] OpenAI, *OpenAI Baselines: ACKTR & A2C*, OpenAI, 2017. adr.: <https://openai.com/index/openai-baselines-acktr-a2c/>.
- [21] Rolnick, D. i Tegmark, M., „The power of deeper networks for expressing natural functions”, maj 2017. doi: 10.48550/arXiv.1705.05502.
- [22] Schulman, J., Levine, S., Moritz, P., Jordan, M. I. i Abbeel, P., *Trust Region Policy Optimization*, 2015. arXiv: 1502.05477 [cs.LG]. adr.: <https://arxiv.org/abs/1502.05477>.
- [23] Schulman, J. e. a., „High-Dimensional Continuous Control Using Generalized Advantage Estimation”, *International Conference on Learning Representations*, 2016.
- [24] Schulman, J. e. a., „Proximal Policy Optimization Algorithms”, *arXiv preprint arXiv:1707.06347*, 2017.
- [25] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I. i Salakhutdinov, R., „Dropout: A Simple Way to Prevent Neural Networks from Overfitting”, *Journal of Machine Learning Research*, t. 15, nr. 1, s. 1929–1958, 2014.
- [26] Sutton, R. S. i Barto, A. G., *Temporal-difference learning*. MIT Press Cambridge, MA, USA, 2018, s. 131–132.
- [27] Sutton, R. S. i Barto, A. G., *Reinforcement Learning: An Introduction*, 2nd. MIT Press, 2018.
- [28] Telgarsky, M., „Benefits of depth in neural networks”, w *Conference on learning theory*, PMLR, 2016, s. 1517–1539.



- [29] Vinyals, O., Babuschkin, I., Czarnecki, W. M. i in., „StarCraft II: A New Challenge for Reinforcement Learning”, *arXiv preprint arXiv:1708.04782*, 2017.
- [30] Zhu, T. i in., „Hyper-Connections”, *arXiv preprint arXiv:2409.19606*, 2024.



## **Wykaz skrótów i symboli**



# Spis rysunków

|   |                                                                                                                            |    |
|---|----------------------------------------------------------------------------------------------------------------------------|----|
| 1 | Porównanie płytkiej i głębokiej sieci neuronowej z wyrównanym położeniem neuronów wyjściowych. . . . .                     | 15 |
| 2 | Schemat działania mechanizmu hyper-connections. . . . .                                                                    | 45 |
| 3 | Wspólny schemat architektury sieci stosowanej w eksperymentach dla <code>env_size=3</code> . .                             | 52 |
| 4 | Schemat bloku HyperConnection–Inception (wariant statyczny i dynamiczny) stosowanego dla <code>env_size=3</code> . . . . . | 52 |
| 5 | Schemat bloku Inception–Residual stosowanego w wariacie residualnym. . . . .                                               | 52 |
| 6 | Plansza Bloodbowl . . . . .                                                                                                | 54 |



# Spis tabel

|   |                                                            |    |
|---|------------------------------------------------------------|----|
| 1 | Porównanie funkcji aktywacji oraz ich pochodnych . . . . . | 14 |
| 4 | Końcowa tabela ligi wytrenowanych modeli . . . . .         | 60 |